

TRƯƠNG CẨM LY

GPU / NPU Software Engineer

✉ camly.gpu@gmail.com

☎ 0909445566

⊕
github.com/camly-cuda

in linkedin.com/in/camly-truong

PROFESSIONAL SUMMARY

GPU/NPU Software Engineer với nền tảng nghiên cứu chuyên sâu về AI chip optimization và high-performance computing. Thành thạo CUDA C++ và Python cho deep learning inference optimization. Có kinh nghiệm thực chiến implement fused CUDA kernels cho quantized transformer inference, tối ưu memory bandwidth và warp occupancy trên GPU/NPU hardware. Từng làm nghiên cứu tại môi trường AI chip lab, am hiểu pipeline từ model quantization đến hardware deployment.

KỸ NĂNG KỸ THUẬT

GPU Programming	CUDA C++ (expert), cuBLAS, cuDNN, Triton (OpenAI)
NPU / Custom HW	Custom AI accelerator inference, hardware-aware kernel design
Quantization	QAT (Quantization-Aware Training), INT4/INT8, FP8, ONNX
Transformer Kernels	Fused attention (Flash Attention variant), KV-cache optimization
Profiling & Tuning	NVIDIA Nsight Compute, Nsight Systems, warp occupancy, roofline model
Frameworks	PyTorch (ATen/C++ backend), TensorRT, ONNX Runtime
Languages	C++ (C++17/20), Python, Bash, CMake

KINH NGHIỆM LÀM VIỆC

GPU/NPU Software Engineer

2022 - Hiện tại

VinAI Semiconductor Lab (Intern → Researcher)

- Nghiên cứu và implement fused attention CUDA kernel tối ưu cho inference quantized transformer (INT4) trên custom AI accelerator, giảm memory bandwidth bottleneck 2.5x.
- Phát triển quantization-aware training pipeline (QAT) cho vision transformer models, duy trì độ chính xác trong 1% so với FP32 baseline khi deploy INT4.
- Sử dụng NVIDIA Nsight Compute đo lường warp occupancy và memory throughput để xác định kernel optimization opportunities; đạt 85%+ arithmetic intensity target.
- Xây dựng benchmarking framework tự động so sánh latency, throughput và memory usage của các kernel implementations trên nhiều batch sizes và sequence lengths.
- Đóng góp vào internal CUDA kernel library cho đội NPU firmware (15+ fused ops).

Junior AI Researcher

2020 - 2022

Đại học Bách Khoa (Research Lab)

- Nghiên cứu efficient transformer architectures và knowledge distillation cho edge devices.
- Triển khai và benchmark các PyTorch models trên NVIDIA GPU cluster của lab.
- Tham gia publish paper về hardware-aware neural architecture search (NAS).

HỌC VẤN

Thạc sĩ Khoa học Máy tính - Chuyên ngành AI & HPC

Đại học Bách Khoa Hà Nội

2020 - 2022

Cử nhân Kỹ thuật Điện tử - Tin học

Đại học Bách Khoa Hà Nội

2016 - 2020

CHỨNG CHỈ

- NVIDIA Deep Learning Institute - CUDA C++ Developer
- NVIDIA Nsight Profiling Certification
- TensorRT Developer - NVIDIA DLI
- PyTorch Advanced - Coursera (deeplearning.ai)

PHONG CÁCH LÀM VIỆC

Research-driven	Hardware-level optimization	Data-informed decisions
Low-level systems thinker	Collaborative researcher	

LƯƠNG MONG MUỐN

Mức lương kỳ vọng	5,000 USD / tháng (gross)
-------------------	---------------------------