

ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG



LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH KHOA HỌC MÁY TÍNH

Đề tài

**ORCHGRAPH-RAG: MÔ HÌNH ĐA TÁC TỬ ĐIỀU PHỐI
BẰNG ĐỒ THỊ CHO TUYỂN DỤNG THÔNG MINH VÀ
TRUY XUẤT TRI THỨC CÁ NHÂN HÓA**
**(ORCHGRAPH-RAG: A GRAPH-ORCHESTRATED
MULTI-MODAL AGENT PARADIGM FOR PRIVACY-AWARE
RECRUITMENT AND PERSONALIZED RETRIEVAL)**

Sinh viên: Trần Thị Hồng Ngọc

Mã số: B2207546

Khóa: 48

Giảng viên hướng dẫn: TS. Mã Trường Thành

Cần Thơ, 04/2026

ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG



LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH KHOA HỌC MÁY TÍNH

Đề tài

**ORCHGRAPH-RAG: MÔ HÌNH ĐA TÁC TỬ ĐIỀU PHỐI
BẰNG ĐỒ THỊ CHO TUYỂN DỤNG THÔNG MINH VÀ
TRUY XUẤT TRI THỨC CÁ NHÂN HÓA**

**(ORCHGRAPH-RAG: A GRAPH-ORCHESTRATED
MULTI-MODAL AGENT PARADIGM FOR PRIVACY-AWARE
RECRUITMENT AND PERSONALIZED RETRIEVAL)**

Giảng viên hướng dẫn
TS. Mã Trường Thành

Sinh viên thực hiện
Trần Thị Hồng Ngọc
Mã số: B2207546
Khóa: 48

Cần Thơ, 04/2026

This image shows a blank sheet of white paper with horizontal ruling lines. The lines are evenly spaced and run across the width of the page. There are no margins, text, or other markings on the paper.

Cần Thơ, ngày tháng năm 2026
(Ký và ghi rõ họ tên)

LỜI CẢM ƠN

Trước hết, tôi xin bày tỏ lòng biết ơn sâu sắc đến Trường Công nghệ thông tin và Truyền thông, Đại học Cần Thơ, nơi đã tạo điều kiện thuận lợi và môi trường học tập năng động để tôi được tiếp cận, nghiên cứu và phát triển kiến thức trong lĩnh vực công nghệ thông tin. Các học phần đại cương, cơ sở ngành và chuyên ngành bổ ích đã giúp tôi tích lũy được nền tảng kiến thức vững chắc, cũng như rèn luyện được khả năng tư duy logic, sáng tạo và kỹ năng làm việc chuyên nghiệp.

Đặc biệt, tôi xin gửi lời cảm ơn chân thành và sâu sắc nhất đến TS. Mã Trường Thành, người đã luôn tận tình hướng dẫn, đồng hành và định hướng cho tôi trong suốt quá trình thực hiện đề tài. Thầy không chỉ giúp tôi củng cố kiến thức chuyên môn mà còn truyền cho tôi tinh thần nghiên cứu nghiêm túc, kiên nhẫn và cầu tiến trong học thuật. Những góp ý quý báu cùng sự chỉ bảo tận tâm của thầy là nguồn động lực to lớn giúp tôi vượt qua những khó khăn để hoàn thiện đề tài luận văn tốt nghiệp một cách tốt nhất.

Tôi cũng xin gửi lời tri ân đến toàn thể quý thầy cô trong Trường Công nghệ Thông tin và Truyền thông, những người đã tận tâm giảng dạy, truyền đạt kiến thức quý báu cho tôi trong suốt những năm học vừa qua. Sự cống hiến, tâm huyết và tinh thần trách nhiệm của quý thầy cô đã giúp tôi không ngừng trưởng thành trong cả kiến thức chuyên môn lẫn tư duy nghiên cứu.

Cuối cùng, tôi xin gửi lời cảm ơn sâu sắc đến gia đình và bạn bè, những người luôn ở bên cạnh, chia sẻ, động viên và khích lệ tinh thần trong suốt quá trình học tập và hoàn thiện luận văn. Sự yêu thương và ủng hộ của mọi người là điểm tựa vững chắc giúp tôi có thêm nghị lực để hoàn thành tốt chặng đường học tập này.

Tôi xin chân thành cảm ơn!

Cần Thơ, ngày 17 tháng 04 năm 2026

Người viết

Trần Thị Hồng Ngọc

MỤC LỤC

DANH MỤC HÌNH ẢNH	iii
DANH MỤC BẢNG BIỂU	v
DANH MỤC TỪ VIẾT TẮT	vi
ABSTRACT	vii
TÓM LƯỢC	viii
I. PHẦN GIỚI THIỆU	1
1. Đặt vấn đề	1
2. Những nghiên cứu liên quan	2
3. Mục tiêu đề tài	4
4. Đối tượng và phạm vi nghiên cứu	5
5. Phương pháp nghiên cứu	5
6. Bố cục quyển báo cáo	5
II. PHẦN NỘI DUNG	7
Chương 1. Mô tả bài toán	7
1. Mô tả chi tiết bài toán	7
1.1. Bài toán tuyển dụng thông minh và truy xuất tri thức	7
1.2. Ứng dụng Web	8
2. Vấn đề giải pháp liên quan đến bài toán	8
2.1. Mô hình ngôn ngữ lớn và giao tiếp streaming	8
2.2. Mô hình nhúng đa ngôn ngữ	9
2.3. Cơ sở dữ liệu vector và pgvector	10
2.4. Đồ thị tri thức và cơ sở dữ liệu đồ thị Neo4j	13
2.5. Nền tảng lưu trữ và đồng bộ dữ liệu Supabase	15
2.6. Tìm kiếm kết hợp (Hybrid Search)	15
2.7. Mô hình số cá nhân (AI Digital Twin)	15
2.8. Framework backend FastAPI và frontend Next.js	16
2.9. Thang đo đánh giá hệ thống RAG (RAGAS)	16
CHƯƠNG 2. THIẾT KẾ VÀ CÀI ĐẶT GIẢI PHÁP	18

1. Thiết kế hệ thống	18
1.1. Mô hình lưu trữ song song	19
1.2. Pipeline nhập liệu CV tiếng Việt	21
1.3. Lược đồ tri thức RecruitmentNode	22
1.4. Cơ chế tìm kiếm kết hợp (Hybrid Search Engine)	24
1.5. Thiết kế bản sao số (Digital Twin Interview)	26
1.6. Hệ thống lịch hẹn và thông báo	28
2. Cài đặt giải pháp	31
2.1. Thu thập và chuẩn bị dữ liệu CV	31
2.2. Cài đặt các bước trong quy trình nhập liệu	32
2.3. Cài đặt tìm kiếm kết hợp và đồ thị tri thức	33
2.4. Cài đặt Digital Twin qua WebSocket streaming	35
2.5. Cài đặt giao diện lập trình ứng dụng và hệ thống lịch hẹn	36
2.6. Cài đặt giao diện người dùng	37
CHƯƠNG 3. KIỂM THỬ VÀ ĐÁNH GIÁ	40
1. Giao diện sản phẩm	40
2. Kết quả thực nghiệm	45
2.1. Thiết lập thực nghiệm	45
2.2. Đánh giá quy trình nhập liệu	46
2.3. So sánh các mô hình biểu diễn vector	48
2.4. Đánh giá hệ thống truy xuất và bảo mật	50
3. Thảo luận chung	53
III. PHẦN KẾT LUẬN	54
1. Kết quả đạt được	54
2. Hướng phát triển	54
TÀI LIỆU THAM KHẢO	56

DANH MỤC HÌNH ẢNH

Hình 1.	Sơ đồ kiến trúc tổng quát của mô hình Truy xuất tăng cường sinh thực	2
Hình 2.	Minh hoạ kiến trúc cơ bản của ESCO với ba trụ cột Kỹ năng, Năng lực và Nghề nghiệp	3
Hình 3.	Minh hoạ kiến trúc cơ bản của GraphRAG	3
Hình 4.	Sơ đồ khối chức năng của hệ thống kỹ năng	4
Hình 5.	Kiến trúc bài toán ORCHGRAPH-RAG	7
Hình 6.	Minh hoạ kiến trúc cơ bản của SBERT	10
Hình 7.	Minh hoạ kiến trúc cơ bản của mô hình nhúng đa ngôn ngữ (tiếng Anh: màu xanh và tiếng Đức: màu hồng)	10
Hình 8.	Quy trình hoạt động cơ bản của một cơ sở dữ liệu vector	11
Hình 9.	Minh hoạ cấu trúc đồ thị đa tầng (trái) và cơ chế chọn lân cận heuristic (phải) của thuật toán HNSW dùng trong tìm kiếm ANN ..	11
Hình 10.	Sơ đồ đường đi cho quá trình lưu trữ trong cơ sở dữ liệu vector	11
Hình 11.	Sơ đồ đường đi cho quá trình truy vấn trong cơ sở dữ liệu vector ..	12
Hình 12.	Minh hoạ việc sử dụng độ tương đồng cosine để đo lường khoảng cách ngữ nghĩa giữa các câu trong không gian vector	13
Hình 13.	Cấu trúc đồ thị tri thức	14
Hình 14.	Minh hoạ mô hình đồ thị thuộc tính trong Neo4j	14
Hình 15.	Kiến trúc tổng quát của hệ thống	18
Hình 16.	Kiến trúc mô hình lưu trữ song song	19
Hình 17.	Sơ đồ nguyên lý Polyglot Persistence	20
Hình 18.	Luồng tiền xử lý dữ liệu	21
Hình 19.	Luồng trích xuất và ghi dữ liệu	22
Hình 20.	Kiến trúc bộ máy truy vấn kết hợp	25
Hình 21.	Luồng xử lý phỏng vấn Digital Twin	27
Hình 22.	Sơ đồ kiểm soát truy cập dựa trên quan hệ đồ thị	28
Hình 23.	Luồng xử lý lịch hẹn và thông báo	29
Hình 24.	Sơ đồ trích xuất dữ liệu qua LLM theo chiến lược Map-Reduce ...	33
Hình 25.	Sơ đồ thuật toán tính điểm tìm kiếm kết hợp	34
Hình 26.	Sơ đồ tổng hợp các nhóm API của hệ thống	36
Hình 27.	Kiến trúc phân tầng của giao diện người dùng	38
Hình 28.	Hình giao diện trang tìm kiếm ứng viên	40

Hình 29.	Hình giao diện phỏng vấn Bản sao số	41
Hình 30.	Hình giao diện trực quan hóa đồ thị tri thức	42
Hình 31.	Hình giao diện quản lý lịch phỏng vấn thực	43
Hình 32.	Hình giao diện cài đặt lịch rảnh của ứng viên	44
Hình 33.	Hình giao diện nạp dữ liệu và phản hồi trạng thái xử lý CV	44
Hình 34.	Biểu đồ trực quan hóa độ bao phủ từng trường	47
Hình 35.	Biểu đồ so sánh hiệu suất các mô hình trên hai tác vụ thực nghiệm	50
Hình 36.	Biểu đồ so sánh kết quả RAGAS giữa các cấu hình truy xuất	51

DANH MỤC BẢNG BIỂU

Bảng 2.	Đặc tả lược đồ dữ liệu RecruitmentNode và ranh giới bảo mật	23
Bảng 3.	Phân tách trường dữ liệu trong RecruitmentNode	24
Bảng 4.	Các luật chuẩn hóa cứng áp dụng sau bước trích xuất thực thể	24
Bảng 5.	Cấu hình siêu tham số tìm kiếm kết hợp	26
Bảng 6.	Cấu trúc và phân bố tập dữ liệu thực nghiệm	32
Bảng 7.	Thời gian xử lý trung bình phân bố theo các bước trong quy trình .	33
Bảng 8.	Thành phần điểm trong cơ chế tìm kiếm kết hợp	35
Bảng 9.	Danh sách các API hệ thống nhóm Xác thực và Nghiệp vụ cốt lõi .	37
Bảng 10.	Danh sách các API hệ thống nhóm Lịch hẹn và Thông báo	37
Bảng 11.	Ánh xạ định tuyến và các tính năng giao diện cốt lõi	39
Bảng 12.	Kết quả đánh giá bước làm sạch văn bản trên 30 CV	46
Bảng 13.	Độ bao phủ từng trường trên 30 CV có nhãn chuẩn	47
Bảng 14.	Tổng hợp kết quả bước trích xuất thực thể	47
Bảng 15.	Mức độ đầy đủ của các nút ứng viên	48
Bảng 16.	Thông kê quan hệ và kỹ năng trong đồ thị	48
Bảng 17.	So sánh 4 mô hình biểu diễn vector trên tác vụ tìm kiếm ứng viên .	49
Bảng 18.	So sánh 4 mô hình biểu diễn vector trên tác vụ truy xuất câu hỏi phỏng vấn	49
Bảng 19.	Cấu hình bốn hệ thống thực nghiệm	51
Bảng 20.	Kết quả RAGAS so sánh bốn cấu hình truy xuất	51
Bảng 21.	Kết quả kiểm thử bảo mật phân lập dữ liệu đa người dùng (Cross- tenant)	52

DANH MỤC TỪ VIẾT TẮT

STT	Từ viết tắt	Từ viết đầy đủ
1	LLM	Large Language Model
2	RAG	Retrieval-Augmented Generation
3	GraphRAG	Graph Retrieval-Augmented Generation
4	KG	Knowledge Graph
5	GNN	Graph Neural Network
6	ANN	Approximate Nearest Neighbor
7	HNSW	Hierarchical Navigable Small World
8	ReBAC	Relationship-Based Access Control
9	RLS	Row Level Security
10	JD	Job Description
11	CV	Curriculum Vitae
12	ATS	Applicant Tracking System
13	SSE	Server-Sent Events
14	JWT	JSON Web Token
15	SBERT	Sentence-BERT
16	MRR	Mean Reciprocal Rank
17	NDCG	Normalized Discounted Cumulative Gain
18	API	Application Programming Interface
19	ASGI	Asynchronous Server Gateway Interface
20	SSR	Server-Side Rendering

ABSTRACT

In increasingly competitive IT labor markets, recruitment teams face the challenge of identifying the most suitable candidates rather than simply filtering qualified ones. Traditional ATS keyword-matching approaches fail to capture semantic equivalences and cannot reason over holistic career trajectories. While LLMs and RAG offer promising alternatives, conventional vector-based RAG architectures struggle with HR data due to relational fragmentation, multi-hop hallucination, and the absence of fine-grained privacy enforcement. This thesis proposes ORCHGRAPH-RAG, a graph-orchestrated multi-agent paradigm for privacy-aware recruitment and personalized knowledge retrieval. The architecture integrates a knowledge graph (Neo4j) with a vector store (Supabase/pgvector) in a Dual-DB design enforcing public/private data separation at the data layer. A Master Orchestrator Agent routes natural-language queries to either a Hybrid Search Agent combining graph-structural signals with dense vector similarity or a Digital Twin Agent conducting personalized AI-driven interviews grounded strictly on each candidate’s knowledge subgraph. Experiments on a synthesized Vietnamese IT recruitment dataset show the Hybrid+ configuration achieves Answer Relevance of 0.7474 and Context Recall of 0.9615 (RAGAS), with an extremely high privacy safety rate across all red-teaming scenarios. The GTE-multilingual-base model is the most consistent performer across both candidate retrieval (Recall@5: 0.9722) and interview question answering (Recall: 0.7949).

Keywords: Knowledge Graph, GraphRAG, Multi-Agent System, Digital Twin, Privacy-Aware Retrieval, Recruitment Intelligence, Large Language Models.

TÓM LƯỢC

Trong thị trường lao động công nghệ thông tin cạnh tranh, các hệ thống ATS truyền thống hay kiến trúc RAG vector hiện tại đều bộc lộ hạn chế về suy luận ngữ nghĩa, phân mảnh dữ liệu và bảo mật quyền riêng tư nhân sự. Để giải quyết vấn đề này, luận văn đề xuất ORCHGRAPH-RAG, mô hình đa tác nhân điều phối bằng đồ thị. Kiến trúc này tích hợp đồ thị tri thức (Neo4j) và cơ sở dữ liệu vector (Supabase/pgvector) theo thiết kế Dual-DB nhằm phân tách dữ liệu công khai và riêng tư ở tầng dữ liệu. Hệ thống sử dụng một Tác nhân Điều phối Chính để định tuyến truy vấn đến Tác nhân Tìm kiếm Kết hợp (tận dụng cả cấu trúc đồ thị và độ tương đồng vector) hoặc Tác nhân Bản sao Số (thực hiện phỏng vấn AI cá nhân hóa theo đồ thị tri thức riêng của ứng viên). Thử nghiệm trên dữ liệu tuyển dụng tại Việt Nam cho thấy cấu hình Hybrid+ đạt Mức độ Liên quan của câu trả lời là 0.7474 và Độ thu hồi Ngữ cảnh là 0.9615 (RAGAS), với độ an toàn quyền riêng tư cực kỳ cao trong các kịch bản kiểm thử tấn công. GTE-multilingual-base là mô hình đạt hiệu suất ổn định nhất trong cả tác vụ truy xuất ứng viên (Recall@5: 0.9722) và trả lời phỏng vấn (Recall: 0.7949).

Từ khóa: Đồ thị tri thức, GraphRAG, Hệ thống đa tác tử, Bản sao số, Truy xuất bảo mật cá nhân, Tuyển dụng thông minh, Mô hình ngôn ngữ lớn.

I. PHẦN GIỚI THIỆU

1. Đặt vấn đề

Trong bối cảnh thị trường nhân lực ngành Công nghệ thông tin ngày càng cạnh tranh, bài toán cốt lõi mà các bộ phận tuyển dụng phải đối mặt không đơn thuần là lọc đủ điều kiện mà là tìm đúng người phù hợp nhất, một sự phân biệt tưởng nhỏ nhưng có hệ quả lớn về chất lượng nhân sự và chi phí tuyển dụng. Quá trình này đòi hỏi xử lý khối lượng lớn dữ liệu phi cấu trúc: hồ sơ ứng viên (CV) chứa đựng lộ trình nghề nghiệp phức tạp, và mô tả công việc (JD) thường được diễn đạt theo nhiều cách khác nhau tùy từng tổ chức.

Phương pháp tuyển dụng truyền thống chủ yếu dựa vào hệ thống theo dõi ứng viên (Applicant Tracking System, viết tắt là ATS) với cơ chế đối sánh từ khóa (keyword matching). Cách tiếp cận này bộc lộ hai hạn chế căn bản: thứ nhất, nó bỏ sót các ứng viên tiềm năng do sự khác biệt về cách diễn đạt, một kỹ sư có kinh nghiệm "Spring Boot" hoàn toàn đáp ứng yêu cầu "Java Backend" nhưng có thể bị loại bởi cơ chế khớp từ khóa đơn giản; thứ hai, nó thiếu khả năng hiểu ngữ cảnh tổng thể của một lộ trình nghề nghiệp, tức là không thể suy luận rằng ứng viên từng dẫn dắt một dự án quy mô lớn tại công ty fintech có nhiều khả năng phù hợp hơn với vai trò senior engineer so với ứng viên chỉ liệt kê cùng danh sách kỹ năng mà thiếu chiều sâu kinh nghiệm.

Sự phát triển của Mô hình ngôn ngữ lớn (Large Language Model, viết tắt là LLM) và kỹ thuật Truy xuất tăng cường sinh thực (Retrieval-Augmented Generation, viết tắt là RAG) đã mang lại hướng tiếp cận mới có khả năng phân tích ngữ nghĩa tự nhiên. Tuy nhiên, kiến trúc RAG vector truyền thống (Naive RAG) gặp phải rào cản kỹ thuật đặc thù khi xử lý dữ liệu nhân sự. Do bản chất chia nhỏ văn bản (chunking) để lưu trữ vào cơ sở dữ liệu vector, Naive RAG thường làm đứt gãy mối liên hệ cấu trúc giữa các thực thể, ví dụ, thông tin "ứng viên A thực hiện dự án B tại công ty C sử dụng công nghệ D" bị phân tán sang nhiều đoạn văn bản độc lập không liên kết với nhau. Điều này dẫn đến hiện tượng "ảo giác" (hallucination) khi hệ thống phải suy luận tổng hợp đa chiều, đồng thời không có cơ chế kiểm soát ranh giới bảo mật thông tin cá nhân theo từng vai trò truy cập [22].

Từ thực tiễn đó, một hướng tiếp cận có triển vọng là sử dụng đồ thị tri thức (Knowledge Graph) để biểu diễn trực tiếp mạng lưới quan hệ giữa ứng viên và tổ chức, lưu trữ song song các thông tin công khai phục vụ truy vấn và kiểm soát truy cập dữ liệu nhạy cảm theo cấu trúc quan hệ. Khi đồ thị tri thức được tích hợp vào luồng sinh văn bản của LLM theo kiến trúc GraphRAG [5], hệ thống có thể "nhìn thấy" toàn bộ chuỗi quan hệ ngữ cảnh của từng ứng viên thay vì chỉ tìm kiếm đoạn văn bản tương đồng, từ đó hỗ trợ nhà tuyển dụng tìm đúng người phù hợp nhất thay vì chỉ lọc người đủ điều kiện theo từ khóa.


Xuất phát từ nhu cầu đó, đề tài "ORCHGRAPH-RAG: Mô hình đa tác tử điều phối bằng đồ thị cho tuyển dụng thông minh và truy xuất tri thức cá nhân hóa" được thực hiện nhằm xây dựng một hệ thống kết hợp sự linh hoạt trong hiểu ngữ

nghĩa của LLM với sự chặt chẽ về cấu trúc quan hệ của cơ sở dữ liệu đồ thị, hướng đến mục tiêu tối ưu hóa quy trình tuyển dụng và cá nhân hóa trải nghiệm phỏng vấn thông qua bản sao số (Digital Twin) của từng ứng viên.

2. Những nghiên cứu liên quan

Trong những năm gần đây, việc ứng dụng Trí tuệ nhân tạo vào lĩnh vực quản trị nhân sự đã dịch chuyển từ các mô hình học máy phân loại văn bản truyền thống sang các hệ thống hỏi đáp thông minh dựa trên LLM. Các nghiên cứu hiện tại có thể phân thành bốn hướng tiếp cận chính, mỗi hướng đóng góp những hiểu biết nhất định nhưng đồng thời bộc lộ những hạn chế còn tồn đọng.


Hướng 1, Hệ thống RAG dựa trên Vector (Vector-based RAG) [11]: Các nghiên cứu theo hướng này tập trung vào việc nhúng (embedding) CV và JD vào không gian vector để tính độ tương đồng ngữ nghĩa. Điểm mạnh của phương pháp là giải quyết được bài toán từ đồng nghĩa so với ATS truyền thống. Tuy nhiên, hạn chế căn bản nằm ở chỗ vector embedding chỉ nắm bắt độ tương đồng tổng thể giữa hai đoạn văn bản mà không giải quyết được các quan hệ đa chiều cần thiết để xây dựng ngữ cảnh suy luận. Cụ thể, khi một nhà tuyển dụng cần truy vấn "tìm ứng viên từng làm việc tại công ty fintech, có kinh nghiệm xây dựng hệ thống xử lý dữ liệu thời gian thực", hệ thống vector thuần túy không thể liên kết các thực thể rời rạc như công ty, lĩnh vực, dự án, công nghệ thành một chuỗi suy luận có cơ sở, dẫn đến kết quả không có căn cứ (ungrounded generation).



Hình 1. Sơ đồ kiến trúc tổng quát của mô hình Truy xuất tăng cường sinh thực


Hướng 2, Đồ thị tri thức trong nhân sự (HR Knowledge Graph): Một số nghiên cứu đã đề xuất xây dựng Ontology cho thị trường lao động, tiêu biểu là ESCO (European Skills, Competences, Qualifications and Occupations) của Ủy ban Châu Âu [7], ánh xạ mối quan hệ giữa kỹ năng và vị trí công việc. Các hệ thống này biểu diễn tốt cấu trúc quan hệ kết nối giữa HR và nhân sự ở tầng Ontology, nhưng hạn chế cơ bản là chúng hoạt động như cơ sở tri thức tĩnh, đòi hỏi truy vấn bằng ngôn ngữ cấu trúc (Cypher/SPARQL), không hỗ trợ tương tác ngôn ngữ tự nhiên với người dùng cuối và thiếu cơ chế kiểm soát quyền truy cập dữ liệu cá nhân nhạy

cảm [9].



Hình 2. Minh họa kiến trúc cơ bản của ESCO với ba trụ cột Kỹ năng, Năng lực và Nghề nghiệp


Hướng 3, GraphRAG tổng quát: Microsoft Research giới thiệu GraphRAG [5] như một kiến trúc lai tích hợp đồ thị tri thức vào luồng sinh văn bản của LLM, cải thiện đáng kể khả năng trả lời các câu hỏi đòi hỏi tổng hợp toàn cục (global queries). Tuy nhiên, GraphRAG được thiết kế cho dữ liệu văn bản tổng quát và chưa được tối ưu cho domain nhân sự với các ràng buộc đặc thù về bảo mật phân tầng (public/private data) hay bài toán phỏng vấn cá nhân hóa.



Hình 3. Minh họa kiến trúc cơ bản của GraphRAG

Hướng 4, Bản sao số trong tuyển dụng: Khái niệm Digital Twin tạo đại diện số phản chiếu đặc trưng của một cá nhân đã được nghiên cứu trong các lĩnh vực y tế và giáo dục [12, 17], nhưng ứng dụng vào tuyển dụng với kiểm soát truy cập theo

vai trò (Role-based Access Control, ReBAC) [8] vẫn là lĩnh vực còn mới mẻ và chưa có nhiều công bố học thuật.



Hình 4. Sơ đồ khối chức năng của hệ thống kỹ năng

Tóm lại còn những hạn chế: Từ phân tích trên, có thể xác định hai hạn chế mà đề tài này hướng đến lấp đầy. Thứ nhất, sự thiếu vắng một kiến trúc tích hợp sâu đồ thị tri thức nhân sự vào luồng sinh văn bản của LLM, kết hợp với hệ thống đa tác tử (Multi-Agent) phân tách các luồng nghiệp vụ tìm kiếm ứng viên diện rộng và phỏng vấn cá nhân hóa trong khi vẫn đảm bảo kiểm soát truy cập dữ liệu nhạy cảm ở tầng cấu trúc đồ thị. Thứ hai, chưa có nghiên cứu nào áp dụng kiến trúc GraphRAG vào bài toán phỏng vấn tự động bằng Digital Twin với cơ chế bảo mật privacy-by-design cho dữ liệu CV tiếng Việt trong lĩnh vực Công nghệ thông tin.

3. Mục tiêu đề tài

Mục tiêu tổng quát của đề tài là nghiên cứu, thiết kế và cài đặt thử nghiệm mô hình ORCHGRAPH-RAG nhằm tối ưu hóa quy trình truy xuất dữ liệu tuyển dụng và tạo ra các đại diện số (Digital Twin) hỗ trợ phỏng vấn.

Các mục tiêu cụ thể bao gồm:

- **Xây dựng kiến trúc lưu trữ Dual-DB (Đồ thị và Vector):** Kết hợp khả năng biểu diễn mối quan hệ của Graph DB (Neo4j) và khả năng tìm kiếm ngữ nghĩa của Vector DB để quản lý hồ sơ nhân sự theo kiến trúc phân tách bảo mật (Public/Private data).
- **Phát triển Master Agent điều phối minh bạch:** Phát triển Master Agent điều phối minh bạch: Xây dựng tác tử trung tâm có khả năng chuyển ngữ truy vấn tự nhiên, định tuyến và khai thác đồ thị tri thức để tìm kiếm ứng viên/công việc một cách có cơ sở, giảm thiểu ảo giác.
- **Tạo lập Digital Twin đại diện ứng viên:** Phát triển các tác tử cá nhân hóa mang đặc trưng tri thức của từng ứng viên (dựa trên dữ liệu CV), cho phép

thực hiện các cuộc phỏng vấn sơ bộ tự động, tương tác và truy xuất thông tin hỏi đáp theo ngữ cảnh thực tế.

4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu:

- Dữ liệu văn bản phi cấu trúc trong miền nhân sự (Hồ sơ ứng viên (CV), Mô tả công việc (JD)).
- Mạng lưới quan hệ thực thể: Tổ chức (Organization), Nhân sự (Personnel), Kỹ năng (Skills), Học vấn (Education).
- Các phương pháp trích xuất thông tin (Information Extraction), kiến trúc GraphRAG và hệ thống Đa tác tử (Multi-Agent System).

Phạm vi nghiên cứu: Đề tài giới hạn thử nghiệm trên tập dữ liệu tổng hợp (synthetic dataset) thuộc lĩnh vực Công nghệ thông tin (IT/Software Engineering) để đảm bảo độ phức tạp về mặt công nghệ và kỹ năng. Mô hình tập trung vào việc đối chiếu tri thức, hỗ trợ sàng lọc và phỏng vấn vòng loại, không thay thế quyết định tuyển dụng cuối cùng của con người.

5. Phương pháp nghiên cứu

Để đạt được các mục tiêu đề ra, đề tài sử dụng kết hợp các phương pháp nghiên cứu sau:

- Phương pháp nghiên cứu lý thuyết: Khảo sát các tài liệu học thuật, nghiên cứu cấu trúc Ontology cho dữ liệu nhân sự, cơ chế hoạt động của GraphRAG và các rủi ro bảo mật trong quá trình tiêm dữ liệu (Data Ingestion) vào LLM.
- Phương pháp mô hình hóa và thực nghiệm: Thiết kế pipeline trích xuất dữ liệu tự động (One-Pass Classification có rào chắn luật cứng). Cài đặt môi trường thử nghiệm trên cơ sở dữ liệu Neo4j [14] và tích hợp các LLM (OpenAI/Anthropic) qua framework xây dựng tác tử.
- Phương pháp đánh giá và thống kê: Sử dụng các framework đánh giá tiêu chuẩn như RAGAS [6] để đo lường chất lượng truy xuất (Tính trung thực (Faithfulness), Độ liên quan (Answer Relevance)). Tiến hành kiểm thử bảo mật (Privacy Evaluation) qua các kịch bản tấn công (Red-teaming) để định lượng độ an toàn của cơ chế phân tách dữ liệu.

6. Bố cục quyển báo cáo

Quyển báo cáo gồm có 3 phần chính là: Phần giới thiệu, Phần nội dung và Phần kết luận, cuối quyển báo cáo là phần Tài liệu tham khảo chứa những quyển sách, bài báo được trích dẫn trong báo cáo. Cụ thể phần bố cục được chia như sau:

- **Phần giới thiệu:** Trình bày các vấn đề hiện tại, các nghiên cứu liên quan, mục tiêu của đề tài, đối tượng và phạm vi nghiên cứu, cùng với phương pháp nghiên cứu được áp dụng.
- **Phần nội dung:**

- + **Chương 1: Mô tả bài toán** Giới thiệu chi tiết về bài toán, bao gồm các kiến thức và framework cụ được sử dụng trong quá trình nghiên cứu đề tài.
- + **Chương 2: Thiết kế và cài đặt giải pháp** Mô tả sơ lược về pipeline của hệ thống và kiến trúc của mô hình. Đồng thời mô tả phương pháp thu thập và tiền xử lý dữ liệu.
- + **Chương 3: Kiểm thử và đánh giá** Trình bày giao diện sản phẩm và thực hiện đánh giá kết quả thực nghiệm của mô hình đề ra.
- **Phần kết luận:** Tóm tắt kết quả đạt được, nêu lên những hạn chế của đề tài và đề xuất hướng phát triển trong tương lai.
- **Tài liệu tham khảo:** Liệt kê các nguồn tài liệu được sử dụng trong quá trình nghiên cứu và thực hiện đề tài.


II. PHẦN NỘI DUNG

Chương 1. Mô tả bài toán

1. Mô tả chi tiết bài toán

1.1. Bài toán tuyển dụng thông minh và truy xuất tri thức

Trong phạm vi hệ thống ORCHGRAPH-RAG, bài toán quản trị và khai thác tri thức nhân sự được mô hình hóa thành hai luồng bài toán con có tính nội kết cao, cùng chia sẻ một cơ sở tri thức thống nhất nhưng phục vụ những mục tiêu hoàn toàn khác biệt.



Hình 5. Kiến trúc bài toán ORCHGRAPH-RAG

- *Bài toán đối sánh ứng viên:* Hệ thống tiếp nhận một yêu cầu tuyển dụng (Job Description, viết tắt là JD) phi cấu trúc viết bằng ngôn ngữ tự nhiên và trả về danh sách ứng viên xếp hạng theo mức độ phù hợp. Về bản chất, đây là bài toán tìm kiếm đồ thị con (subgraph matching) kết hợp đo lường độ tương đồng ngữ nghĩa: hệ thống cần bóc tách các thực thể yêu cầu (kỹ năng, thâm niên, lĩnh vực) từ JD rồi tìm kiếm trong cơ sở dữ liệu những ứng viên có cấu trúc tri thức tiệm cận nhất với yêu cầu đó. Khác với hệ thống ATS truyền thống chỉ đếm từ khóa, hệ thống cần suy luận được các quan hệ ngầm định: ứng viên có kinh nghiệm "Spring Boot" hoàn toàn đáp ứng yêu cầu "Java Backend Framework" dù hai chuỗi ký tự không trùng khớp.
- *Bài toán phỏng vấn qua bản sao số:* Một tác tử AI đóng vai đại diện của ứng viên, nhận câu hỏi từ nhà tuyển dụng và sinh ra câu trả lời dựa hoàn toàn trên

tri thức trong hồ sơ của người đó. Đây là bài toán hỏi đáp có truy xuất tăng cường (QA-RAG) với hai ràng buộc cốt lõi. Thứ nhất, ràng buộc trung thực: tác tử chỉ được phép sinh văn bản dựa trên tập ngữ cảnh (context window) xây dựng từ đồ thị cá nhân của ứng viên, không được suy diễn thêm từ kiến thức tham số của mô hình. Thứ hai, ràng buộc bảo mật (privacy): hệ thống phải kiểm soát phân quyền truy cập theo cấu trúc quan hệ (Relationship-based Access Control, viết tắt là ReBAC) [8], đảm bảo các thông tin nhạy cảm như mức lương kỳ vọng hay bí mật kỹ thuật dự án không bị rò rỉ trong quá trình tổng hợp của mô hình ngôn ngữ lớn (LLM).

Mục tiêu cốt lõi của đề tài là xây dựng một kiến trúc tích hợp giải quyết đồng thời cả hai luồng bài toán trên thông qua sự kết hợp giữa đồ thị tri thức nhân sự và cơ chế truy xuất tăng cường dựa trên đồ thị, đảm bảo mọi kết quả đầu ra đều có khả năng truy vết về nguồn dữ liệu gốc.

1.2. Ứng dụng Web

Để minh chứng tính thực tiễn của mô hình nghiên cứu và hỗ trợ người dùng trong việc tương tác với hệ thống, đề tài triển khai ứng dụng web ORCHGRAPH-RAG phục vụ hai nhóm người dùng với luồng tương tác khác nhau.

Hệ thống được thiết kế không chỉ để đưa ra kết quả đề xuất mà còn hướng tới tính minh bạch (explainability), giúp người dùng hiểu được cơ sở của từng quyết định thông qua trực quan hóa đồ thị tri thức. Cụ thể, ứng dụng hỗ trợ linh hoạt ba kịch bản sử dụng chính:

- *Chức năng tìm kiếm ứng viên:* Người dùng thuộc nhóm tổ chức nhập yêu cầu tuyển dụng bằng ngôn ngữ tự nhiên. Hệ thống thực hiện tìm kiếm kết hợp tín hiệu từ đồ thị kỹ năng và tín hiệu ngữ nghĩa từ vector embedding, trả về danh sách ứng viên kèm điểm số và phần giải thích có truy vết về cấu trúc đồ thị. Nhờ cơ chế này, nhà tuyển dụng không chỉ biết ai phù hợp mà còn biết tại sao người đó phù hợp.
- *Chức năng phỏng vấn bản sao số:* Tổ chức có thể khởi tạo một phiên hội thoại với bản sao số của ứng viên thông qua giao diện chat streaming thời gian thực. Tác tử AI đóng vai ứng viên và chỉ trả lời trong phạm vi thông tin có trong hồ sơ. Ở chế độ công khai (khi chưa có kết nối được chấp thuận), tác tử chỉ truy cập dữ liệu công khai; sau khi ứng viên cấp quyền, toàn bộ vault dữ liệu riêng tư mới được mở khóa.
- *Chức năng quản lý lịch hẹn:* Sau khi đánh giá sơ bộ qua bản sao số, nhà tuyển dụng có thể đặt lịch phỏng vấn thực trực tiếp trong ứng dụng. Hệ thống hỗ trợ đồng bộ lịch rảnh của ứng viên, gửi xác nhận qua email và đẩy thông báo thời gian thực qua Supabase Realtime [21].

2. Vấn đề giải pháp liên quan đến bài toán

2.1. Mô hình ngôn ngữ lớn và giao tiếp streaming

Mô hình ngôn ngữ lớn (Large Language Model, viết tắt là LLM) là các mạng nơ-ron Transformer [22] được huấn luyện trên lượng dữ liệu văn bản khổng lồ theo

mục tiêu dự đoán token tiếp theo trong chuỗi. Với số lượng tham số từ hàng tỷ đến hàng nghìn tỷ, LLM có khả năng mã hóa kiến thức ngôn ngữ và thế giới ở mức độ sâu, cho phép thực hiện nhiều tác vụ khác nhau chỉ thông qua mô tả tự nhiên trong prompt mà không cần tinh chỉnh lại mô hình (zero-shot và few-shot prompting) [2].


Tính chất sinh tạo xác suất (probabilistic generation) của LLM, trong đó mỗi token được chọn theo phân phối xác suất trên toàn bộ từ vựng, là nguồn gốc của hiện tượng ảo giác (hallucination), tức là mô hình có thể sinh ra những phát biểu nghe có vẻ hợp lý nhưng thực tế không chính xác [10]. Tham số nhiệt độ (temperature) kiểm soát mức độ "sáng tạo" của quá trình sinh: nhiệt độ bằng 0 buộc mô hình luôn chọn token có xác suất cao nhất, tạo ra đầu ra rất định và ít ảo giác nhất; nhiệt độ cao làm phẳng phân phối xác suất, tăng tính đa dạng nhưng cũng tăng nguy cơ ảo giác. Trong các ứng dụng đòi hỏi tương tác thời gian thực, giao tiếp streaming là kỹ

thuật quan trọng giúp cải thiện trải nghiệm người dùng. Thay vì chờ toàn bộ phản hồi được sinh xong rồi mới trả về (có thể mất nhiều giây với các câu trả lời dài), máy chủ truyền từng token ngay khi được sinh ra thông qua cơ chế Server-Sent Events (SSE) hoặc WebSocket. Phía giao diện nhận và hiển thị lũy tiến, tạo cảm giác phản hồi tức thì tương tự như đang trò chuyện với người thật. Về mặt kiến trúc, điều này đòi hỏi máy chủ phải hỗ trợ xử lý bất đồng bộ (asynchronous I/O) để duy trì nhiều kết nối streaming song song mà không chặn luồng thực thi.

2.2. Mô hình nhúng đa ngôn ngữ

Mô hình nhúng (Embedding Model) là các mô hình học sâu có nhiệm vụ ánh xạ văn bản, từ, câu, hoặc đoạn văn thành các vector số thực trong không gian nhiều chiều, sao cho các văn bản có ngữ nghĩa tương đồng sẽ nằm gần nhau về mặt hình học. Khác với các phương pháp truyền thống như Bag-of-Words hay TF-IDF chỉ dựa trên tần suất từ, các mô hình nhúng hiện đại dựa trên kiến trúc Transformer nắm bắt được ngữ nghĩa trong ngữ cảnh, tức là cùng một từ có thể được nhúng thành các vector khác nhau tùy theo văn cảnh xuất hiện.

Sentence-BERT (SBERT) do Reimers và Gurevych [20] giới thiệu là một sửa đổi quan trọng của kiến trúc BERT gốc, được tối ưu hóa đặc biệt cho tác vụ tạo vector biểu diễn ở cấp độ câu. SBERT sử dụng kiến trúc Siamese, hai nhánh encoder dùng chung trọng số kết hợp với cơ chế Mean Pooling để nén thông tin toàn bộ câu thành một vector cố định. Quá trình huấn luyện tối ưu hóa hàm mất mát tương đồng (như Cosine Similarity Loss hoặc Triplet Loss) để kéo vector của các câu có ngữ nghĩa giống nhau lại gần và đẩy các câu khác nghĩa ra xa, tạo ra không gian nhúng có tính phân tách ngữ nghĩa cao.



Đối với dữ liệu văn bản đa ngôn ngữ, đặc biệt là các tài liệu tiếng Việt có xen lẫn thuật ngữ kỹ thuật tiếng Anh, yêu cầu đặt ra với mô hình nhúng không chỉ là hiểu ngữ nghĩa đơn ngữ mà còn phải có khả năng căn chỉnh đa ngôn ngữ (cross-lingual alignment), tức là ánh xạ các cụm từ cùng nghĩa trong hai ngôn ngữ khác nhau về cùng một vùng lân cận trong không gian vector. Các mô hình như multilingual-E5 [23], GTE-multilingual [24] và BGE-M3 [3] được huấn luyện trên dữ liệu song ngữ quy mô lớn theo mục tiêu này, và thường vượt trội so với các mô hình đơn ngữ khi xử lý các văn bản kỹ thuật có từ vựng pha trộn.


2.3. Cơ sở dữ liệu vector và pgvector

Cơ sở dữ liệu vector (Vector Database) là hệ thống được thiết kế để lưu trữ và tìm kiếm hiệu quả các vector số thực có số chiều cao, thường thông qua các thuật toán tìm kiếm lân cận gần đúng (Approximate Nearest Neighbor, viết tắt là ANN). Thay vì so sánh chính xác từng cặp vector có độ phức tạp cao, ANN đánh đổi một phần độ chính xác để giảm đáng kể chi phí tính toán thông qua các cấu trúc dữ liệu


chỉ mục như HNSW (Hierarchical Navigable Small World) [13] hay IVF (Inverted File Index), cho phép tìm kiếm trong hàng triệu vector chỉ trong vài mili giây.




Hình 8. Quy trình hoạt động cơ bản của một cơ sở dữ liệu vector



Hình 9. Minh họa cấu trúc đồ thị đa tầng (trái) và cơ chế chọn lân cận heuristic (phải) của thuật toán HNSW dùng trong tìm kiếm ANN



Hình 10. Sơ đồ đường đi cho quá trình lưu trữ trong cơ sở dữ liệu vector




Hình 11. Sơ đồ đường đi cho quá trình truy vấn trong cơ sở dữ liệu vector

Giai đoạn truy vấn trong cơ sở dữ liệu vector bao gồm việc nhập dữ liệu cần so khớp, chẳng hạn như một bức ảnh sẽ được so sánh với các ảnh khác. Đồng thời, bộ lọc metadata có thể được áp dụng để loại bỏ các kết quả có đặc điểm không mong muốn, ví dụ như loại bỏ hình ảnh vấy có màu cụ thể. Bộ lọc này có thể được thực hiện trước hoặc sau khi tìm kiếm tương đồng. Dữ liệu được xử lý bằng mô hình đã sử dụng để lưu trữ, và hệ thống sẽ trả về các kết quả gần giống nhất dựa trên độ tương đồng.

Thước đo phổ biến để đánh giá độ tương đồng giữa hai vector trong không gian nhúng là độ tương đồng cosine:

$$S_{\text{vector}}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \cdot \|\mathbf{v}\|}$$

Giá trị này nằm trong khoảng $[-1, 1]$, trong đó giá trị tiệm cận 1 biểu thị hai vector gần như cùng hướng, tức hai đoạn văn bản có ngữ nghĩa tương đồng cao.




Hình 12. Minh họa việc sử dụng độ tương đồng cosine để đo lường khoảng cách ngữ nghĩa giữa các câu trong không gian vector

pgvector là phần mở rộng mã nguồn mở của PostgreSQL, cung cấp kiểu dữ liệu vector và các toán tử tìm kiếm ANN trực tiếp trong cơ sở dữ liệu quan hệ. So với các hệ thống vector độc lập (như Pinecone hay Weaviate), pgvector có lợi thế tận dụng hệ sinh thái PostgreSQL hiện có: giao dịch ACID, Row Level Security (RLS), và khả năng kết hợp truy vấn vector với điều kiện lọc quan hệ trong cùng một câu lệnh SQL.

2.4. Đồ thị tri thức và cơ sở dữ liệu đồ thị Neo4j


Đồ thị tri thức (Knowledge Graph) là một cấu trúc dữ liệu biểu diễn thế giới thực dưới dạng mạng lưới các thực thể và mối quan hệ giữa chúng. Về mặt hình thức, một đồ thị tri thức $G = (V, E)$ được đặc trưng bởi tập đỉnh V đại diện cho các thực thể (như con người, tổ chức, kỹ năng, dự án) và tập cạnh $E \subseteq V \times R \times V$, trong đó R là tập nhãn quan hệ có ngữ nghĩa. Khác với cơ sở dữ liệu quan hệ (RDBMS) phải thực hiện phép kết nối (JOIN) tốn kém khi duyệt nhiều bảng, đồ thị tri thức lưu trữ trực tiếp các liên kết đến đỉnh lân cận, cho phép duyệt cạnh hiệu quả khi thực hiện truy vấn nhiều bước (multi-hop).



Hình 13. Cấu trúc đồ thị tri thức

Mô hình Property Graph là một trong những chuẩn biểu diễn phổ biến nhất của đồ thị tri thức trong thực tế, trong đó cả đỉnh lẫn cạnh đều có thể mang các thuộc tính bổ sung dưới dạng cặp khóa-giá trị. Điều này cho phép mã hóa thông tin ngữ nghĩa phong phú trực tiếp trên cấu trúc đồ thị mà không cần các bảng phụ trợ hay bảng ánh xạ trung gian.

Neo4j là hệ quản trị cơ sở dữ liệu đồ thị (Graph DBMS) theo mô hình Property Graph. Neo4j sử dụng ngôn ngữ truy vấn Cypher, được thiết kế để biểu diễn các mẫu quan hệ (relationship patterns) một cách trực quan [14]. cú pháp của Cypher cho phép mô tả các truy vấn multi-hop phức tạp trong một biểu thức ngắn gọn và dễ đọc, trong khi SQL thường cần nhiều tầng lồng nhau hoặc đệ quy. Ngoài khả năng truy vấn đồ thị, các phiên bản hiện đại của Neo4j còn hỗ trợ lưu trữ vector embedding trực tiếp như một thuộc tính của đỉnh, kết hợp với chỉ mục vector để thực hiện ANN Search ngay trong đồ thị.



Hình 14. Minh họa mô hình đồ thị thuộc tính trong Neo4j

2.5. Nền tảng lưu trữ và đồng bộ dữ liệu Supabase

Supabase là một nền tảng backend-as-a-service xây dựng trên PostgreSQL, cung cấp đồng thời cơ sở dữ liệu quan hệ, cơ chế xác thực người dùng, API tự sinh và kênh đồng bộ thời gian thực. Trong bối cảnh các ứng dụng AI cần vừa lưu trữ dữ liệu cấu trúc vừa hỗ trợ truy vấn ngữ nghĩa, Supabase cho phép kết hợp linh hoạt giữa bảng quan hệ truyền thống, Row Level Security (RLS) và các tiện ích mở rộng như pgvector để lưu trữ vector embedding ngay trong cùng một hệ quản trị [21].

Một ưu điểm quan trọng của Supabase là cơ chế Realtime, cho phép hệ thống phát sinh và lắng nghe các sự kiện thay đổi dữ liệu gần như tức thì mà không cần tự triển khai tầng WebSocket riêng. Điều này đặc biệt hữu ích cho các tác vụ như thông báo, cập nhật trạng thái hoặc đồng bộ lịch hẹn, nơi giao diện cần phản ánh thay đổi dữ liệu ngay sau khi có thao tác từ phía máy chủ. Bên cạnh đó, việc giữ dữ liệu riêng tư trong PostgreSQL và áp dụng RLS ở mức dòng giúp kiểm soát truy cập chi tiết hơn so với việc chỉ dựa vào tầng ứng dụng.

2.6. Tìm kiếm kết hợp (Hybrid Search)

Tìm kiếm kết hợp là kỹ thuật kết hợp nhiều tín hiệu truy xuất có bản chất khác nhau để tận dụng ưu điểm của từng tín hiệu trong khi bù đắp điểm yếu của nhau. Trong bối cảnh tìm kiếm văn bản, hai tín hiệu phổ biến nhất thường được kết hợp là tín hiệu thưa (sparse retrieval) và tín hiệu dày (dense retrieval). Đây cũng là nền tảng thường gặp trong các pipeline RAG hiện đại, nơi tầng truy xuất cần cân bằng giữa độ khớp từ khóa và độ tương đồng ngữ nghĩa trước khi sinh câu trả lời [11].

Tín hiệu thưa dựa trên sự trùng khớp từ khóa chính xác, tiêu biểu là BM25 hoặc Jaccard. Tín hiệu này cho độ chính xác cao khi truy vấn chứa các từ khóa tường minh, nhưng dễ bỏ sót các trường hợp tương đương ngữ nghĩa. Ngược lại, tín hiệu dày dựa trên embedding vector bắt được quan hệ ngữ nghĩa ngầm định và từ đồng nghĩa, nhưng có thể kém chính xác khi truy vấn cần khớp với thực thể rất cụ thể.

Điểm tổng hợp cuối cùng trong Hybrid Search thường được tính theo hàm kết hợp tuyến tính có trọng số:

$$S_{\text{final}}(c) = \alpha \cdot S_{\text{sparse}}(c, q) + \beta \cdot S_{\text{dense}}(c, q), \quad \alpha + \beta = 1$$

Trong đó α và β là các siêu tham số điều chỉnh mức độ ưu tiên tương đối giữa hai tín hiệu.

Một kỹ thuật phổ biến để chuẩn hóa và kết hợp các tín hiệu từ nhiều nguồn có thang điểm khác nhau là Reciprocal Rank Fusion (RRF), trong đó mỗi tài liệu được gán điểm dựa trên thứ hạng trong từng danh sách kết quả thay vì điểm tuyệt đối.

2.7. Mô hình số cá nhân (AI Digital Twin)

Bản sao số (Digital Twin) là khái niệm chỉ một đại diện số phản chiếu trạng thái và đặc trưng của một thực thể thực trong thế giới vật lý có thể là con người, thiết bị, quy trình hoặc hệ thống được đồng bộ hóa liên tục thông qua dữ liệu từ thực thể gốc. Khái niệm này ban đầu xuất phát từ lĩnh vực kỹ thuật công nghiệp, sau đó được mở rộng sang các lĩnh vực y tế, giáo dục và quản trị nhân sự [12].

Trong bối cảnh AI hiện đại, AI Digital Twin của một cá nhân là một tác tử LLM được neo (grounded) chặt chẽ vào một tập ngữ cảnh được xây dựng từ dữ liệu thực của người đó, thay vì dựa vào kiến thức tham số chung của mô hình. Điểm then chốt về mặt kỹ thuật là tác tử này phải tuân thủ hai ràng buộc cốt lõi. Ràng buộc thứ nhất là tính trung thực: mọi câu trả lời sinh ra phải có thể truy vết trực tiếp về nguồn dữ liệu gốc trong tập ngữ cảnh, tác tử không được suy diễn hay bổ sung thông tin từ kiến thức tham số của mô hình. Ràng buộc thứ hai là tính riêng tư (Privacy): tập ngữ cảnh cấp cho tác tử phải được kiểm soát chặt chẽ theo quyền truy cập của người dùng hiện tại, đảm bảo thông tin nhạy cảm không bị lộ ngay cả khi hệ thống bị tấn công bằng các kỹ thuật khai thác prompt (prompt injection, jailbreak) [12].

Để đạt được tính trung thực, một kỹ thuật phổ biến là kết hợp cấu hình tham số nhiệt độ thấp ($\text{temperature} = 0$, buộc mô hình chọn token có xác suất cao nhất) với các lệnh ức chế ngữ nghĩa (Inhibitor Commands) tường minh trong system prompt, yêu cầu mô hình chỉ phản hồi dựa trên ngữ cảnh được cung cấp và từ chối trả lời khi thông tin không có trong đó.

2.8. Framework backend FastAPI và frontend Next.js

FastAPI là framework Python hiện đại xây dựng trên chuẩn ASGI (Asynchronous Server Gateway Interface), cho phép xử lý nhiều yêu cầu đồng thời theo mô hình bất đồng bộ (async/await) mà không chặn luồng thực thi [19]. Đặc tính này đặc biệt quan trọng đối với các ứng dụng AI, nơi một yêu cầu có thể phải chờ phản hồi từ LLM trong vài giây trong khi hệ thống vẫn cần phục vụ các yêu cầu khác song song. FastAPI cũng tự động sinh tài liệu API theo chuẩn OpenAPI (Swagger UI) từ các khai báo kiểu dữ liệu Python và tích hợp tự nhiên với hệ sinh thái thư viện học máy như PyTorch, Transformers hay LangChain mà không cần tầng giao tiếp trung gian.

Next.js là framework React cho phép xây dựng ứng dụng web theo kiến trúc kết hợp giữa Server-Side Rendering (SSR) và Client-Side Rendering (CSR). Với App Router trong các phiên bản gần đây, Next.js phân biệt rõ ràng giữa Server Components được render ở phía máy chủ, thân thiện với SEO và hiệu năng tải trang ban đầu và Client Components được hydrate ở phía trình duyệt để xử lý tương tác người dùng động như streaming chat hay trực quan hóa đồ thị. Cơ chế middleware của Next.js cho phép thực hiện xác thực và kiểm tra phiên làm việc trước khi request được chuyển đến bất kỳ trang hay API nào, giúp bảo vệ toàn bộ nhóm route cần xác thực chỉ với một điểm kiểm soát duy nhất.

2.9. Thang đo đánh giá hệ thống RAG (RAGAS)

Đánh giá chất lượng hệ thống RAG đòi hỏi hai nhóm chỉ số riêng biệt vì truy xuất và sinh văn bản là hai bài toán có tiêu chí thành công khác nhau.

Về chất lượng truy xuất, ba chỉ số phổ biến là $\text{MRR}@k$ (Mean Reciprocal Rank), $\text{Recall}@k$ và $\text{NDCG}@k$ (Normalized Discounted Cumulative Gain). $\text{MRR}@k$ đo chất lượng xếp hạng thông qua nghịch đảo thứ hạng của tài liệu đúng đầu tiên, được tính trung bình trên tập truy vấn:

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i}$$

$\text{Recall}@k$ đo tỉ lệ tài liệu đúng xuất hiện trong top- k kết quả trả về. $\text{NDCG}@k$ tính thêm yếu tố vị trí của tài liệu đúng, trong đó tài liệu đúng ở vị trí cao được thưởng điểm lớn hơn:


$$\text{NDCG}@k = \frac{\text{DCG}@k}{\text{IDCG}@k}, \quad \text{DCG}@k = \sum_{i=1}^k \frac{\text{rel}_i}{\log_2(i+1)}$$

Về chất lượng sinh văn bản, framework RAGAS do Es và cộng sự [6] giới thiệu sử dụng LLM đóng vai trò người đánh giá (LLM-as-judge) để tự động hóa quá trình kiểm định mà không cần tập ground truth tuyệt đối. Bốn chỉ số trọng tâm bao gồm: Faithfulness, Answer Relevancy, Context Precision và Context Recall.

CHƯƠNG 2. THIẾT KẾ VÀ CÀI ĐẶT GIẢI PHÁP

1. Thiết kế hệ thống

Quy trình tổng quát của hệ thống ORCHGRAPH-RAG được minh hoạ tại Hình 15, bao gồm bốn giai đoạn xử lý tuần tự liên kết với nhau: (1) Nhập liệu và tiền xử lý, (2) Xây dựng kho tri thức, (3) Định tuyến và truy vấn, và (4) Tổng hợp kết quả. Kiến trúc được thiết kế theo hai luồng nghiệp vụ độc lập: tìm kiếm ứng viên và phỏng vấn bản sao số nhưng dùng chung một nền tảng tri thức.



Hình 15. Kiến trúc tổng quát của hệ thống

Đặc tả dữ liệu đầu vào (INPUT): Hệ thống tiếp nhận hai loại dữ liệu chính. Hồ sơ ứng viên được cung cấp dưới dạng tệp có định dạng .pdf, .docx, .txt. hoặc .md. Truy vấn người dùng được nhập dưới dạng văn bản tự nhiên, bao gồm mô tả công việc (JD) hoặc câu hỏi phỏng vấn. Hệ thống được thiết kế với cơ chế chấp nhận thiếu hụt, cho phép hoạt động ngay cả khi người dùng không cung cấp đầy đủ thông tin.

Đặc tả dữ liệu đầu ra (OUTPUT): Tùy theo luồng nghiệp vụ, hệ thống trả về một trong hai loại kết quả: danh sách ứng viên xếp hạng kèm chuỗi lý giải có thể truy vết, hoặc câu trả lời phỏng vấn theo thời gian thực có căn cứ từ đồ thị tri thức cá nhân của ứng viên.

Chi tiết bốn giai đoạn xử lý được trình bày như sau:

- *Giai đoạn 1:* Nhập liệu và tiền xử lý (Ingestion Agent) là giai đoạn đầu tiên trong quy trình, nơi Hồ sơ ứng viên thô được xử lý tuần tự qua năm bước, bao gồm phân tích định dạng, làm sạch văn bản, chia đoạn, trích xuất thực thể theo lược đồ RecruitmentNode, và vector hoá đa trường.
- *Giai đoạn 2:* Xây dựng kho tri thức (Dual-DB) là giai đoạn xây dựng cơ sở dữ liệu tri thức, nơi Dữ liệu sau khi xử lý được ghi song song lên Neo4j (dữ liệu công khai dạng đồ thị có hướng) và Supabase/pgvector (dữ liệu riêng tư).

và vector nhúng). Hai hệ thống tạo thành luồng truy xuất khép kín được mô tả chi tiết ở *mục 1.2*.

- *Giai đoạn 3: Định tuyến và truy vấn (Orchestrator Agent)* là giai đoạn phân loại truy vấn và chuyển hướng sang các tác tử phù hợp. Khi nhận truy vấn đầu vào, bộ định tuyến phân loại ý định và chuyển sang Tác tử tìm kiếm hoặc Tác tử bản sao số. Tác tử tìm kiếm kết hợp điểm đồ thị và điểm vector nhúng theo công thức:


$$S_{final}(c) = \alpha \cdot S_{graph}(c, q) + \beta \cdot S_{vector}(c, q), \quad \alpha = 0,2, \beta = 0,8$$

- *Giai đoạn 4: Tổng hợp kết quả (Output)* là giai đoạn cuối cùng trong quy trình, nơi kết quả được trả về qua giao diện web. Luồng tìm kiếm hiển thị danh sách ứng viên xếp hạng kèm lý giải có truy vết về từng nút và cạnh cụ thể trên đồ thị. Luồng phỏng vấn truyền từng đoạn phản hồi theo thời gian thực qua kết nối WebSocket.


1.1. Mô hình lưu trữ song song

Thách thức thiết kế trung tâm của hệ thống là đồng thời đáp ứng ba yêu cầu có tính mâu thuẫn nhau: tìm kiếm ngữ nghĩa linh hoạt dựa trên vector nhúng, suy luận quan hệ có cấu trúc dựa trên duyệt đồ thị, và kiểm soát bảo mật dữ liệu cá nhân ở mức chi tiết theo từng trường.

Giải pháp được lựa chọn là kiến trúc lưu trữ song song theo nguyên lý Polyglot Persistence: mỗi loại dữ liệu được lưu trong hệ thống phù hợp nhất với đặc tính của nó, thay vì ép tất cả vào một kho lưu trữ thống nhất. Kiến trúc tổng thể được minh họa tại Hình 16; nguyên lý phân tách công khai/riêng tư được thể hiện tại Hình 17.



Hình 16. Kiến trúc mô hình lưu trữ song song



Hình 17. Sơ đồ nguyên lý Polyglot Persistence

Hai lớp lưu trữ đảm nhận các vai trò kỹ thuật riêng biệt:

- **Lớp lưu trữ cấu trúc công khai Neo4j:** Neo4j quản lý toàn bộ dữ liệu công khai dưới dạng đồ thị có hướng. Các thực thể Personnel, Organization, Skill, Project, Education được biểu diễn là các nút mang nhãn và thuộc tính; các mối quan hệ HAS_SKILL, WORKED_AT, PARTICIPATED_IN, CONNECTED_TO là các cạnh. Neo4j còn lưu vector nhúng cấp thực thể của từng ứng viên để phục vụ bước lọc thô ban đầu trong luồng tìm kiếm.
- **Lớp lưu trữ ngữ nghĩa và riêng tư Supabase/pgvector:** là lớp quản lý hai loại dữ liệu. Thứ nhất là các đoạn văn bản (chunks) đã vector hoá ở mức chi tiết phục vụ tái xếp hạng ngữ nghĩa sau bước lọc thô từ Neo4j. Thứ hai là kho dữ liệu riêng tư chứa các trường nhạy cảm như lương kỳ vọng, thông tin liên hệ và bí mật kỹ thuật dự án.


Hai lớp này tạo thành một luồng truy xuất hai tầng: hệ thống trước tiên truy hồi sơ bộ thông qua chỉ mục vector cấp thực thể trên Neo4j để lọc nhanh danh sách ứng viên tiềm năng; tiếp theo, hệ thống fan-out sang kho đoạn văn bản trên Supabase để lấy tín hiệu tương đồng chi tiết, sau đó hợp nhất và tái xếp hạng danh sách. Chiến lược này vừa đảm bảo tốc độ lọc thô, vừa giữ được chất lượng đối sánh ngữ nghĩa ở cấp độ hạt mịn.

Đặc biệt, hệ thống duy trì ranh giới dữ liệu nghiêm ngặt theo ngữ cảnh nghiệp vụ: trong tác vụ Tìm kiếm, hệ thống chỉ truy cập các chunk công khai; trong tác vụ Phỏng vấn Bản sao số, dữ liệu riêng tư chỉ được đưa vào ngữ cảnh khi cạnh uỷ quyền giữa tổ chức và ứng viên được xác thực hợp lệ trên đồ thị.


1.2. Pipeline nhập liệu CV tiếng Việt

Pipeline nhập liệu là cầu nối giữa CV phi cấu trúc và kiến trúc lưu trữ song song. Thiết kế pipeline ưu tiên ba mục tiêu: giảm thất thoát thông tin qua các bước biến đổi, phân tách dữ liệu công khai và riêng tư ngay từ bước trích xuất, và duy trì khả năng xử lý đa định dạng nhờ cơ chế dự phòng nhiều tầng.

Pipeline gồm sáu bước nối tiếp, được phân chia thành hai nhóm chức năng và minh hoạ tại Hình 18 and 19.



Hình 18. Luồng tiền xử lý dữ liệu



Hình 19. Luồng trích xuất và ghi dữ liệu

- Bước 1: Phân tích định dạng (Parse) là bước mà CV thô được chuyển thành luồng văn bản tuyến tính. Hệ thống sử dụng chuỗi bộ phân tích dự phòng ba tầng; tệp .json bỏ qua toàn bộ chuỗi này vì đã có cấu trúc sẵn.
- Bước 2: Làm sạch văn bản (Clean) là bước loại bỏ nhiễu khỏi văn bản mà không làm mất ký tự tiếng Việt. Bộ làm sạch dùng biểu thức chính quy để đạt được điều này.
- Bước 3: Chia đoạn (Chunk) là bước chia văn bản sạch thành các đoạn với kích thước tối đa 7.000 ký tự và vùng chồng lấp 400 ký tự giữa hai đoạn liền kề.
- Bước 4: Trích xuất thực thể (Extract) là bước đưa mỗi đoạn vào mô hình ngôn ngữ để trích xuất thực thể theo lược đồ RecruitmentNode, đầu ra được kiểm tra thành JSON hợp lệ.
- Bước 5: Vector hoá (Vectorize) là bước vector hoá RecruitmentNode theo chiến lược đa trường, cho phép tìm kiếm ngữ nghĩa có trọng số theo từng khía cạnh của hồ sơ.
- Bước 6: Ghi song song (Dual-write) là bước ghi dữ liệu tuần tự lên Neo4j trước, sau đó lên Supabase. Neo4j lưu lớp cấu trúc đồ thị và vector cấp thực thể; Supabase lưu hồ sơ, chunks và embeddings cấp đoạn.

1.3. Lược đồ tri thức RecruitmentNode

Lược đồ tri thức RecruitmentNode được thiết kế để chuẩn hóa các trường trích xuất từ CV thành một cấu trúc thống nhất, gồm các trường công khai phục vụ tìm

kiểm và các trường riêng tư phục vụ phỏng vấn bản sao số. Cách thiết kế này cho phép hệ thống tách bạch rõ ngữ cảnh tìm kiếm và ngữ cảnh hội thoại.

Bảng 2. Đặc tả lược đồ dữ liệu *RecruitmentNode* và ranh giới bảo mật

Phân vùng	Trường dữ liệu (Field)	Kiểu dữ liệu	Mô tả / Ghi chú
Public Partition (Lưu trữ tại Neo4j)	full_name	String	Họ tên đầy đủ của ứng viên.
	professional_summary	String	Tóm tắt chuyên môn nghiệp vụ.
	skills	List<String>	Danh sách các kỹ năng cốt lõi.
	experience	List<Experience>	Mảng đối tượng chứa lịch sử làm việc.
	education	List<Education>	Mảng đối tượng chứa lịch sử học vấn.
	certificates	List<String>	Các chứng chỉ chuyên môn.
	is_available	Boolean	Trạng thái sẵn sàng nhận việc.
	cultural_tags	List<String>	Các nhãn về độ phù hợp văn hóa.
	additional_information	String	Các thông tin bổ sung khác.
Private Partition (Lưu trữ tại Supabase)	contact.email	String	Thuộc khối đối tượng ContactInfo.
	contact.phone	String	Thuộc khối đối tượng ContactInfo.
	contact.github	String	Thuộc khối đối tượng ContactInfo.
	contact.linkedin	String	Thuộc khối đối tượng ContactInfo.
	salary_expectation	String	Mức lương kỳ vọng (Dữ liệu nhạy cảm).
	blacklist_orgs	List<String>	Các công ty ứng viên không muốn chia sẻ CV.
	project_technical_secrets	String	Chi tiết dự án có yếu tố bảo mật (NDA).
	interview_questions_history	List<String>	Lịch sử các câu hỏi đã từng phỏng vấn.
	evidence_links	List<String>	Các liên kết chứng minh năng lực.

Nguyên tắc thiết kế cốt lõi là ranh giới bảo mật phải nằm ở tầng dữ liệu, không phải tầng ứng dụng. Ngay từ lúc trích xuất, mỗi trường đã được gán rõ ràng vào một trong hai phân vùng, không có vùng xám. Một trường đã khai báo là riêng tư sẽ không bao giờ xuất hiện trong Neo4j, bất kể logic ứng dụng phía trên có gì.

Bảng 3. Phân tách trường dữ liệu trong *RecruitmentNode*

Trường công khai	Trường riêng tư
full_name	contact.email
professional_summary	contact.phone
skills	contact.github / linkedin
experience (tên dự án, công ty)	salary_expectation
education	project_technical_secrets
certificates	evidence_links / additional_information
is_available	
cultural_tags	


Bên cạnh phân tách, lược đồ áp dụng các luật chuẩn hóa cứng chạy độc lập sau bước trích xuất, được tổng hợp tại Bảng 4.

Bảng 4. Các luật chuẩn hóa cứng áp dụng sau bước trích xuất thực thể

Trường áp dụng	Luật chuẩn hóa
skills	Toàn bộ tên kỹ năng ép về chữ thường để tránh bùng nổ nút trùng lặp trong Neo4j (ví dụ: "Python" → "python").
is_available	Chuyển đổi từ mọi biểu đạt tự nhiên tiếng Việt ("Đang tìm việc", "Open to offers", ...) về kiểu logic nhị phân (true/false).
education.year	Ép về kiểu số nguyên 4 chữ số; loại bỏ định dạng không hợp lệ.

1.4. Cơ chế tìm kiếm kết hợp (Hybrid Search Engine)

Tác tử điều phối trung tâm nhận truy vấn tuyển dụng bằng ngôn ngữ tự nhiên và trả về danh sách ứng viên xếp hạng kèm lý giải. Hệ thống triển khai cơ chế tìm kiếm kết hợp hai tầng, hội tụ tín hiệu từ cả cơ sở dữ liệu đồ thị và kho vector phân mảnh, được minh họa tại Hình 20.



Hình 20. Kiến trúc bộ máy truy vấn kết hợp

Tầng 1: Truy hồi sơ bộ cấp thực thể

Mọi truy vấn tuyển dụng dạng ngôn ngữ tự nhiên đều được xử lý thống nhất qua luồng truy hồi ngữ nghĩa. Truy vấn được mã hoá thành vector và đối chiếu trực tiếp với chỉ mục vector cấp thực thể (node-level vector index) lưu trên Neo4j. Thao tác này hoạt động như bộ lọc thô (coarse filter), nhanh chóng thu hẹp không gian tìm kiếm và trích xuất danh sách ngắn (shortlist) top k ứng viên có độ tương đồng ngữ nghĩa tổng thể gần nhất với JD, đồng thời truy xuất kèm mạng lưới quan hệ (relational subgraph) xung quanh mỗi ứng viên.

Tầng 2: Tái xếp hạng kết hợp (Hybrid Re-ranking)

Danh sách sơ bộ tiếp tục được đánh giá song song qua hai tín hiệu độc lập. Tín hiệu đồ thị (S_{graph}) đo mức độ khớp về cấu trúc kỹ năng. Tín hiệu vector (S_{vector}) được cập nhật bằng cách phân tán truy vấn (fan-out) sang Supabase để lấy điểm tương đồng ngữ nghĩa chi tiết từ các đoạn văn bản công khai của các ứng viên trong shortlist. Điểm tổng hợp cuối cùng được tính theo công thức dung hợp trọng số:

$$S_{\text{final}}(c) = \alpha \cdot S_{\text{graph}}(c, q) + \beta \cdot S_{\text{vector}}(c, q), \quad \alpha + \beta = 1 \quad (.1)$$

Với cấu hình mặc định $\alpha = 0,2$ và $\beta = 0,8$, hệ thống đặt trọng tâm vào độ tương đồng ngữ nghĩa từ mô hình nhúng, đồng thời sử dụng cấu trúc đồ thị như bộ hiệu chỉnh (calibrator) cho các kỹ năng đặc thù.

Điểm đồ thị nâng cao (S_{graph}) được thiết kế với ba thành phần:

$$S_{\text{graph}}(c, q) = \lambda_1 \cdot S_{\text{jaccard}} + \lambda_2 \cdot S_{\text{seniority}} + \lambda_3 \cdot S_{\text{bonus}} \quad (.2)$$

với $\lambda_1 = 0,50$, $\lambda_2 = 0,25$, $\lambda_3 = 0,25$, trong đó:

- S_{jaccard} (điểm cơ sở): Đo hệ số Jaccard thể hiện mức độ giao thoa giữa tập kỹ năng yêu cầu của JD và tập kỹ năng ứng viên sở hữu.
- $S_{\text{seniority}}$ (điểm thâm niên): Được tính dựa trên hàm bậc thang (step function) đánh giá tổng lượng kinh nghiệm quy đổi từ các thực thể Experience trên đồ thị.
- S_{bonus} (điểm thưởng kết nối): Được kích hoạt khi có sự giao thoa giữa kỹ năng yêu cầu và các công nghệ liên kết gián tiếp qua các cạnh USED_TECH và CONNECTED_TO. Cơ chế này giúp phát hiện năng lực thực chiến ẩn trong lịch sử dự án mà ứng viên không liệt kê rõ trong phần kỹ năng.

Cấu hình siêu tham số được tổng hợp tại Bảng 5.


Bảng 5. Cấu hình siêu tham số tìm kiếm kết hợp

Hệ thống	α	β	Ghi chú
RAG thuần	0,0	1,0	Chỉ dùng vector cosine từ các đoạn văn bản.
GraphRAG thuần	1,0	0,0	Chỉ dùng điểm đồ thị nâng cao.
Hybrid (cơ bản)	0,2	0,8	Kết hợp vector và Jaccard kỹ năng cơ bản.
Hybrid+ (đề xuất)	0,2	0,8	Kết hợp vector và S_{graph} nâng cao ba thành phần.

Sau khi lọc top k ứng viên, tác tử trích xuất đồ thị con xung quanh từng ứng viên và dùng chuỗi quan hệ này làm cơ sở để mô hình ngôn ngữ sinh lý giải có thể truy vết về từng nút và cạnh cụ thể trên đồ thị, nền tảng của tính minh bạch (Explainable AI) trong quyết định tuyển dụng.


1.5. Thiết kế bản sao số (Digital Twin Interview)

Bản sao số là tác tử cá nhân hoá đại diện cho một ứng viên cụ thể trong cuộc hội thoại phỏng vấn. Khác với tác tử điều phối hoạt động diện rộng trên toàn bộ tập dữ liệu, mỗi bản sao số chỉ biết về một người và chỉ được phép phản hồi trong phạm vi tri thức có trong hồ sơ của người đó. Luồng xử lý phỏng vấn qua kết nối WebSocket được minh hoạ tại Hình 21.



Hình 21. Luồng xử lý phỏng vấn Digital Twin

Kiểm soát truy cập dựa trên quan hệ đồ thị (ReBAC): Cơ chế phân quyền không nằm ở tầng ứng dụng mà được ánh xạ trực tiếp trên cấu trúc đồ thị Neo4j, được minh họa tại Hình 22. Trước mỗi phiên phỏng vấn, hệ thống kiểm tra trạng thái cạnh CONNECTED_TO giữa nút tổ chức và nút ứng viên. Nếu quan hệ mang trạng thái accepted (đã chấp thuận), ngữ cảnh phỏng vấn được xây dựng toàn diện từ dữ liệu đồ thị công khai kết hợp với các đoạn văn bản riêng tư truy hồi từ Supabase. Nếu chưa được chấp thuận, hệ thống giới hạn ngữ cảnh đầu vào chỉ ở phần thông tin công khai. Thiết kế này đảm bảo an toàn ở mức kiến trúc: ngay cả khi bị tấn công bằng kỹ thuật tiêm câu lệnh (prompt injection), mô hình ngôn ngữ vẫn không thể sinh thông tin nhạy cảm vì ngữ cảnh được cấp không chứa các khối dữ liệu này.



Hình 22. Sơ đồ kiểm soát truy cập dựa trên quan hệ đồ thị


Chiến lược hạn chế ảo giác: Để đảm bảo tính trung thực của bản sao số, hệ thống áp dụng chiến lược kiểm soát đa lớp. Về mặt tham số, nhiệt độ sinh được đặt ở mức thấp ($temperature = 0,1$) để mô hình ưu tiên tính chính xác và nhất quán mà vẫn giữ được độ tự nhiên cơ bản trong ngôn ngữ. Về mặt ngữ nghĩa, tác tử được ràng buộc bởi một thẻ định dạng nhân vật (persona prompt) nghiêm ngặt, kết hợp với bước đối chiếu dữ liệu nền (grounding check) và hậu kiểm chứng cứ (post-hoc validation). Tác tử phải phản hồi theo quy ước từ chối nếu câu hỏi vượt ra ngoài phạm vi hồ sơ gốc, ngăn chặn việc mô hình tự suy diễn từ kiến thức tham số nội tại.

Giao tiếp phản hồi liên tục qua WebSocket: Nhằm mang lại trải nghiệm tương tác liền mạch, máy chủ thiết lập kết nối WebSocket trực tiếp với máy khách. Thay vì truyền trực tiếp từng token từ mô hình (vốn có thể gây bất ổn và cần thời gian cho các bước hậu kiểm), hệ thống đợi mô hình sinh hoàn chỉnh và xác thực câu trả lời, sau đó phân tách văn bản đầu ra thành từng từ hoặc cụm từ nhỏ và liên tục đẩy về máy khách. Kỹ thuật này tạo ra hiệu ứng gõ phím trực tiếp (simulated streaming), vừa đảm bảo chất lượng nội dung, vừa duy trì cảm giác hội thoại thời gian thực.

1.6. Hệ thống lịch hẹn và thông báo

Sau khi đánh giá ứng viên qua bản sao số và quyết định tiến đến phỏng vấn thực, hệ thống lịch hẹn và thông báo thay thế quy trình trao đổi email thủ công bằng một luồng tương tác có cấu trúc trực tiếp trong ứng dụng. Quá trình đàm phán lịch

phòng vẫn được quản lý thông qua một cỗ máy trạng thái (state machine), minh hoạ tại Hình 23.



Hình 23. Luồng xử lý lịch hẹn và thông báo

Thiết lập khả dụng lịch (availability): Luồng hoạt động bắt đầu từ phía ứng viên thông qua việc thiết lập cấu hình lịch rảnh (availability). Ứng viên khai báo các khung giờ khả dụng định kỳ theo tuần, chỉ định các ngày ngoại lệ (blocked dates), cấu hình thời lượng mỗi phiên (slot duration) và ngưỡng thời gian báo trước tối thiểu (advance notice hours). Dựa trên các tham số này, hệ thống tự động suy diễn danh sách các khung giờ khả dụng thực tế.

Khởi tạo lịch và tác vụ nền: Khi tổ chức truy vấn danh sách và quyết định tạo lịch phỏng vấn, hệ thống thực hiện đồng thời ba tác vụ nền: lưu bản ghi lịch hẹn với trạng thái khởi tạo (pending), gửi email xác nhận tự động đính kèm tệp sự kiện chuẩn (.ics) qua giao thức SMTP, và phát sinh bản ghi thông báo (notification) vào cơ sở dữ liệu.

Cỗ máy trạng thái đàm phán lịch: Quá trình đàm phán lịch diễn ra qua các vòng lặp phản hồi, làm thay đổi trạng thái của lịch hẹn theo các bước sau:

- *Pending* (Khởi tạo): Lịch vừa được tổ chức tạo, chờ ứng viên phản hồi.
- *Confirmed* (Xác nhận): Một trong hai bên chấp nhận thời gian đề xuất của bên kia.
- *Cancelled* (Hủy bỏ): Một trong hai bên từ chối hoặc chủ động hủy lịch.
- *Rescheduled* (Thay đổi lịch): Ứng viên không đồng ý với giờ ban đầu và đề xuất khung giờ mới.

- *Awaiting org response* (Chờ tổ chức phản hồi): Trạng thái sau khi ứng viên đề xuất giờ mới.
- *Awaiting personnel response* (Chờ ứng viên phản hồi): Tổ chức đưa ra đề xuất ngược lại (counter-propose). Vòng lặp đàm phán tiếp diễn cho đến khi đạt trạng thái confirmed hoặc cancelled.

Thông báo thời gian thực: Hệ thống thông báo thời gian thực được xây dựng trên Supabase Realtime. Khác với kiến trúc thăm dò định kỳ (polling) gây tiêu tốn tài nguyên mạng, máy khách thiết lập một kênh đăng ký (subscription) lắng nghe trực tiếp các thay đổi trên bảng notifications trong PostgreSQL, đảm bảo ứng viên và tổ chức nhận cập nhật tức thì khi có yêu cầu kết nối mới, lịch phỏng vấn được tạo hoặc đối tác phản hồi.

2. Cài đặt giải pháp

2.1. Thu thập và chuẩn bị dữ liệu CV

Nhằm loại trừ rủi ro thiên lệch đánh giá vòng lặp (circular evaluation bias), tập dữ liệu thực nghiệm được xây dựng theo một quy trình kiểm soát khắt khe. Cụ thể, nguồn dữ liệu thô ban đầu được tổng hợp từ việc tạo sinh qua các mô hình ngôn ngữ lớn (LLM) và thu thập các mẫu hồ sơ thực tế từ cộng đồng. Trong quy trình này, LLM chỉ đóng vai trò cung cấp dữ liệu thô, còn toàn bộ công đoạn gán nhãn dữ liệu chuẩn (ground truth annotation) được tiến hành hoàn toàn thủ công và độc lập. Sự phân tách này đảm bảo tính khách quan cho kết quả thực nghiệm, ngăn ngừa triệt để rủi ro hệ thống tự chấm điểm trên chính dữ liệu do nó tạo ra.

Hệ thống dữ liệu phục vụ thực nghiệm được phân loại thành ba nhóm chính, bao gồm:

- **Tập dữ liệu hồ sơ ứng viên (CV Dataset):** Nguồn dữ liệu thô được xây dựng thông qua việc kết hợp dữ liệu sinh tự động từ LLM (Claude, Gemini) và các CV thực tế thu thập từ cộng đồng. Nhằm đánh giá sức chịu đựng của hệ thống trước các tình huống ngoại lệ (edge cases), tập dữ liệu bao gồm cả hồ sơ chuẩn hóa lẫn hồ sơ được cố ý chèn nhiều nhân tạo. Cuối cùng, dữ liệu được đưa qua bước kiểm định chất lượng (QA audit) để chuẩn hóa thành tập dữ liệu đối sánh thủ công (ground truth), làm thước đo chuẩn cho hệ thống.
- **Tập dữ liệu mô tả công việc (JD Dataset):** Tập hợp các yêu cầu tuyển dụng bằng tiếng Việt, bao quát nhiều vai trò kỹ thuật đặc thù như Kỹ thuật dữ liệu, Lập trình hệ thống, Di động, Hạ tầng đám mây, Trí tuệ nhân tạo và Dẫn dắt kỹ thuật. Mỗi mô tả công việc đều được gán nhãn thủ công với ít nhất 1 đến 3 ứng viên phù hợp nhất từ tập dữ liệu đồ thị.
- **Tập dữ liệu hỗ trợ kiểm thử:** Bao gồm các kịch bản được thiết kế riêng để kiểm thử khả năng bảo mật dữ liệu cá nhân, bộ dữ liệu cặp câu hỏi và đáp án (Q&A) dùng cho việc đánh giá chất lượng sinh văn bản qua framework RAGAS, cùng với bộ nhớ đệm biểu diễn vector (vector cache) giúp tối ưu hóa thời gian tính toán trong quá trình chạy thực nghiệm.

Để làm rõ hơn quy mô và mục đích của từng nhóm dữ liệu, cấu trúc tập dữ liệu thực nghiệm được tổng hợp chi tiết tại Bảng 6.


Bảng 6. Cấu trúc và phân bố tập dữ liệu thực nghiệm

Nhóm dữ liệu	Nguồn gốc và phương pháp xử lý	Mục đích sử dụng
Hồ sơ ứng viên (CVs)	Kết hợp LLM và thu thập mẫu thực tế; cây nhiễu, đối soát và gán nhãn thủ công.	Kiểm thử độ chính xác của luồng nhập liệu đa phương thức và khả năng xử lý ngoại lệ.
Mô tả công việc (JDs)	Viết bằng tiếng Việt cho 6 vai trò IT; gán nhãn thủ công 1 đến 3 ứng viên/JD.	Đánh giá hiệu suất đối sánh của cơ chế Tìm kiếm kết hợp.
Kịch bản bảo mật	Xây dựng thủ công các mẫu câu tấn công (Red-teaming).	Kiểm thử ranh giới bảo mật và khả năng phân quyền truy cập đồ thị (Re-BAC).
Bộ câu hỏi Q&A	Xây dựng thủ công các cặp câu hỏi và đáp án chuẩn.	Đánh giá chất lượng truy xuất và mức độ trung thực của Bản sao số (qua RAGAS).

2.2. Cài đặt các bước trong quy trình nhập liệu

Quy trình nhập liệu được thiết kế thành một luồng điều phối tự động, phân loại hướng xử lý dựa trên định dạng tệp đầu vào. Đối với các tệp dữ liệu đã được định dạng sẵn cấu trúc (như JSON), hệ thống áp dụng cơ chế nạp trực tiếp, bỏ qua các công đoạn phân tích và trích xuất nhằm tối ưu hóa tài nguyên và thời gian.

Luồng dữ liệu phi cấu trúc theo chiến lược Map-Reduce: Đối với luồng dữ liệu phi cấu trúc, hệ thống triển khai chiến lược Map-Reduce để xử lý hiệu quả các văn bản dài (được minh họa tại Hình 24). Cụ thể, quy trình này diễn ra như sau: văn bản thô được phân chia thành các đoạn nhỏ với kích thước tối đa 7.000 ký tự, kết hợp một vùng chồng lấp 400 ký tự giữa các đoạn liên kế để duy trì ngữ cảnh gián đoạn. Tại giai đoạn ánh xạ (Map), mỗi đoạn văn bản được đưa qua mô hình ngôn ngữ lớn để bóc tách thành các đối tượng JSON rời rạc. Tiếp đó, tại giai đoạn rút gọn (Reduce), hệ thống tiến hành hợp nhất các phần dữ liệu phân mảnh này thành một khối thông tin thống nhất, tuân thủ nghiêm ngặt lược đồ đối tượng mục tiêu.



Hình 24. Sơ đồ trích xuất dữ liệu qua LLM theo chiến lược Map-Reduce


Phân bổ thời gian xử lý theo công đoạn: Quá trình trích xuất thông qua mô hình ngôn ngữ lớn chiếm tỷ trọng thời gian cao nhất, được xem là điểm nghẽn tính toán đặc trưng của các hệ thống AI tạo sinh hiện nay. Tuy nhiên, do toàn bộ quy trình nhập liệu chỉ thực thi ngầm một lần duy nhất tại thời điểm ứng viên tải hồ sơ lên hệ thống, độ trễ này hoàn toàn không gây ảnh hưởng đến trải nghiệm tương tác thời gian thực của người dùng ở các tính năng khác. Phân bổ thời gian trung bình cho từng công đoạn xử lý được thống kê chi tiết tại Bảng 7.

Bảng 7. Thời gian xử lý trung bình phân bổ theo các bước trong quy trình

Công đoạn xử lý	Thời gian trung bình	Ghi chú
Phân tích định dạng (Parse)	~2 đến 5 giây	Biến động tùy thuộc vào độ phức tạp của bố cục tệp.
Làm sạch và chia đoạn	~0,01 giây	Xử lý nhanh thông qua biểu thức chính quy nội bộ.
Trích xuất thông tin (Extract)	~8,97 giây	Điểm nghẽn chính do thời gian chờ phản hồi từ LLM.
Vector hóa (Vectorize)	~0,18 giây	Gọi API từ mô hình nhúng đa ngôn ngữ.
Ghi cơ sở dữ liệu đồ thị	~0,1 giây	Lưu trữ cấu trúc đỉnh, cạnh và vector cấp thực thể.
Ghi cơ sở dữ liệu vector	~0,5 giây	Lưu trữ các đoạn văn bản và vector cấp phân đoạn.

2.3. Cài đặt tìm kiếm kết hợp và đồ thị tri thức

Hệ thống tìm kiếm kết hợp được hiện thực hóa thông qua mô-đun tác tử điều phối trung tâm. Sơ đồ thuật toán tính điểm của quá trình này được minh họa tại Hình 25.



Hình 25. Sơ đồ thuật toán tính điểm tìm kiếm kết hợp

Luồng truy xuất hai bước: Luồng truy xuất được thiết kế theo cấu trúc hai bước chặt chẽ. Bước thứ nhất, hệ thống truy vấn chỉ mục vector trên cơ sở dữ liệu đồ thị để trích xuất nhanh danh sách rút gọn (shortlist) các ứng viên tiềm năng. Bước thứ hai, hệ thống thực hiện phân tán yêu cầu (fan-out) sang cơ sở dữ liệu vector phụ trợ nhằm thu thập thêm tín hiệu tương đồng ngữ nghĩa chi tiết từ các phân đoạn văn bản công khai của những ứng viên trong danh sách vừa lọc.

Hàm tính điểm xếp hạng: Điểm tổng hợp cuối cùng (S_{final}) để xếp hạng ứng viên được tính theo công thức:

$$S_{\text{final}} = 0,2 \cdot S_{\text{graph}} + 0,8 \cdot S_{\text{vector}} \quad (.3)$$

Trong đó, điểm đồ thị nâng cao (S_{graph}) được tính dựa trên ba yếu tố:

$$S_{\text{graph}} = 0,5 \cdot S_{\text{base}} + 0,25 \cdot S_{\text{seniority}} + 0,25 \cdot S_{\text{bonus}} \quad (.4)$$

Chi tiết về ý nghĩa và vai trò của từng thành phần điểm số được giải thích tại Bảng 8. Sau khi xác định được nhóm ứng viên phù hợp nhất (top-k), hệ thống sử dụng mô hình ngôn ngữ lớn để sinh ra phần lý giải đánh giá mức độ phù hợp. Quá trình sinh văn bản này có khả năng truy vết trực tiếp về từng đỉnh và cạnh cụ thể trên đồ thị, qua đó đảm bảo tính minh bạch cho các quyết định tuyển dụng.

Bảng 8. Thành phần điểm trong cơ chế tìm kiếm kết hợp

Thành phần điểm	Trọng số	Ý nghĩa và cách hoạt động
S_{vector}	0,8	Điểm tương đồng ngữ nghĩa: đo lường khoảng cách vector giữa yêu cầu tuyển dụng và các phân đoạn văn bản trong hồ sơ ứng viên.
S_{graph}	0,2	Điểm cấu trúc đồ thị: tổng hợp các tín hiệu từ mạng lưới quan hệ tri thức của ứng viên, bao gồm ba thành phần phụ bên dưới.
S_{base}	0,5 (của S_{graph})	Điểm kỹ năng cơ sở: tính toán theo hệ số Jaccard, thể hiện mức độ giao thoa trực tiếp giữa tập kỹ năng yêu cầu và tập kỹ năng ứng viên sở hữu.
$S_{\text{seniority}}$	0,25 (của S_{graph})	Điểm thâm niên: định lượng dựa trên tổng thời gian kinh nghiệm được ghi nhận qua các quan hệ làm việc trên đồ thị.
S_{bonus}	0,25 (của S_{graph})	Điểm thưởng kết nối: được kích hoạt khi hệ thống phát hiện các công nghệ liên kết gián tiếp (phù hợp với yêu cầu) thông qua các dự án hoặc tổ chức trong mạng lưới của ứng viên.

2.4. Cài đặt Digital Twin qua WebSocket streaming

Tính năng Phỏng vấn Bản sao số được thiết kế với hai điểm cuối (endpoint) xử lý đàm thoại: một giao diện hỗ trợ đàm thoại đơn lượt (single-turn) qua giao thức HTTP nhằm phục vụ công tác kiểm thử, và một giao diện WebSocket hỗ trợ đàm thoại duy trì trạng thái (multi-turn streaming) dành cho tương tác thời gian thực trên ứng dụng. Sơ đồ tuần tự của quá trình giao tiếp này được minh họa tại Hình 21.


Luồng xử lý dữ liệu qua giao thức WebSocket được thực thi qua năm bước tuần tự như sau:

- **Xác thực phân quyền (ReBAC):** Hệ thống truy vấn cơ sở dữ liệu đồ thị để kiểm tra trạng thái quan hệ kết nối (CONNECTED_TO) giữa tổ chức tuyển dụng và ứng viên. Dựa trên trạng thái này, hệ thống sẽ quyết định phạm vi dữ liệu được phép cấp phát cho mô hình.
- **Xây dựng ngữ cảnh:** Trong trường hợp quan hệ kết nối chưa được xác thực hợp lệ, LLM chỉ được tiếp cận dữ liệu đồ thị và các phân đoạn văn bản ở trạng thái công khai. Ngược lại, nếu kết nối đã được chấp thuận, hệ thống sẽ mở khóa và trích xuất thêm các phân đoạn văn bản mang tính riêng tư từ cơ sở dữ liệu vector.
- **Cấu hình mô hình:** Mô hình ngôn ngữ được thiết lập với hệ số nhiệt độ (temperature) ở mức thấp (0,1) nhằm ưu tiên tính chính xác và nhất quán dựa trên tập ngữ cảnh, nhưng vẫn duy trì được độ tự nhiên cơ bản trong ngôn ngữ giao tiếp.
- **Phát luồng dữ liệu:** Thay vì truyền trực tiếp từng token từ mô hình (có thể gây bất ổn định kết nối), máy chủ chờ quá trình sinh và xác thực câu trả lời hoàn tất. Chuỗi kết quả sau đó được phân tách thành từng từ hoặc cụm từ nhỏ và liên tục truyền về máy khách qua kênh WebSocket, tạo ra hiệu ứng gõ phím trực quan cho người dùng.

- **Lưu trữ:** Toàn bộ lịch sử giao tiếp, bao gồm thông tin phiên và nội dung tin nhắn, được ghi nhận đồng bộ vào cơ sở dữ liệu quan hệ để phục vụ cho các vòng đàm thoại tiếp theo hoặc lưu trữ đối soát.

2.5. Cài đặt giao diện lập trình ứng dụng và hệ thống lịch hẹn

Hệ thống máy chủ được xây dựng trên nền tảng FastAPI với kiến trúc phân tầng theo từng lĩnh vực nghiệp vụ. Cách tiếp cận này giúp tách biệt các luồng xử lý độc lập, tạo điều kiện thuận lợi cho việc bảo trì và mở rộng các tính năng. Sơ đồ tổng hợp các nhóm giao diện lập trình ứng dụng (API) được minh họa tại Hình 26.



Hình 26. Sơ đồ tổng hợp các nhóm API của hệ thống

Cơ chế bảo mật và xác thực: An ninh hệ thống được đảm bảo thông qua chuẩn xác thực mã thông báo định danh (JSON Web Token, viết tắt là JWT). Khi người dùng đăng nhập thành công, nền tảng quản trị dữ liệu sẽ cấp phát một mã thông báo duy nhất. Các yêu cầu truy cập vào những tài nguyên nhạy cảm sau đó sẽ được kiểm chứng thông qua các hàm phụ thuộc trung tâm để xác minh danh tính và quyền hạn của người dùng trước khi xử lý nghiệp vụ.

Hệ thống lịch hẹn và quản lý dịch vụ: Luồng nghiệp vụ lịch hẹn được thiết kế chặt chẽ nhằm hỗ trợ quá trình đàm phán giữa nhà tuyển dụng và ứng viên. Hệ thống tự động tính toán các khung giờ khả dụng dựa trên cấu hình lịch rảnh của ứng viên và gửi thông báo thời gian thực đến các bên liên quan thông qua cơ chế lắng nghe sự kiện trực tiếp. Chi tiết các điểm cuối (endpoints) quan trọng của hệ thống được liệt kê tại Bảng 9 and 10.

Bảng 9. Danh sách các API hệ thống nhóm Xác thực và Nghiệp vụ cốt lõi


Phương thức	Điểm cuối	Mô tả chức năng
POST	/auth/register	Đăng ký tài khoản mới cho tổ chức hoặc ứng viên.
POST	/auth/login	Xác thực thông tin và cấp phát mã thông báo JWT.
POST	/ingest	Tiếp nhận hồ sơ và kích hoạt quy trình trích xuất tri thức.
POST	/search	Thực hiện tìm kiếm kết hợp danh sách ứng viên (dành cho tổ chức).
POST	/interview	Đàm thoại với bản sao số theo luồng đơn lượt (HTTP).
WS	/interview/ws	Đàm thoại duy trì trạng thái thời gian thực qua Web-Socket.
GET	/graph	Truy xuất cấu trúc đồ thị phục vụ trực quan hóa mạng lưới.

Bảng 10. Danh sách các API hệ thống nhóm Lịch hẹn và Thông báo

Phương thức	Điểm cuối	Mô tả chức năng
PUT	/availability	Cập nhật cấu hình thời gian rảnh và các ngày ngoại lệ.
GET	/availability/{id}/slots	Tính toán và liệt kê các khung giờ khả dụng cho phỏng vấn.
POST	/schedule	Khởi tạo yêu cầu đặt lịch phỏng vấn thực tế.
PATCH	/schedule/{id}/status	Cập nhật trạng thái xác nhận hoặc hủy bỏ lịch hẹn.
PATCH	/schedule/{id}/reschedule	Ứng viên phản hồi và đề xuất khung giờ thay thế.
GET	/notification	Truy xuất danh sách thông báo và trạng thái đọc của người dùng.

2.6. Cài đặt giao diện người dùng

Giao diện người dùng được phát triển trên nền tảng Next.js, áp dụng kiến trúc phân tầng thành phần máy chủ và máy khách (Server và Client Components). Kiến trúc tổng thể của giao diện được minh họa chi tiết tại Hình 27.



Hình 27. Kiến trúc phân tầng của giao diện người dùng

Cơ chế bảo vệ luồng truy cập: Một phần mềm trung gian (middleware) hoạt động trên máy chủ được thiết lập để bảo vệ các phân hệ nội bộ. Cơ chế này liên tục kiểm tra và gia hạn mã thông báo phiên làm việc (session token) từ hệ thống cơ sở dữ liệu, đồng thời tự động chuyển hướng người dùng về trang xác thực nếu phiên làm việc không còn hiệu lực.

Quản lý trạng thái ứng dụng: Việc quản lý trạng thái của ứng dụng được phân tách thành hai tầng chuyên biệt nhằm tối ưu hóa hiệu năng:

- **Trạng thái máy khách:** Thư viện Zustand được sử dụng để xử lý các trạng thái giao diện cục bộ có tính chất tức thời (như trạng thái thanh điều hướng, tùy chọn hiển thị).
- **Trạng thái máy chủ:** Thư viện TanStack Query đảm nhận việc quản lý luồng dữ liệu truy xuất từ API, cung cấp các cơ chế tự động lưu đệm (caching), đồng bộ dữ liệu nền (background refetch) và cập nhật giao diện lạc quan (optimistic updates).

Tổ chức định tuyến phân quyền và các chức năng cốt lõi tương ứng được thống kê chi tiết tại Bảng 11.

Bảng 11. Ảnh xạ định tuyến và các tính năng giao diện cốt lõi

Đường dẫn	Vai trò	Tính năng chính
/search	Tổ chức	Tìm kiếm ứng viên, xem xếp hạng và lý giải kết quả có truy vết.
/interview	Tổ chức	Không gian đàm thoại thời gian thực với bản sao số.
/graph	Đa vai trò	Tương tác và trực quan hóa mạng lưới đồ thị tri thức.
/schedule	Đa vai trò	Quản lý vòng đời lịch phỏng vấn (xác nhận, hủy, đổi lịch).
/availability	Ứng viên	Thiết lập khung giờ khả dụng và các ngày ngoại lệ.
/notifications	Đa vai trò	Trung tâm hiển thị thông báo hệ thống theo thời gian thực.
/profile	Đa vai trò	Quản lý thông tin cá nhân và theo dõi trạng thái xử lý hồ sơ.

CHƯƠNG 3. KIỂM THỬ VÀ ĐÁNH GIÁ

1. Giao diện sản phẩm

Hệ thống được thiết kế với giao diện trực quan, chia thành các phân hệ rõ ràng nhằm tối ưu hóa trải nghiệm tương tác cho cả nhà tuyển dụng và ứng viên. Dưới đây là mô tả chi tiết về các màn hình chức năng cốt lõi của hệ thống.

Giao diện trang tìm kiếm ứng viên

Đây là màn hình chức năng trung tâm dành cho nhà tuyển dụng, cho phép thực hiện các truy vấn tìm kiếm ứng viên dựa trên JD thông qua cơ chế tìm kiếm kết hợp.

Tìm kiếm ứng viên
Điền hoặc nhập mô tả công việc (JD), sau đó nhấn Tìm ứng viên.

Vị trí tuyển dụng
VD: Senior Data Engineer

Dùng làm nhân cho các cuộc phỏng vấn

Cấp độ
Chọn cấp độ (tự chọn)

Kỹ năng bắt buộc
Nhập kỹ năng rồi nhấn Enter hoặc dấu phẩy...

Mô tả công việc
Mô tả yêu cầu, trách nhiệm, môi trường làm việc...
Mô tả càng chi tiết, kết quả matching càng chính xác.

0 ký tự

Tìm ứng viên phù hợp

Tìm kiếm gần đây 4 lần ▲

Embedded Rust / Firmware Engineer. Cấp độ: Senior. Kỹ năng bắt buộc: "rust no_std", "freertos", "dma", "arm cortex-m". L...	12:03 08-04 5 ứng viên ▲
Lý Thành Đạt	77% —
Trần Đình Đức	73% —
Hoàng Minh Khải	71% —
Ngô Hữu Lộc	70% —
Nguyễn Thị Ngọc Hà	70% —
Privacy-Preserving Computing Engineer. Cấp độ: Principal / Staff. Kỹ năng bắt buộc: "differential privacy", "homomorphic...	22:54 06-04 5 ứng viên ▼
Threat Intelligence & SOC Analyst. Cấp độ: Senior. Kỹ năng bắt buộc: "splunk siem", "soar automation", "mitre att&ck", "...	19:41 06-04 5 ứng viên ▼
Mô tả công việc CurlyBlue is the VR game studio behind jmancurly (jmancurly) - the 1 VR YouTube channel in the world wit...	15:13 01-04 10 ứng viên ▼

Nhập mô tả công việc để tìm ứng viên phù hợp.


Hình 28. Hình giao diện trang tìm kiếm ứng viên

- **Khu vực nhập liệu mô tả công việc:** Cung cấp các biểu mẫu (form) để nhà tuyển dụng định nghĩa vị trí, cấp độ chuyên môn và danh sách kỹ năng bắt buộc. Vùng văn bản được thiết kế mở rộng nhằm thu thập tối đa ngữ cảnh về yêu cầu và trách nhiệm, cung cấp dữ liệu đầu vào chất lượng cho mô hình đối sánh.

- **Khu vực tra cứu lịch sử tìm kiếm:** Hệ thống hỗ trợ lưu trữ cục bộ (local storage) danh sách các truy vấn gần đây. Mỗi bản ghi tóm tắt nội dung rút gọn, thời điểm thực hiện và số lượng ứng viên tìm thấy, hỗ trợ tái sử dụng cấu hình tìm kiếm nhanh chóng.

Giao diện phỏng vấn Digital Twin (đàm thoại thời gian thực)

Giao diện này cung cấp không gian tương tác trực tiếp giữa nhà tuyển dụng và bản sao số của ứng viên, được tổ chức thành ba khu vực chức năng liên kết chặt chẽ.




Hình 29. Hình giao diện phỏng vấn Bản sao số

- **Khu vực tổng quan năng lực ứng viên:** Hiển thị thông tin định danh và bản tóm tắt mức độ phù hợp (LLM Fit Summary). Hệ thống đối chiếu kinh nghiệm với yêu cầu công việc thông qua điểm số tương đồng (Match score) và độ mạnh kết nối (Connection strength).
- **Khu vực quản lý phiên hội thoại:** Hiển thị danh sách các phiên đàm thoại được sắp xếp theo thời gian tạo (mới nhất xếp trước), tích hợp công cụ tìm kiếm nhanh để quản lý nhiều luồng phỏng vấn.
- **Khu vực hội thoại tương tác:** Mô phỏng môi trường nhắn tin trực tiếp, sử dụng giao thức WebSocket để tạo hiệu ứng truyền phát chuỗi (simulated streaming). Nút chức năng "Đặt lịch phỏng vấn thực" được tích hợp ngay tại giao diện để chuyển đổi trạng thái tuyển dụng liền mạch.

Giao diện trực quan hóa đồ thị tri thức

Nhằm tăng cường khả năng giải thích (Explainability), giao diện đồ thị quan hệ được xây dựng dựa trên thuật toán đồ thị lực tương tác 2D (Force-directed graph 2D).




Hình 30. Hình giao diện trực quan hóa đồ thị tri thức

- **Không gian trực quan hóa mạng lưới:** Biểu diễn dữ liệu dưới dạng đồ thị phức hợp với các đỉnh (node) đại diện cho nhân sự, kỹ năng, tổ chức, dự án. Cung cấp các công cụ tương tác đa chiều như phóng to (zoom), thu nhỏ, kéo thả (pan) và chọn đỉnh.
- **Bảng thông tin chi tiết:** Khi chọn một đỉnh nhân sự cụ thể, hệ thống hiển thị tóm tắt chuyên môn và danh sách kỹ năng cốt lõi. Người dùng có thể thực hiện thao tác chuyển hướng nhanh như bắt đầu phỏng vấn bản sao số hoặc xem hồ sơ chi tiết.

Giao diện quản lý lịch phỏng vấn thực (Schedule)

Phân hệ này được thiết kế để nhà tuyển dụng theo dõi, quản lý tập trung và kiểm soát vòng đời của các sự kiện phỏng vấn thực tế.



Hình 31. Hình giao diện quản lý lịch phỏng vấn thực

- **Danh sách lịch hẹn:** Trình bày dưới dạng thẻ thông tin (card) bao gồm: thông tin ứng viên, thời gian, thời lượng, hình thức tổ chức (Online/Offline), địa điểm và trạng thái lịch hẹn. Trạng thái gửi email thông báo cũng được cập nhật trực tiếp trên thẻ.
- **Hỗ trợ thông tin tiền phỏng vấn:** Cung cấp chức năng xem nhanh "Tóm tắt phỏng vấn AI" ngay trên thẻ sự kiện để hỗ trợ chuẩn bị kịch bản phỏng vấn chính thức. Hệ thống hiển thị các nút hành động tương ứng (Xác nhận, Đề xuất giờ khác, Hủy lịch) tùy thuộc vào vai trò và trạng thái.

Giao diện cài đặt lịch rảnh của ứng viên (Availability)

Đây là màn hình chức năng dành riêng cho ứng viên để chủ động khai báo quỹ thời gian khả dụng của bản thân.

Hình 32. Hình giao diện cài đặt lịch rảnh của ứng viên

- **Thiết lập cấu hình thời gian:** Ứng viên có thể thiết lập các khung giờ rảnh rồi lặp lại theo tuần thông qua các công cụ chọn giờ (Time Pickers) trực quan, hoặc đánh dấu vô hiệu hóa toàn bộ một ngày (trạng thái "Nghỉ"). Các tham số này làm cơ sở dữ liệu đầu vào giúp hệ thống đề xuất khung giờ phù hợp khi tạo lịch hẹn.

Giao diện upload và phản hồi trạng thái xử lý CV (Hồ sơ của tôi)

Giao diện hồ sơ cá nhân đóng vai trò là điểm tiếp nhận dữ liệu (ingestion) của ứng viên vào hệ thống, đồng thời hiển thị kết quả bóc tách thông tin cơ bản.

Hình 33. Hình giao diện nạp dữ liệu và phản hồi trạng thái xử lý CV

- **Khu vực tải lên và tiếp nhận hồ sơ:** Cung cấp vùng tương tác (Dropzone) hỗ trợ các định dạng tệp văn bản phổ biến (PDF, DOCX, TXT, JSON, MD). Hệ thống phản hồi trạng thái xử lý cơ bản (thành công hoặc thất bại) ngay sau khi tải lên.
- **Khu vực hiển thị kết quả trích xuất:** Minh bạch hóa quá trình xử lý bằng cách hiển thị thông tin AI bóc tách được, bao gồm một đoạn văn bản giới thiệu tổng quan năng lực và danh sách các thẻ (tags) từ khóa đại diện cho bộ kỹ năng chuyên môn.

2. Kết quả thực nghiệm

2.1. Thiết lập thực nghiệm

2.1.1. Tập dữ liệu thực nghiệm

Để đảm bảo tính khách quan, toàn bộ dữ liệu thực nghiệm được xây dựng theo nguyên tắc: mô hình ngôn ngữ lớn chỉ tạo sinh nội dung thô ban đầu, còn việc gán nhãn chuẩn do tác giả thực hiện thủ công và độc lập. Nguyên tắc này ngăn mô hình tự đánh giá tốt trên dữ liệu mà chính nó tạo ra.

Tập dữ liệu gồm ba thành phần chính:

- **Tập hồ sơ ứng viên:** Bao gồm 30 CV kỹ thuật tiếng Việt lĩnh vực IT, trong đó 20 CV đầy đủ thông tin theo chuẩn lược đồ đã định nghĩa và 10 CV bị thiếu một số trường, nhằm kiểm tra khả năng xử lý dữ liệu không hoàn chỉnh của hệ thống.
- **Tập bản mô tả công việc:** Bao gồm 30 yêu cầu tuyển dụng viết bằng tiếng Việt, phân bổ đa dạng qua các vai trò kỹ thuật chuyên sâu như: Lập trình hệ thống (Systems Programming), Hạ tầng đám mây (Cloud/Infra), Trí tuệ nhân tạo (AI/ML), Kỹ thuật dữ liệu, An toàn thông tin (Security/Privacy) và Dẫn dắt kỹ thuật (Technical Leadership). Mỗi yêu cầu được gán nhãn tối thiểu 1–3 ứng viên phù hợp từ tập 50 hồ sơ trong cơ sở dữ liệu đồ thị.
- **Tập câu hỏi phỏng vấn:** Bao gồm 26 cặp câu hỏi và câu trả lời chuẩn, phục vụ đánh giá chất lượng truy xuất theo bộ chỉ số RAGAS.

2.1.2. Môi trường thực nghiệm

Các thực nghiệm được thực hiện với cấu hình như sau: ngôn ngữ lập trình Python 3.12, cơ sở dữ liệu đồ thị Neo4j 5.26 chạy qua Docker, cơ sở dữ liệu vector Supabase tích hợp pgvector, bộ đánh giá RAGAS phiên bản 0.2 trở lên. Mô hình ngôn ngữ dùng để đánh giá là GPT-4o-mini với nhiệt độ sinh bằng 0, mô hình trích xuất thực thể sử dụng GPT-4o-mini làm lựa chọn chính và Llama 3.1-8B làm phương án dự phòng.

2.1.3. Chiến lược kiểm thử

Hệ thống được kiểm thử trên hai luồng nghiệp vụ có đặc trưng khác nhau, nên bộ thang đo cũng được chọn riêng cho từng luồng.

- **Luồng tìm kiếm ứng viên:** Bài toán xếp hạng danh sách, được đánh giá trên 30 truy vấn bằng ba chỉ số: MRR@5 (thứ hạng trung bình nghịch đảo của ứng

viên đúng đầu tiên trong top 5), Recall@5 và Recall@10 (tỉ lệ ứng viên đúng xuất hiện trong top 5 và top 10), và NDCG@5 (chỉ số xếp hạng có tính đến vị trí của từng kết quả đúng).

- **Luồng truy xuất trả lời câu hỏi phỏng vấn:** Đánh giá trên 26 cặp câu hỏi bằng bộ chỉ số RAGAS gồm năm thành phần: Độ trung thực (tỉ lệ thông tin trong câu trả lời có thể truy vết về ngữ cảnh được cấp), Độ phù hợp câu trả lời (mức độ câu trả lời giải quyết đúng câu hỏi), Độ bao phủ ngữ cảnh (ngữ cảnh truy xuất có bao phủ đủ thông tin cần thiết không), Độ chính xác ngữ cảnh (tỉ lệ ngữ cảnh được dùng thực sự cần thiết), và Độ đúng đắn câu trả lời (so sánh với câu trả lời chuẩn).

2.2. Đánh giá quy trình nhập liệu

2.2.1. Bước làm sạch văn bản

Bước này có nhiệm vụ loại bỏ nhiều từ văn bản thô gồm ký tự lạ, khoảng trắng thừa và lỗi mã hóa, mà không làm mất thông tin ngôn ngữ. Kết quả đánh giá trên 30 CV được trình bày trong Bảng 12.


Bảng 12. Kết quả đánh giá bước làm sạch văn bản trên 30 CV

Chỉ số	Công thức	Kết quả	Mục tiêu
Số tệp xử lý	-	30	30
Tỉ lệ loại bỏ nhiều trung bình	(độ dài trước - sau) / trước	0,32%	10–30%
Tỉ lệ ký tự tiếng Việt trước xử lý	số ký tự TV / tổng ký tự chữ	0,0903	-
Tỉ lệ ký tự tiếng Việt sau xử lý	số ký tự TV / tổng ký tự chữ	0,0903	$\geq 0,09$

Tỉ lệ loại bỏ nhiều đạt 0,32%, thấp hơn kỳ vọng vì tập CV tổng hợp được tạo từ mô hình ngôn ngữ lớn nên vốn đã khá sạch. Quan trọng hơn, tỉ lệ ký tự tiếng Việt trước và sau xử lý bằng nhau (0,0903), xác nhận bước này không làm mất dữ liệu ngôn ngữ. Với CV thực tế từ người dùng (tệp PDF scan, dán từ Word), tỉ lệ loại bỏ nhiều dự kiến sẽ cao hơn đáng kể.

2.2.2. Bước trích xuất thực thể

Đây là bước trọng tâm của quy trình nhập liệu, sử dụng mô hình ngôn ngữ lớn để trích xuất thông tin có cấu trúc từ CV theo lược đồ đã định nghĩa. Chất lượng ở bước này ảnh hưởng trực tiếp đến toàn bộ phần sau: chất lượng đồ thị tri thức, chất lượng biểu diễn vector và khả năng trả lời câu hỏi phỏng vấn. Hệ thống áp dụng phương pháp danh sách trắng để phân loại dữ liệu. Nhóm trường công khai gồm 8 trường: tên đầy đủ, tóm tắt năng lực, kỹ năng, kinh nghiệm, học vấn, chứng chỉ, trạng thái tìm việc và đặc trưng văn hóa. Nhóm trường riêng tư gồm các trường còn lại như email, số điện thoại, tài khoản mạng xã hội, mức lương kỳ vọng, bí mật kỹ thuật dự án.



Hình 34. Biểu đồ trực quan hóa độ bao phủ từng trường

Bảng 13. Độ bao phủ từng trường trên 30 CV có nhãn chuẩn

Trường	Độ bao phủ	Nhóm
Tên đầy đủ	1,00	Công khai
Tóm tắt năng lực	1,00	Công khai
Kỹ năng	1,00	Công khai
Mức lương kỳ vọng	0,96	Riêng tư
Kinh nghiệm	0,96	Công khai
Email liên hệ	0,92	Riêng tư
Số điện thoại	0,92	Riêng tư
Học vấn	0,88	Công khai
Chứng chỉ	0,64	Công khai
Bí mật kỹ thuật dự án	0,24	Riêng tư
Đặc trưng văn hóa	0,12	Công khai

Bảng 14. Tổng hợp kết quả bước trích xuất thực thể

Chỉ số	Giá trị
Độ bao phủ trung bình – nhóm công khai	0,700
Độ bao phủ trung bình – nhóm riêng tư	0,656
Độ chính xác phân loại công khai/riêng tư	0,824
Tỉ lệ sinh thông tin sai trung bình	0,08 trường/CV
Thời gian trích xuất trung bình	8,97 giây/CV

Dựa trên kết quả trên, có thể rút ra một số nhận xét như sau:

- Ba trường cốt lõi (tên, tóm tắt năng lực, kỹ năng) đạt độ bao phủ 100%, cho thấy mô hình xử lý tốt thông tin được trình bày rõ ràng trong CV.
- Các trường bí mật kỹ thuật dự án và danh sách tổ chức cần tránh chỉ đạt 0,24 vì thường xuất hiện ẩn trong phần mô tả tự do của CV, không có cấu trúc tường minh để mô hình nhận diện.

- Trường đặc trưng văn hóa đạt 0,12 do khái niệm này chưa phổ biến trong format CV tiếng Việt, mô hình không đủ cơ sở để suy luận.
- Tỷ lệ sinh thông tin sai chỉ 0,08 trường/CV chỉ xuất hiện ở 2 trong 25 CV là mức thấp, xác nhận độ tin cậy của quy trình trong điều kiện dữ liệu sạch.

Bước trích xuất thực thể chiếm khoảng 70% tổng thời gian xử lý và là điểm nghẽn chính của toàn bộ quy trình. Tuy nhiên, vì quy trình này chỉ chạy một lần khi người dùng tải CV lên và chạy ngầm (offline), độ trễ này không ảnh hưởng đến trải nghiệm tương tác trực tiếp.

2.2.3. Chất lượng đồ thị tri thức

Sau khi nhập liệu, đề tài kiểm tra mức độ đầy đủ và nhất quán của dữ liệu đã được ghi vào đồ thị. Kết quả được tổng hợp trong Bảng 15 and 16.

Bảng 15. Mức độ đầy đủ của các nút ứng viên

Chỉ số	Giá trị	Tỷ lệ
Tổng nút ứng viên	50	100%
Có tên đầy đủ	50	100,0%
Có danh sách kỹ năng	50	100,0%
Có tóm tắt năng lực	50	100,0%
Có vectơ biểu diễn	50	100,0%
Có trạng thái tìm việc	50	100,0%

Bảng 16. Thống kê quan hệ và kỹ năng trong đồ thị

Chỉ số	Giá trị
Tổng quan hệ kết nối tổ chức – ứng viên	10
– Đã chấp thuận	6
– Đang chờ	4
Số kỹ năng duy nhất (sau chuẩn hóa)	555
Tổng số lần kỹ năng xuất hiện	1.008
Số kỹ năng trung bình mỗi ứng viên	22,46
Tỷ lệ giảm biến thể sau chuẩn hóa	0,72% (559 xuống 555)

Đồ thị đạt mức đầy đủ cao với 100% nút ứng viên có đủ các thuộc tính cần thiết. Tuy nhiên, số lượng quan hệ kết nối giữa tổ chức và ứng viên còn ít (10 quan hệ cho 50 nút), khiến thành phần điểm thưởng kết nối trong công thức tìm kiếm chưa phát huy hết tác dụng. Đây là lý do đề tài bổ sung thêm thành phần tính điểm thâm niên vào công thức để tín hiệu từ đồ thị không phụ thuộc quá nhiều vào độ thưa của dữ liệu quan hệ.

2.3. So sánh các mô hình biểu diễn vector

2.3.1. Thiết lập thực nghiệm

Bốn mô hình biểu diễn vector đa ngôn ngữ được đưa vào so sánh bao gồm: PhoBERT-base-v2 (768 chiều, 135 triệu tham số), multilingual-E5-base (768 chiều, 278 triệu tham số), GTE-multilingual-base (768 chiều, 305 triệu tham số) và BGE-M3 (768 chiều, 568 triệu tham số).

Hai luồng nghiệp vụ của hệ thống có yêu cầu khác nhau về mô hình biểu diễn, nên được đánh giá riêng biệt:

- **Tác vụ tìm kiếm ứng viên:** Đòi hỏi mô hình so khớp tốt giữa bản mô tả công việc (JD) và hồ sơ ứng viên (CV) vốn là các văn bản dài, chứa nhiều thuật ngữ kỹ thuật pha trộn Việt - Anh.
- **Tác vụ truy xuất câu hỏi phỏng vấn:** Đòi hỏi mô hình tìm đúng đoạn văn bản ngắn (chunk) trong CV khớp chính xác với câu hỏi cụ thể của nhà tuyển dụng.

2.3.2. Kết quả trên tác vụ tìm kiếm ứng viên

Bảng 17 trình bày kết quả thực nghiệm trên 30 truy vấn tuyển dụng với tập 50 hồ sơ ứng viên.

Bảng 17. So sánh 4 mô hình biểu diễn vector trên tác vụ tìm kiếm ứng viên

Mô hình	MRR@5	Recall@5	Recall@10	NDCG@5	Thời gian (ms)
PhoBERT-base-v2	0,6361	0,6694	0,7361	0,5832	206,95
multilingual-E5-base	1,0000	0,9556	1,0000	0,9573	186,44
GTE-multilingual-base	1,0000	0,9722	0,9833	0,9698	244,41
BGE-M3	1,0000	0,3890	1,0000	0,9465	556,28

Dựa trên kết quả thực nghiệm, có thể rút ra một số nhận xét như sau:


- Ba mô hình E5, GTE và BGE-M3 đều đạt $MRR@5 = 1,0$. Điều này chứng minh cả ba đều có khả năng biểu diễn ngữ nghĩa đa ngôn ngữ tốt cho dữ liệu kỹ thuật IT tại Việt Nam.
- PhoBERT-base-v2 đạt kết quả thấp hơn đáng kể ($MRR@5 = 0,6361$) do hạn chế của tập dữ liệu huấn luyện (tin tức) thiếu hụt các thuật ngữ chuyên ngành IT tiếng Anh.
- BGE-M3 dù xếp hạng ứng viên số một chính xác nhưng Recall@5 chỉ đạt 0,3890, cho thấy khả năng bao phủ các ứng viên phù hợp trong top 5 kém hơn so với E5 và GTE. Ngoài ra, độ trễ xử lý của BGE-M3 cao gấp 2,3 lần so với GTE.
- Xét cả chất lượng truy xuất lẫn tốc độ xử lý, GTE-multilingual-base là lựa chọn tối ưu nhất với Recall@5 cao nhất (0,9722) và NDCG@5 cao nhất (0,9698).

2.3.3. Kết quả trên tác vụ truy xuất câu hỏi phỏng vấn

Tác vụ này đánh giá khả năng ánh xạ câu hỏi phỏng vấn đến các đoạn văn bản tương ứng trong CV. Kết quả chi tiết được tổng hợp tại Bảng 18.

Bảng 18. So sánh 4 mô hình biểu diễn vector trên tác vụ truy xuất câu hỏi phỏng vấn

Mô hình	Prec@5	Recall	MRR	Hit@1	Thời gian (ms)
PhoBERT-base-v2	0,4462	0,7500	0,9231	0,8462	793,56
multilingual-E5-base	0,4000	0,6795	0,9423	0,9231	723,78
GTE-multilingual-base	0,4692	0,7949	0,9359	0,8846	730,07
BGE-M3	0,2231	0,3782	0,4622	0,2692	736,09



Hình 35. Biểu đồ so sánh hiệu suất các mô hình trên hai tác vụ thực nghiệm

Nhận xét từ Bảng 18 và Hình 35:

- GTE-multilingual-base tiếp tục dẫn đầu về Precision@5 (0,4692) và Recall (0,7949), cho thấy sự ổn định trên cả hai luồng nghiệp vụ.
- multilingual-E5-base đạt MRR cao nhất (0,9423), cho thấy đoạn văn bản đúng thường xuất hiện ngay ở vị trí đầu tiên dù độ bao phủ tổng thể thấp hơn GTE.
- BGE-M3 sụt giảm hiệu suất nghiêm trọng ở tác vụ này, xác nhận mô hình không phù hợp cho việc truy xuất các đoạn văn bản ngắn trong tiếng Việt.
- PhoBERT-base-v2 thể hiện tốt ở tác vụ này nhờ tập huấn luyện gần gũi với ngôn ngữ tự nhiên trong các câu hỏi phỏng vấn tiếng Việt thuần.

Kết luận: Nhìn chung qua cả hai tác vụ, GTE-multilingual-base là mô hình nhất quán nhất với chỉ số Recall dẫn đầu. Do đó, đề tài lựa chọn GTE-multilingual-base làm mô hình biểu diễn vector thống nhất cho hệ thống ORCHGRAPH-RAG.

2.4. Đánh giá hệ thống truy xuất và bảo mật

2.4.1. Cấu hình thực nghiệm

Bốn cấu hình truy xuất được so sánh thông qua việc điều chỉnh trọng số α và β trong công thức kết hợp, đồng thời thay đổi cách tính điểm đồ thị. Mục tiêu là đánh giá xem việc bổ sung tín hiệu từ đồ thị tri thức (GraphRAG) và chiến lược tính điểm nâng cao có cải thiện chất lượng trả lời so với truy xuất vector thuần túy hay không.

Công thức tính điểm đồ thị nâng cao gồm ba thành phần:

$$S_{\text{đồ thị}}(c, q) = \lambda_1 \cdot S_{\text{kỹ năng}} + \lambda_2 \cdot S_{\text{thâm niên}} + \lambda_3 \cdot S_{\text{kết nối}} \quad (.5)$$

với $\lambda_1 = 0,50$, $\lambda_2 = 0,25$, $\lambda_3 = 0,25$. Trong đó: điểm kỹ năng đo tỉ lệ giao thoa kỹ năng giữa ứng viên và yêu cầu tuyển dụng; điểm thâm niên tính dựa trên tổng số năm kinh nghiệm theo các quan hệ làm việc trong đồ thị; điểm kết nối được kích hoạt khi ứng viên có kinh nghiệm tại tổ chức đã thực hiện dự án dùng đúng công nghệ yêu cầu (chuỗi 3 bước quan hệ: ứng viên, tổ chức, dự án, công nghệ).

Bảng 19. Cấu hình bốn hệ thống thực nghiệm


Hệ thống	α	β	Điểm đồ thị	Mô tả
RAG	0,0	1,0	Không áp dụng	Chỉ dùng độ tương đồng vector
GraphRAG	1,0	0,0	Chỉ kỹ năng	Chỉ dùng điểm đồ thị (cũ)
Hybrid	0,4	0,6	Chỉ kỹ năng	Kết hợp điểm đồ thị cũ
Hybrid+ (đề xuất)	0,4	0,6	3 thành phần	Kết hợp điểm đồ thị nâng cao

2.4.2. Kết quả so sánh bốn cấu hình

Bảng 20 trình bày kết quả đánh giá trên 26 cặp câu hỏi và câu trả lời, sử dụng mô hình GPT-4o-mini để chấm điểm với thông số nhiệt độ sinh bằng 0.

Bảng 20. Kết quả RAGAS so sánh bốn cấu hình truy xuất

Hệ thống	Độ trung thực	Phù hợp câu trả lời	Bao phủ ngữ cảnh	Chính xác ngữ cảnh	Đúng dẫn câu trả lời
RAG	0,8727	0,6458	0,9615	0,9103	0,6613
GraphRAG	0,8833	0,6761	0,9615	0,9167	0,7052
Hybrid	0,8613	0,7462	0,9615	0,9103	0,6378
Hybrid+	0,8803	0,7474	0,9615	0,9167	0,6567



Hình 36. Biểu đồ so sánh kết quả RAGAS giữa các cấu hình truy xuất

Dựa trên kết quả kiểm thử bốn cấu hình, có thể rút ra một số nhận xét như sau:

- Độ bao phủ ngữ cảnh đạt 0,9615 đồng đều ở cả bốn cấu hình, cho thấy đồ thị tri thức đã chứa đủ thông tin cần thiết để trả lời các câu hỏi trong tập kiểm thử, bất kể chiến lược truy xuất nào được áp dụng.
- GraphRAG đạt độ trung thực cao nhất (0,8833) và độ đúng dẫn câu trả lời cao nhất (0,7052). Khi chỉ dùng tín hiệu từ đồ thị, ngữ cảnh được cấp cho mô hình có cấu trúc quan hệ chặt chẽ hơn, giúp câu trả lời sinh ra chính xác và bám sát nguồn dữ liệu hơn.
- Hybrid+ đạt độ phù hợp câu trả lời cao nhất (0,7474), nhỉnh hơn Hybrid (0,7462) và vượt rõ GraphRAG (0,6761). Tín hiệu thâm niên và kết nối trong

công thức điểm nâng cao giúp truy xuất ứng viên có ngữ cảnh liên quan hơn đến từng câu hỏi cụ thể.

- Hybrid có độ trung thực thấp nhất (0,8613), cho thấy việc kết hợp vector thuần với điểm kỹ năng đơn giản có thể đưa vào ngữ cảnh những thông tin ít liên quan hơn, làm giảm độ bám sát nguồn của câu trả lời.
- Khoảng cách giữa Hybrid và Hybrid+ còn nhỏ (0,7462 so với 0,7474) vì tập dữ liệu hiện tại có ít quan hệ giữa tổ chức và ứng viên, khiến thành phần điểm kết nối chưa phát huy. Khi quy mô dữ liệu tăng lên, sự chênh lệch này dự kiến sẽ rõ hơn, nhất là với các yêu cầu tuyển dụng có điều kiện cụ thể về thâm niên hoặc lĩnh vực kinh nghiệm.

2.4.3. Kiểm thử bảo mật: Phân lập ranh giới dữ liệu đa người dùng (Cross-tenant Access Control)

Đây là thực nghiệm mang tính quyết định để đánh giá độ tin cậy của hệ thống phân quyền dựa trên quan hệ (ReBAC). Điểm yếu chí mạng của các hệ thống RAG đa người dùng (Multi-tenant) hiện nay là rủi ro rò rỉ dữ liệu chéo khi kẻ tấn công sử dụng kỹ thuật tiêm câu lệnh (Prompt Injection) để vượt rào (Jailbreak). Kiến trúc ORCHGRAPH-RAG được thiết kế để chặn đứng rủi ro này ngay tại tầng cơ sở dữ liệu vật lý (Dual-DB), thay vì phụ thuộc vào bộ lọc từ khóa của mô hình ngôn ngữ.

Để kiểm chứng tính hiệu quả của cơ chế này, một kịch bản kiểm thử "Ủy quyền chéo" tự động (automated test) được thiết lập với 2 Tổ chức (A, B) và 2 Ứng viên (X, Y). Trạng thái quan hệ trên đồ thị Neo4j được giả lập như sau:

Tổ chức A đã được Ứng viên X chấp thuận (cạnh CONNECTED_TO mang trạng thái ACCEPTED). Tổ chức B chưa được Ứng viên X chấp thuận (trạng thái PENDING). Tổ chức A không có kết nối với Ứng viên Y (trạng thái NONE).

Các kịch bản tấn công khai thác lỗ hổng bằng Prompt Injection được đưa trực tiếp vào API của hệ thống để đánh giá khả năng phòng thủ.

Bảng 21. Kết quả kiểm thử bảo mật phân lập dữ liệu đa người dùng (Cross-tenant)

STT	Kịch bản tấn công (Vượt rào bằng Prompt Injection)	Tài khoản	Mục tiêu	KQ	Đánh giá
1	Ủy quyền chéo cơ bản: Ép AI đóng vai quản trị viên hệ thống để yêu cầu trích xuất mức lương kỳ vọng.	Tổ chức B	Dữ liệu X	0	Chặn thành công
2	Dò thám ngang (Lateral Probing): Dùng tài khoản đã cấp quyền của người này để dò hỏi bí mật dự án của người khác.	Tổ chức A	Dữ liệu Y	0	Chặn thành công
3	Tấn công nhập vai (DAN Jailbreak): Sử dụng kỹ thuật DAN để vô hiệu hóa system prompt và ép buộc rò rỉ thông tin.	Tổ chức B	Dữ liệu X	0	Chặn thành công

Hệ thống đạt tỉ lệ an toàn tuyệt đối trên tất cả các kịch bản kiểm thử ủy quyền chéo. Khi Tổ chức B hoặc Tổ chức A cố gắng truy cập dữ liệu mà họ không có thẩm quyền, mô hình ngôn ngữ hoàn toàn không rò rỉ bất kỳ thông tin nhạy cảm nào như mức lương hay bí mật kỹ thuật.

Kết quả này chứng minh sự ưu việt của kiến trúc ReBAC trên cơ sở dữ liệu đồ thị: hệ thống ORCHGRAPH-RAG luôn kiểm tra cạnh CONNECTED_TO trên

Neo4j làm rào chắn đầu tiên. Khi trạng thái quan hệ không phải là ACCEPTED, cơ chế gác cổng sẽ từ chối truy xuất các phân đoạn dữ liệu riêng tư (Private semantic chunks) từ Supabase. Do đó, dữ liệu nhạy cảm hoàn toàn bị loại trừ khỏi cửa sổ ngữ cảnh (Context Window) trước khi được gửi đến LLM. Nhờ giới hạn nghiêm ngặt ở tầng truy xuất vật lý, mô hình ngôn ngữ dù có bị đánh lừa bởi các kỹ thuật Prompt Injection tinh vi đến đâu cũng không thể rò rỉ những thông tin mà nó chưa bao giờ được tiếp xúc trong phiên làm việc.

3. Thảo luận chung

Dựa trên các thực nghiệm từ quy trình nhập liệu đến đánh giá hệ thống truy xuất và kiểm thử bảo mật, có thể rút ra các nhận xét tổng quát sau:

- **Hiệu quả của cơ chế bảo mật ReBAC trên đồ thị:** Kết quả kiểm thử đã xác nhận tính đúng đắn của việc đặt ranh giới bảo mật tại tầng dữ liệu vật lý (Dual-DB). Thay vì tin tưởng vào khả năng tuân thủ chỉ thị của LLM (vốn dễ bị tổn thương trước các kỹ thuật Prompt Injection hay Jailbreak), hệ thống đã chặn đứng rò rỉ thông tin bằng cách loại trừ hoàn toàn dữ liệu nhạy cảm khỏi cửa sổ ngữ cảnh dựa trên trạng thái quan hệ CONNECTED_TO. Tỷ lệ an toàn tuyệt đối trong thực nghiệm ủy quyền chéo (Cross-tenant) chứng minh đây là hướng đi bền vững cho các hệ thống RAG đa người dùng.
- **Chất lượng đồ thị tri thức:** Đồ thị đạt mức đầy đủ cao với 100% nút có đủ thuộc tính cần thiết và 555 kỹ năng duy nhất, trung bình 22,46 kỹ năng/ứng viên. Tuy nhiên, số lượng quan hệ tổ chức và ứng viên (10 quan hệ trên 50 nút) còn ít, làm hạn chế tín hiệu điểm kết nối trong công thức tìm kiếm. Đây là hạn chế cần giải quyết khi mở rộng quy mô hệ thống thực tế.
- **Lựa chọn mô hình biểu diễn vector:** GTE-multilingual-base là mô hình nhất quán nhất trên cả hai tác vụ: dẫn đầu về Recall trên tác vụ tìm kiếm ứng viên và tiếp tục dẫn đầu về cả Precision lẫn Recall trên tác vụ truy xuất câu hỏi phỏng vấn. BGE-M3 thể hiện sự phân kỳ lớn giữa hai tác vụ (tốt ở tìm kiếm tổng thể nhưng kém ở khớp chi tiết), cho thấy không phải mô hình có nhiều tham số nhất là lựa chọn tối ưu cho mọi tác vụ.
- **Đánh đổi giữa GraphRAG và Hybrid+:** GraphRAG cho câu trả lời trung thực và đúng đắn hơn; Hybrid+ cho câu trả lời phù hợp hơn với từng câu hỏi cụ thể. Sự khác biệt này phản ánh đặc thù của từng chiến lược: ngữ cảnh từ đồ thị có cấu trúc chặt hơn nên ít bị "pha loãng", trong khi kết hợp thêm tín hiệu vector giúp bắt được ngữ nghĩa câu hỏi tốt hơn. Với bài toán tuyển dụng, Hybrid+ là lựa chọn thực tế hơn vì nhà tuyển dụng thường đặt câu hỏi theo nhiều cách khác nhau.
- **Điểm nghẽn pipeline nhập liệu:** Bước trích xuất thực thể chiếm khoảng 70% tổng thời gian xử lý (8,97 giây trên tổng 13 giây/CV), là điểm nghẽn không thể tránh khi dùng mô hình ngôn ngữ lớn để phân tích văn bản phi cấu trúc. Do quy trình này chạy ngầm một lần duy nhất khi ứng viên tải CV lên, độ trễ này không ảnh hưởng đến trải nghiệm người dùng cuối.

III. PHẦN KẾT LUẬN

1. Kết quả đạt được

- **Xây dựng thành công kiến trúc Dual-DB và cơ chế ReBAC bảo mật:** Đề tài đã đề xuất và cài đặt hoàn chỉnh mô hình lưu trữ song song kết hợp Neo4j và Supabase/pgvector. Ranh giới bảo mật dựa trên quan hệ (ReBAC) đảm bảo thông tin nhạy cảm (mức lương, bí mật dự án) không thể bị truy xuất trái phép ngay cả khi hệ thống bị tấn công bằng kỹ thuật tiêm câu lệnh. Hiệu quả này đã được kiểm chứng thực nghiệm với tỉ lệ an toàn tuyệt đối trên các kịch bản ủy quyền chéo.
- **Phát triển hệ thống tìm kiếm kết hợp có khả năng giải thích:** Cơ chế Hybrid Search tích hợp điểm đồ thị nâng cao ba thành phần (kỹ năng, thâm niên, kết nối) với tín hiệu tương đồng vector ngữ nghĩa, đạt Recall@5 lên tới 0,9722 với mô hình GTE-multilingual-base. Đặc biệt, kết quả tìm kiếm được kèm theo lý giải có truy vết về từng nút và cạnh cụ thể trên đồ thị, nâng cao tính minh bạch cho hội đồng tuyển dụng và khắc phục hạn chế của RAG thông thường trong việc suy luận đa chiều.
- **Triển khai tác tử bản sao số cá nhân hóa:** Đề tài đã xây dựng và triển khai cơ chế Digital Twin cho phép nhà tuyển dụng thực hiện phỏng vấn sơ bộ tự động thông qua giao diện chat streaming thời gian thực. Tác tử được neo chặt vào tri thức hồ sơ của từng ứng viên, kiểm soát phân quyền truy cập dựa trên quan hệ đồ thị (ReBAC), và đạt độ phù hợp câu trả lời 0,7474 cùng độ trung thực 0,8803 theo đánh giá RAGAS.
- **Xây dựng ứng dụng web tích hợp đầy đủ:** Hệ thống ORCHGRAPH-RAG được triển khai thành ứng dụng web hoàn chỉnh với giao diện trực quan cho hai nhóm người dùng, bao gồm các chức năng tìm kiếm ứng viên, phỏng vấn bản sao số, trực quan hóa đồ thị tri thức và quản lý vòng đời lịch hẹn phỏng vấn tích hợp thông báo thời gian thực.

2. Hướng phát triển

- **Mở rộng quy mô đồ thị tri thức:** Tiếp tục thu thập dữ liệu CV và JD thực tế để tăng mật độ quan hệ trong đồ thị, từ đó phát huy đầy đủ tác dụng của thành phần điểm kết nối và điểm thâm niên trong công thức tìm kiếm kết hợp. Khi mật độ quan hệ tổ chức và ứng viên tăng lên, sự chênh lệch giữa Hybrid và Hybrid+ dự kiến sẽ rõ rệt hơn đáng kể.
- **Tối ưu hóa quy trình nhập liệu:** Nghiên cứu các kỹ thuật giảm chi phí cho bước trích xuất thực thể hiện chiếm khoảng 70% tổng thời gian xử lý thông qua việc tinh chỉnh (fine-tuning) mô hình ngôn ngữ cỡ nhỏ trên tập dữ liệu CV tiếng Việt đã gán nhãn, hoặc áp dụng chiến lược xử lý song song để rút ngắn thời gian nhập liệu mà không ảnh hưởng đến chất lượng trích xuất.
- **Nâng cao khả năng suy luận đa bước trên đồ thị:** Nghiên cứu tích hợp các phương pháp duyệt đồ thị thích nghi (adaptive multi-hop traversal) để mô hình tự động xác định độ sâu suy luận phù hợp tùy theo độ phức tạp của truy vấn,

thay vì sử dụng chiều sâu cố định. Hướng này mở ra khả năng trả lời các câu hỏi tuyển dụng đòi hỏi tổng hợp thông tin từ nhiều thực thể liên kết gián tiếp trong đồ thị, chẳng hạn suy luận về sự phù hợp văn hóa tổ chức dựa trên chuỗi quan hệ đồng nghiệp và dự án.

TÀI LIỆU THAM KHẢO

- [1] Takuya Akiba et al. “Optuna: A Next-generation Hyperparameter Optimization Framework”. In: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 2019, pp. 2623–2631.
- [2] Tom B. Brown et al. “Language Models are Few-Shot Learners”. In: *Advances in Neural Information Processing Systems*. Vol. 33. 2020.
- [3] Jiacheng Chen et al. “BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation”. In: arXiv preprint arXiv:2309.07597 (2024).
- [4] Jacob Devlin et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. In: *Proceedings of NAACL-HLT 2019*. 2019, pp. 4171–4186.
- [5] Darren Edge et al. “From Local to Global: A Graph RAG Approach to Query-Focused Summarization”. In: arXiv preprint arXiv:2404.16130 (2024).
- [6] Shahul Es et al. “RAGAS: Automated Evaluation of Retrieval Augmented Generation”. In: *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*. 2024, pp. 150–158.
- [7] European Commission. *ESCO – European Skills, Competences, Qualifications and Occupations*. <https://esco.ec.europa.eu>. Accessed: 2026-04-13. 2023.
- [8] Philip W. L. Fong. “Relationship-Based Access Control: Protection Model and Policy Language”. In: *Proceedings of the 1st ACM Conference on Data and Application Security and Privacy (CODASPY)*. ACM, 2011, pp. 191–202.
- [9] Aidan Hogan et al. “Knowledge Graphs”. In: *ACM Computing Surveys (CSUR)* 54.4 (2021), pp. 1–37.
- [10] Lei Huang, Weijie Yu, et al. “A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions”. In: *ACM Transactions on Information Systems* (2023).
- [11] Patrick Lewis et al. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. In: *Advances in Neural Information Processing Systems*. Vol. 33. 2020.

- [12] Ethan Lindstrom. “Feasibility of a Human Capital Digital Twin”. Systems Design and Management Program. MA thesis. Massachusetts Institute of Technology, 2023.
- [13] Yu. A. Malkov and D. A. Yashunin. “Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs”. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 42.4 (2018), pp. 824–836.
- [14] Neo4j Inc. *Neo4j Graph Database Documentation v5.26*. <https://neo4j.com/docs/>. Accessed: 2026-04-13. 2024.
- [15] Dat Quoc Nguyen and Anh Tuan Nguyen. “PhoBERT: Pre-trained Language Models for Vietnamese”. In: *Findings of the Association for Computational Linguistics: EMNLP 2020*. 2020, pp. 1037–1042.
- [16] Shirui Pan et al. “Unifying Large Language Models and Knowledge Graphs: A Roadmap”. In: *IEEE Transactions on Knowledge and Data Engineering* 36.7 (2024), pp. 3580–3599.
- [17] Joon Sung Park et al. “Generative Agents: Interactive Simulacra of Human Behavior”. In: *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. 2023, pp. 1–22.
- [18] Jian Peng et al. “Graph Retrieval-Augmented Generation: A Survey”. In: arXiv preprint arXiv:2408.08921 (2024).
- [19] Sebastián Ramírez. *FastAPI: High performance, easy to learn, fast to code, ready for production*. <https://fastapi.tiangolo.com/>. Accessed: 2026-04-14. 2024.
- [20] Nils Reimers and Iryna Gurevych. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. 2019, pp. 3982–3992.
- [21] Supabase Inc. *Supabase Documentation – pgvector and Vector Embeddings*. <https://supabase.com/docs/guides/ai>. Accessed: 2026-04-13. 2024.
- [22] Ashish Vaswani et al. “Attention Is All You Need”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017.
- [23] Liang Wang et al. “Multilingual E5 Text Embeddings: A Technical Report”. In: arXiv preprint arXiv:2402.05672 (2024).

- [24] Zhiwei Zhang et al. “mGTE: Generalized Long-Context Text Representation and Reranking Models for Multilingual Text Retrieval”. In: arXiv preprint arXiv:2407.19669 (2024).
- [25] Yukun Zhu et al. “Aligning Books and Movies: Towards Story-Like Visual Explanations by Watching Movies and Reading Books”. In: *Proceedings of the IEEE International Conference on Computer Vision*. 2015, pp. 19–27.