

ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG



LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH KHOA HỌC MÁY TÍNH

Đề tài

**ORCHGRAPH-RAG: MÔ HÌNH ĐA TÁC TỬ ĐIỀU PHỐI
BẰNG ĐỒ THỊ CHO TUYỂN DỤNG THÔNG MINH VÀ
TRUY XUẤT TRI THỨC CÁ NHÂN HÓA**

**(ORCHGRAPH-RAG: A GRAPH-ORCHESTRATED
MULTI-MODAL AGENT PARADIGM FOR PRIVACY-AWARE
RECRUITMENT AND PERSONALIZED RETRIEVAL)**

Sinh viên: Trần Thị Hồng Ngọc

Mã số: B2207546

Khóa: 48

Giảng viên hướng dẫn: TS. Mã Trường Thành

Cần Thơ, 04/2026

ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG



LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH KHOA HỌC MÁY TÍNH

Đề tài

**ORCHGRAPH-RAG: MÔ HÌNH ĐA TÁC TỬ ĐIỀU PHỐI
BẰNG ĐỒ THỊ CHO TUYỂN DỤNG THÔNG MINH VÀ
TRUY XUẤT TRI THỨC CÁ NHÂN HÓA**

**(ORCHGRAPH-RAG: A GRAPH-ORCHESTRATED
MULTI-MODAL AGENT PARADIGM FOR PRIVACY-AWARE
RECRUITMENT AND PERSONALIZED RETRIEVAL)**

Giảng viên hướng dẫn
TS. Mã Trường Thành

Sinh viên thực hiện
Trần Thị Hồng Ngọc
Mã số: B2207546
Khóa: 48

Cần Thơ, 04/2026

**XÁC NHẬN CHỈNH SỬA LUẬN VĂN
THEO YÊU CẦU CỦA HỘI ĐỒNG**

Tên luận văn (tiếng Việt và tiếng Anh): OrchGraph-RAG: Mô hình đa tác tử điều phối bằng đồ thị cho tuyển dụng thông minh và truy xuất tri thức cá nhân hóa (OrchGraph-RAG: A Graph-Orchestrated Multi-Modal Agent Paradigm for Privacy-Aware Recruitment and Personalized Retrieval).

Họ tên sinh viên: Trần Thị Hồng Ngọc

Mã SV: B2207546

Mã lớp: DI22Z6A1

Đã báo cáo tại hội đồng ngành: Khoa học máy tính

Ngày báo cáo: 22/04/2026

Hội đồng báo cáo gồm:

- TS. Trần Nguyễn Minh Thư
- TS. Võ Trí Thức
- TS. Mã Trường Thành


Chủ tịch hội đồng
Ủy viên
Thư ký

Luận văn đã được chỉnh sửa theo góp ý của Hội đồng.

Cần Thơ, ngày 22 tháng 04 năm 2026

Giảng viên hướng dẫn

(Ký và ghi rõ họ tên)


Mã Trường Thành

This image shows a blank sheet of white paper with horizontal ruling lines. The lines are evenly spaced and run across the width of the page. There are no margins, text, or other markings on the paper.

Cần Thơ, ngày tháng năm 2026
(Ký và ghi rõ họ tên)

LỜI CẢM ƠN

Trước hết, tôi xin bày tỏ lòng biết ơn sâu sắc đến Trường Công nghệ thông tin và Truyền thông, Đại học Cần Thơ, nơi đã tạo điều kiện thuận lợi và môi trường học tập năng động để tôi được tiếp cận, nghiên cứu và phát triển kiến thức trong lĩnh vực công nghệ thông tin. Các học phần đại cương, cơ sở ngành và chuyên ngành bổ ích đã giúp tôi tích lũy được nền tảng kiến thức vững chắc, cũng như rèn luyện được khả năng tư duy logic, sáng tạo và kỹ năng làm việc chuyên nghiệp.

Đặc biệt, tôi xin gửi lời cảm ơn chân thành và sâu sắc nhất đến TS. Mã Trường Thành, người đã luôn tận tình hướng dẫn, đồng hành và định hướng cho tôi trong suốt quá trình thực hiện đề tài. Thầy không chỉ giúp tôi củng cố kiến thức chuyên môn mà còn truyền cho tôi tinh thần nghiên cứu nghiêm túc, kiên nhẫn và cầu tiến trong học thuật. Những góp ý quý báu cùng sự chỉ bảo tận tâm của thầy là nguồn động lực to lớn giúp tôi vượt qua những khó khăn để hoàn thiện đề tài luận văn tốt nghiệp một cách tốt nhất.

Tôi cũng xin gửi lời tri ân đến toàn thể quý thầy cô trong Trường Công nghệ Thông tin và Truyền thông, những người đã tận tâm giảng dạy, truyền đạt kiến thức quý báu cho tôi trong suốt những năm học vừa qua. Sự cống hiến, tâm huyết và tinh thần trách nhiệm của quý thầy cô đã giúp tôi không ngừng trưởng thành trong cả kiến thức chuyên môn lẫn tư duy nghiên cứu.

Cuối cùng, tôi xin gửi lời cảm ơn sâu sắc đến gia đình và bạn bè, những người luôn ở bên cạnh, chia sẻ, động viên và khích lệ tinh thần trong suốt quá trình học tập và hoàn thiện luận văn. Sự yêu thương và ủng hộ của mọi người là điểm tựa vững chắc giúp tôi có thêm nghị lực để hoàn thành tốt chặng đường học tập này.

Tôi xin chân thành cảm ơn!

Cần Thơ, ngày 25 tháng 11 năm 2025

Người viết

Trần Thị Hồng Ngọc

MỤC LỤC

DANH MỤC HÌNH ẢNH	iii
DANH MỤC BẢNG BIỂU	iv
DANH MỤC TỪ VIẾT TẮT	v
ABSTRACT	vi
TÓM LƯỢC	vii
I. PHẦN GIỚI THIỆU	1
1. Đặt vấn đề	1
2. Những nghiên cứu liên quan	2
3. Mục tiêu đề tài	3
4. Đối tượng và phạm vi nghiên cứu	3
5. Phương pháp nghiên cứu	3
6. Bố cục quyển báo cáo	4
II. PHẦN NỘI DUNG	5
CHƯƠNG 1. MÔ TẢ BÀI TOÁN	5
1. Mô tả chi tiết bài toán	5
1.1. Bài toán tuyển dụng thông minh và truy xuất tri thức	5
1.2. Ứng dụng Web	5
2. Vấn đề giải pháp liên quan đến bài toán	6
2.1. Mô hình ngôn ngữ lớn và giao tiếp streaming	6
2.2. Mô hình nhúng đa ngôn ngữ	7
2.3. Cơ sở dữ liệu vector và pgvector	8
2.4. Đồ thị tri thức và cơ sở dữ liệu đồ thị Neo4j	11
2.5. Nền tảng lưu trữ và đồng bộ dữ liệu Supabase	13
2.6. Tìm kiếm kết hợp	13
2.7. Mô hình số cá nhân (AI Digital Twin)	13
2.8. Framework backend FastAPI và frontend Next.js	14
2.9. Thang đo đánh giá hệ thống RAG (RAGAS)	14
CHƯƠNG 2. THIẾT KẾ VÀ CÀI ĐẶT GIẢI PHÁP	16

1. Thiết kế hệ thống	16
1.1. Mô hình lưu trữ song song (Dual-DB)	17
1.2. Pipeline nhập liệu CV tiếng Việt	20
1.3. Lược đồ tri thức RecruitmentNode	23
1.4. Cơ chế tìm kiếm kết hợp (Hybrid Search Engine)	24
1.6. Thiết kế bản sao số	26
1.7. Hệ thống lịch hẹn và thông báo	28
2. Cài đặt giải pháp	31
2.1. Thu thập và chuẩn bị dữ liệu CV	31
2.2. Cài đặt các bước trong Pipeline Ingestion	31
2.3. Cài đặt Hybrid Search và đồ thị tri thức	32
2.4. Cài đặt Digital Twin qua WebSocket streaming	33
2.5. Cài đặt API và hệ thống lịch hẹn	34
2.6. Cài đặt giao diện	35
CHƯƠNG 3. KIỂM THỬ VÀ ĐÁNH GIÁ	38
1. Giao diện sản phẩm	38
2. Kết quả thực nghiệm	43
2.1. Thiết lập thực nghiệm	43
2.2. Đánh giá quy trình nhập liệu	44
2.3. So sánh các mô hình biểu diễn vector	46
2.4. Đánh giá hệ thống truy xuất và bảo mật	48
3. Thảo luận chung	50
III. PHẦN KẾT LUẬN	51
1. Kết quả đạt được	51
2. Hướng phát triển	51
TÀI LIỆU THAM KHẢO	52

DANH MỤC HÌNH ẢNH

Hình 1.	Minh họa kiến trúc cơ bản của SBERT	7
Hình 2.	Minh họa kiến trúc cơ bản của mô hình nhúng đa ngôn ngữ (tiếng Anh - màu xanh và tiếng Đức - màu hồng)	8
Hình 3.	Quy trình hoạt động cơ bản của một cơ sở dữ liệu vector	8
Hình 4.	Minh họa cấu trúc đồ thị đa tầng (trái) và cơ chế chọn lân cận heuristic (phải) của thuật toán HNSW dùng trong tìm kiếm ANN..	9
Hình 5.	Sơ đồ đường đi cho quá trình lưu trữ trong cơ sở dữ liệu vector	9
Hình 6.	Sơ đồ đường đi cho quá trình truy vấn trong cơ sở dữ liệu vector ..	10
Hình 7.	Minh họa việc sử dụng độ tương đồng cosine để đo lường khoảng cách ngữ nghĩa giữa các câu trong không gian vector	11
Hình 8.	Cấu trúc đồ thị tri thức	12
Hình 9.	Minh họa mô hình đồ thị thuộc tính trong Neo4j	12
Hình 10.	Luồng xử lý tổng quát của hệ thống khi triển khai thành ứng dụng .	16
Hình 11.	Kiến trúc mô hình lưu trữ song song Dual-DB (Neo4j + Supabase/pgvector)	18
Hình 12.	Sơ đồ nguyên lý Polyglot Persistence	19
Hình 13.	Luồng tiền xử lý dữ liệu	21
Hình 14.	Luồng trích xuất và ghi dữ liệu	22
Hình 15.	Kiến trúc Hybrid Query Engine – công thức $S_{final} (\alpha=0,2; \beta=0,8)$	25
Hình 16.	Luồng xử lý phỏng vấn Digital Twin qua WebSocket streaming ...	27
Hình 17.	Sơ đồ phân quyền truy cập dựa trên quan hệ đồ thị	28
Hình 18.	Sơ đồ trạng thái vòng đời lịch phỏng vấn (đàm phán và đồng thuận)	29
Hình 19.	Sơ đồ thuật toán tính điểm tìm kiếm kết hợp	32
Hình 20.	Sơ đồ tuần tự giao tiếp WebSocket cho Digital Twin Interview	33
Hình 21.	Sơ đồ kiến trúc của giao diện người dùng	36
Hình 22.	Hình giao diện trang tìm kiếm ứng viên	38
Hình 23.	Hình giao diện phỏng vấn Digital Twin	39
Hình 24.	Hình giao diện trực quan hóa đồ thị tri thức	40
Hình 25.	Hình giao diện quản lý lịch phỏng vấn thực	41
Hình 26.	Hình giao diện cài đặt lịch rảnh của ứng viên	41
Hình 27.	Hình giao diện upload và phản hồi trạng thái xử lý CV	42
Hình 28.	Biểu đồ trực quan hóa độ bao phủ từng trường	45

DANH MỤC BẢNG BIỂU

Bảng 1.	Bảng 4. Phân tách trường dữ liệu Public/Private trong RecruitmentNode	24
Bảng 2.	Bảng 5. Các luật chuẩn hóa cứng áp dụng sau bước trích xuất thực thể	24
Bảng 3.	Bảng 6. Cấu hình siêu tham số Hybrid Search (cơ bản và điểm đồ thị nâng cao)	26
Bảng 4.	Bảng 12. Thời gian xử lý trung bình phân bổ theo các bước pipeline	32
Bảng 5.	Bảng 7. Danh sách API endpoints - Auth và Core	34
Bảng 6.	Bảng 8. Danh sách API endpoints - Chat và Scheduling	35
Bảng 7.	Bảng 9. Danh sách API endpoints - Notification	35
Bảng 8.	Bảng 10. Biến môi trường hệ thống	35
Bảng 9.	Bảng 11. Ánh xạ định tuyến (route), vai trò và tính năng chính (frontend)	37
Bảng 10.	Kết quả đánh giá bước làm sạch văn bản trên 30 CV	44
Bảng 11.	Độ bao phủ từng trường trên 30 CV có nhãn chuẩn	44
Bảng 12.	Tổng hợp kết quả bước trích xuất thực thể	45
Bảng 13.	Mức độ đầy đủ của các nút ứng viên (50 nút)	46
Bảng 14.	Thống kê quan hệ và kỹ năng trong đồ thị	46
Bảng 15.	So sánh 4 mô hình biểu diễn vector trên tác vụ tìm kiếm ứng viên .	47
Bảng 16.	So sánh 4 mô hình biểu diễn vector trên tác vụ truy xuất câu hỏi phỏng vấn	47
Bảng 17.	Cấu hình bốn hệ thống thực nghiệm	48
Bảng 18.	Kết quả RAGAS so sánh bốn cấu hình truy xuất	48
Bảng 19.	Kết quả kiểm thử bảo mật dữ liệu cá nhân	49

DANH MỤC TỪ VIẾT TẮT

STT	Từ viết tắt (Abbreviation)	Từ viết đầy đủ (Origin word)
1	ICH	Intangible Cultural Heritage (Di sản văn hóa phi vật thể)
2	MG	Multimodal Graph
3	GNN	Graph Neural Network
4	MGNN	Multimodal Graph Neural Network
5	GAT	Graph Attention Network
6	MGAT	Multimodal Graph Attention Network
7	KAN	Kolgomorov-Arnold Network
8	MFCC	Mel-Frequency Cepstral Coefficients
9	MLP	Multi-Layer Perceptron
10	SL	Số lượng

ABSTRACT

In the era of digital transformation, automatic classification of intangible cultural heritage (ICH) data plays an important role in cultural preservation and promotion. However, traditional CNN-based methods that rely only on image data still face many limitations, especially when dealing with multimodal data and high similarity in costumes, rituals, and festival contexts. To address these issues, I proposes a deep learning architecture that combines a Graph Attention Network on a multimodal graph (MGAT) with FastKAN (Kolmogorov–Arnold Network). The proposed architecture enables joint learning and integration of three data modal, including image, text, and audio, within a shared representation space. Experimental results on a collected ICH dataset show that the proposed method outperforms baseline models, with the DenseNet121 + MGAT + FastKAN configuration achieving an accuracy of 94.35%. In addition, lightweight models such as MobileNetV3 Small and ShuffleNetV2 1.0x also show improvements of more than 8%. The use of FastKAN allows the model to learn complex nonlinear relationships more effectively than traditional MLPs. Furthermore, this study develops and deploys a web-based system called ICH Predictor, which supports data lookup and visualization of the ICH classification process, enhancing the practical applicability of the proposed approach.

Keywords: Intangible Cultural Heritage, Multimodal Classification, Graph Neural Networks, MGAT, FastKAN, Deep Learning.

TÓM LƯỢC

Trong kỷ nguyên chuyển đổi số, việc tự động phân lớp dữ liệu di sản văn hóa phi vật thể (ICH) đóng vai trò quan trọng trong công tác bảo tồn và quảng bá giá trị văn hóa. Tuy nhiên, các phương pháp CNN truyền thống chỉ khai thác dữ liệu hình ảnh vẫn còn nhiều hạn chế, đặc biệt khi phải xử lý dữ liệu có tính đa phương thức và mức độ tương đồng cao về trang phục, nghi thức cũng như bối cảnh lễ hội. Nhằm khắc phục những hạn chế này, tôi đề xuất một kiến trúc học sâu kết hợp Graph Attention Network trên đồ thị đa phương thức (MGAT) với FastKAN (mạng Kolmogorov–Arnold). Kiến trúc này cho phép khai thác và tích hợp đồng thời ba nguồn dữ liệu gồm hình ảnh, văn bản và âm thanh trong một không gian biểu diễn chung. Kết quả thực nghiệm trên tập dữ liệu ICH thu thập được cho thấy phương pháp đề xuất đạt hiệu quả cao hơn so với các mô hình so sánh, trong đó cấu hình DenseNet121 + MGAT + FastKAN đạt độ chính xác 94.35%. Đồng thời, các mô hình gọn nhẹ như MobileNetV3 Small và ShuffleNetV2 1.0x cũng ghi nhận mức cải thiện trên 8%. Việc tích hợp FastKAN giúp mô hình học được các quan hệ phi tuyến phức tạp hiệu quả hơn so với MLP truyền thống. Bên cạnh đó, đề tài còn xây dựng và triển khai hệ thống web ICH Predictor, hỗ trợ tra cứu và trực quan hóa quy trình phân lớp dữ liệu ICH, góp phần nâng cao khả năng ứng dụng thực tế của mô hình đề xuất.

Từ khóa: Di sản văn hóa phi vật thể, Phân loại đa phương thức, Mạng nơ-ron đồ thị, MGAT, FastKAN, Học sâu.

I. PHẦN GIỚI THIỆU

1. Đặt vấn đề

Trong bối cảnh thị trường nhân lực ngành Công nghệ thông tin ngày càng cạnh tranh, bài toán cốt lõi mà các bộ phận tuyển dụng phải đối mặt không đơn thuần là lọc đủ điều kiện mà là tìm đúng người phù hợp nhất - một sự phân biệt tưởng nhỏ nhưng có hệ quả lớn về chất lượng nhân sự và chi phí tuyển dụng. Quá trình này đòi hỏi xử lý khối lượng lớn dữ liệu phi cấu trúc: hồ sơ ứng viên (CV) chứa đựng lộ trình nghề nghiệp phức tạp, và mô tả công việc (JD) thường được diễn đạt theo nhiều cách khác nhau tùy từng tổ chức.

Phương pháp tuyển dụng truyền thống chủ yếu dựa vào hệ thống theo dõi ứng viên (Applicant Tracking System - ATS) với cơ chế đối sánh từ khóa (keyword matching). Cách tiếp cận này bộc lộ hai hạn chế căn bản: thứ nhất, nó bỏ sót các ứng viên tiềm năng do sự khác biệt về cách diễn đạt - một kỹ sư có kinh nghiệm "Spring Boot" hoàn toàn đáp ứng yêu cầu "Java Backend" nhưng có thể bị loại bởi cơ chế khớp từ khóa đơn giản; thứ hai, nó thiếu khả năng hiểu ngữ cảnh tổng thể của một lộ trình nghề nghiệp, tức là không thể suy luận rằng ứng viên từng dẫn dắt một dự án quy mô lớn tại công ty fintech có nhiều khả năng phù hợp hơn với vai trò senior engineer so với ứng viên chỉ liệt kê cùng danh sách kỹ năng mà thiếu chiều sâu kinh nghiệm.

Sự phát triển của Mô hình ngôn ngữ lớn (Large Language Model - LLM) và kỹ thuật Truy xuất tăng cường sinh thực (Retrieval-Augmented Generation - RAG) đã mang lại hướng tiếp cận mới có khả năng phân tích ngữ nghĩa tự nhiên. Tuy nhiên, kiến trúc RAG vector truyền thống (Naive RAG) gặp phải rào cản kỹ thuật đặc thù khi xử lý dữ liệu nhân sự. Do bản chất chia nhỏ văn bản (chunking) để lưu trữ vào cơ sở dữ liệu vector, Naive RAG thường làm đứt gãy mối liên hệ cấu trúc giữa các thực thể - ví dụ, thông tin "ứng viên A thực hiện dự án B tại công ty C sử dụng công nghệ D" bị phân tán sang nhiều đoạn văn bản độc lập không liên kết với nhau. Điều này dẫn đến hiện tượng "ảo giác" (hallucination) khi hệ thống phải suy luận tổng hợp đa chiều, đồng thời không có cơ chế kiểm soát ranh giới bảo mật thông tin cá nhân theo từng vai trò truy cập [7].

Từ thực tiễn đó, một hướng tiếp cận có triển vọng là sử dụng đồ thị tri thức (Knowledge Graph) để biểu diễn trực tiếp mạng lưới quan hệ giữa ứng viên và tổ chức, lưu trữ song song các thông tin công khai phục vụ truy vấn và kiểm soát truy cập dữ liệu nhạy cảm theo cấu trúc quan hệ. Khi đồ thị tri thức được tích hợp vào luồng sinh văn bản của LLM theo kiến trúc GraphRAG [1], hệ thống có thể "nhìn thấy" toàn bộ chuỗi quan hệ ngữ cảnh của từng ứng viên thay vì chỉ tìm kiếm đoạn văn bản tương đồng, từ đó hỗ trợ nhà tuyển dụng tìm đúng người phù hợp nhất thay vì chỉ lọc người đủ điều kiện theo từ khóa.

Xuất phát từ nhu cầu đó, đề tài "ORCHGRAPH-RAG: Mô hình đa tác tử điều phối bằng đồ thị cho tuyển dụng thông minh và truy xuất tri thức cá nhân hóa" được thực hiện nhằm xây dựng một hệ thống kết hợp sự linh hoạt trong hiểu ngữ

nghĩa của LLM với sự chặt chẽ về cấu trúc quan hệ của cơ sở dữ liệu đồ thị, hướng đến mục tiêu tối ưu hóa quy trình tuyển dụng và cá nhân hóa trải nghiệm phỏng vấn thông qua bản sao số (Digital Twin) của từng ứng viên.

2. Những nghiên cứu liên quan

Trong những năm gần đây, việc ứng dụng Trí tuệ nhân tạo vào lĩnh vực quản trị nhân sự đã dịch chuyển từ các mô hình học máy phân loại văn bản truyền thống sang các hệ thống hỏi đáp thông minh dựa trên LLM. Các nghiên cứu hiện tại có thể phân thành bốn hướng tiếp cận chính, mỗi hướng đóng góp những hiểu biết nhất định nhưng đồng thời bộc lộ những hạn chế còn tồn đọng.

Hướng 1 - Hệ thống RAG dựa trên Vector (Vector-based RAG): Các nghiên cứu theo hướng này tập trung vào việc nhúng (embedding) CV và JD vào không gian vector để tính độ tương đồng ngữ nghĩa. Điểm mạnh của phương pháp là giải quyết được bài toán từ đồng nghĩa so với ATS truyền thống. Tuy nhiên, hạn chế căn bản nằm ở chỗ vector embedding chỉ nắm bắt độ tương đồng tổng thể giữa hai đoạn văn bản mà không giải quyết được các quan hệ đa chiều cần thiết để xây dựng ngữ cảnh suy luận. Cụ thể, khi một nhà tuyển dụng cần truy vấn "tìm ứng viên từng làm việc tại công ty fintech, có kinh nghiệm xây dựng hệ thống xử lý dữ liệu thời gian thực", hệ thống vector thuần túy không thể liên kết các thực thể rời rạc - công ty, lĩnh vực, dự án, công nghệ - thành một chuỗi suy luận có cơ sở, dẫn đến kết quả không có căn cứ (ungrounded generation).

Hướng 2 - Đồ thị tri thức trong nhân sự (HR Knowledge Graph): Một số nghiên cứu đã đề xuất xây dựng Ontology cho thị trường lao động, tiêu biểu là ESCO (European Skills, Competences, Qualifications and Occupations) của Ủy ban Châu Âu [16], ánh xạ mối quan hệ giữa kỹ năng và vị trí công việc. Các hệ thống này biểu diễn tốt cấu trúc quan hệ kết nối giữa HR và nhân sự ở tầng Ontology, nhưng hạn chế cơ bản là chúng hoạt động như cơ sở tri thức tĩnh, đòi hỏi truy vấn bằng ngôn ngữ cấu trúc (Cypher/SPARQL), không hỗ trợ tương tác ngôn ngữ tự nhiên với người dùng cuối và thiếu cơ chế kiểm soát quyền truy cập dữ liệu cá nhân nhạy cảm.

Hướng 3 - GraphRAG tổng quát: Microsoft Research giới thiệu GraphRAG [1] như một kiến trúc lai tích hợp đồ thị tri thức vào luồng sinh văn bản của LLM, cải thiện đáng kể khả năng trả lời các câu hỏi đòi hỏi tổng hợp toàn cục (global queries). Tuy nhiên, GraphRAG được thiết kế cho dữ liệu văn bản tổng quát và chưa được tối ưu cho domain nhân sự với các ràng buộc đặc thù về bảo mật phân tầng (public/private data) hay bài toán phỏng vấn cá nhân hóa.

Hướng 4 - Bản sao số (Digital Twin) trong tuyển dụng: Khái niệm Digital Twin - tạo đại diện số phản chiếu đặc trưng của một cá nhân - đã được nghiên cứu trong các lĩnh vực y tế và giáo dục [15], nhưng ứng dụng vào tuyển dụng với kiểm soát truy cập theo vai trò (Role-based Access Control) vẫn là lĩnh vực còn mới mẻ và chưa có nhiều công bố học thuật.

Khoảng trống nghiên cứu: Từ phân tích trên, có thể xác định hai khoảng trống

mà đề tài này hướng đến lấp đầy. Thứ nhất, sự thiếu vắng một kiến trúc tích hợp sâu đồ thị tri thức nhân sự vào luồng sinh văn bản của LLM, kết hợp với hệ thống đa tác tử (Multi-Agent) phân tách các luồng nghiệp vụ - tìm kiếm ứng viên diện rộng và phỏng vấn cá nhân hóa - trong khi vẫn đảm bảo kiểm soát truy cập dữ liệu nhạy cảm ở tầng cấu trúc đồ thị. Thứ hai, chưa có nghiên cứu nào áp dụng kiến trúc GraphRAG vào bài toán phỏng vấn tự động bằng Digital Twin với cơ chế bảo mật privacy-by-design cho dữ liệu CV tiếng Việt trong lĩnh vực Công nghệ thông tin.

3. Mục tiêu đề tài

Mục tiêu tổng quát của đề tài là nghiên cứu, thiết kế và cài đặt thử nghiệm mô hình ORCHGRAPH-RAG nhằm tối ưu hóa quy trình truy xuất dữ liệu tuyển dụng và tạo ra các đại diện số (Digital Twin) hỗ trợ phỏng vấn.

Các mục tiêu cụ thể bao gồm:

- **Xây dựng kiến trúc lưu trữ Dual-DB (Đồ thị - Vector):** Kết hợp khả năng biểu diễn mối quan hệ của Graph DB (Neo4j) và khả năng tìm kiếm ngữ nghĩa của Vector DB để quản lý hồ sơ nhân sự theo kiến trúc phân tách bảo mật (Public/Private data).
- **Phát triển Master Agent điều phối minh bạch:** Phát triển Master Agent điều phối minh bạch: Xây dựng tác tử trung tâm có khả năng chuyển ngữ truy vấn tự nhiên, định tuyến và khai thác đồ thị tri thức để tìm kiếm ứng viên/công việc một cách có cơ sở, giảm thiểu ảo giác.
- **Tạo lập Digital Twin đại diện ứng viên:** Phát triển các tác tử cá nhân hóa mang đặc trưng tri thức của từng ứng viên (dựa trên dữ liệu CV), cho phép thực hiện các cuộc phỏng vấn sơ bộ tự động, tương tác và truy xuất thông tin hỏi đáp theo ngữ cảnh thực tế.

4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu: Dữ liệu văn bản phi cấu trúc trong miền nhân sự (Hồ sơ ứng viên - CV, Mô tả công việc - JD). Mạng lưới quan hệ thực thể: Tổ chức (Organization) - Nhân sự (Personnel) - Kỹ năng (Skills) - Học vấn (Education). Các phương pháp trích xuất thông tin (Information Extraction), kiến trúc GraphRAG và hệ thống Đa tác tử (Multi-Agent System).

Phạm vi nghiên cứu: Đề tài giới hạn thử nghiệm trên tập dữ liệu tổng hợp (synthetic dataset) thuộc lĩnh vực Công nghệ thông tin (IT/Software Engineering) để đảm bảo độ phức tạp về mặt công nghệ và kỹ năng. Mô hình tập trung vào việc đối chiếu tri thức, hỗ trợ sàng lọc và phỏng vấn vòng loại, không thay thế quyết định tuyển dụng cuối cùng của con người.

5. Phương pháp nghiên cứu

Để đạt được các mục tiêu đề ra, đề tài sử dụng kết hợp các phương pháp nghiên cứu sau:

- Phương pháp nghiên cứu lý thuyết: Khảo sát các tài liệu học thuật, nghiên cứu cấu trúc Ontology cho dữ liệu nhân sự, cơ chế hoạt động của GraphRAG và các rủi ro bảo mật trong quá trình tiêm dữ liệu (Data Ingestion) vào LLM.
- Phương pháp mô hình hóa và thực nghiệm: Thiết kế pipeline trích xuất dữ liệu tự động (One-Pass Classification có rào chắn luật cứng). Cài đặt môi trường thử nghiệm trên cơ sở dữ liệu Neo4j [17] và tích hợp các LLM (OpenAI/Anthropic ==[?]==) qua framework xây dựng tác tử.
- Phương pháp đánh giá và thống kê: Sử dụng các framework đánh giá tiêu chuẩn như RAGAS [6] để đo lường chất lượng truy xuất (Tính trung thực - Faithfulness, Độ liên quan - Answer Relevance). Tiến hành kiểm thử bảo mật (Privacy Evaluation) qua các kịch bản tấn công (Red-teaming) để định lượng độ an toàn của cơ chế phân tách dữ liệu.

6. Bố cục quyển báo cáo

Quyển báo cáo gồm có 3 phần chính là: Phần giới thiệu, Phần nội dung và Phần kết luận, cuối quyển báo cáo là phần Tài liệu tham khảo chứa những quyển sách, bài báo được trích dẫn trong báo cáo. Cụ thể phần bố cục được chia như sau:

- **Phần giới thiệu:** Trình bày các vấn đề hiện tại, các nghiên cứu liên quan, mục tiêu của đề tài, đối tượng và phạm vi nghiên cứu, cùng với phương pháp nghiên cứu được áp dụng.
- **Phần nội dung:**
 - + **Chương 1 – Mô tả bài toán:** Giới thiệu chi tiết về bài toán, bao gồm các kiến thức và framework cụ thể được sử dụng trong quá trình nghiên cứu đề tài.
 - + **Chương 2 – Thiết kế và cài đặt giải pháp:** Mô tả sơ lược về pipeline của hệ thống và kiến trúc của mô hình. Đồng thời mô tả phương pháp thu thập và tiền xử lý dữ liệu.
 - + **Chương 3 – Kiểm thử và đánh giá:** Trình bày giao diện sản phẩm và thực hiện đánh giá kết quả thực nghiệm của mô hình đề ra.
- **Phần kết luận:** Tóm tắt kết quả đạt được, nêu lên những hạn chế của đề tài và đề xuất hướng phát triển trong tương lai.
- **Tài liệu tham khảo:** Liệt kê các nguồn tài liệu được sử dụng trong quá trình nghiên cứu và thực hiện đề tài.

II. PHẦN NỘI DUNG

CHƯƠNG 1. MÔ TẢ BÀI TOÁN

1. Mô tả chi tiết bài toán

1.1. Bài toán tuyển dụng thông minh và truy xuất tri thức

Trong phạm vi hệ thống ORCHGRAPH-RAG, bài toán quản trị và khai thác tri thức nhân sự được mô hình hóa thành hai luồng bài toán con có tính nội kết cao, cùng chia sẻ một cơ sở tri thức thống nhất nhưng phục vụ những mục tiêu hoàn toàn khác biệt.

- **Bài toán đối sánh ứng viên:** Hệ thống tiếp nhận một yêu cầu tuyển dụng (JD – Job Description) phi cấu trúc viết bằng ngôn ngữ tự nhiên và trả về danh sách ứng viên xếp hạng theo mức độ phù hợp. Về bản chất, đây là bài toán tìm kiếm đồ thị con (subgraph matching) kết hợp đo lường độ tương đồng ngữ nghĩa: hệ thống cần bóc tách các thực thể yêu cầu (kỹ năng, thâm niên, lĩnh vực) từ JD rồi tìm kiếm trong cơ sở dữ liệu những ứng viên có cấu trúc tri thức tiệm cận nhất với yêu cầu đó. Khác với hệ thống ATS (Applicant Tracking System) truyền thống chỉ đếm từ khóa, hệ thống cần suy luận được các quan hệ ngầm định - ứng viên có kinh nghiệm "Spring Boot" hoàn toàn đáp ứng yêu cầu "Java Backend Framework" dù hai chuỗi ký tự không trùng khớp.
- **Bài toán phỏng vấn qua bản sao số:** Một tác tử AI đóng vai đại diện của ứng viên, nhận câu hỏi từ nhà tuyển dụng và sinh ra câu trả lời dựa hoàn toàn trên tri thức trong hồ sơ của người đó. Đây là bài toán hỏi đáp có truy xuất tăng cường (QA-RAG) với hai ràng buộc cốt lõi. Thứ nhất, ràng buộc trung thực (faithfulness): tác tử chỉ được phép sinh văn bản dựa trên tập ngữ cảnh (context window) xây dựng từ đồ thị cá nhân của ứng viên, không được suy diễn thêm từ kiến thức tham số của mô hình. Thứ hai, ràng buộc bảo mật (privacy): hệ thống phải kiểm soát phân quyền truy cập theo cấu trúc quan hệ (Relationship-based Access Control – ReBAC) [13], đảm bảo các thông tin nhạy cảm như mức lương kỳ vọng hay bí mật kỹ thuật dự án không bị rò rỉ trong quá trình tổng hợp của mô hình ngôn ngữ lớn (LLM).

Mục tiêu cốt lõi của đề tài là xây dựng một kiến trúc tích hợp giải quyết đồng thời cả hai luồng bài toán trên thông qua sự kết hợp giữa đồ thị tri thức nhân sự và cơ chế truy xuất tăng cường dựa trên đồ thị, đảm bảo mọi kết quả đầu ra đều có khả năng truy vết về nguồn dữ liệu gốc.

1.2. Ứng dụng Web

Để minh chứng tính thực tiễn của mô hình nghiên cứu và hỗ trợ người dùng trong việc tương tác với hệ thống, đề tài triển khai ứng dụng web ORCHGRAPH-RAG phục vụ hai nhóm người dùng với luồng tương tác khác nhau.

Hệ thống được thiết kế không chỉ để đưa ra kết quả đề xuất mà còn hướng tới tính minh bạch (explainability), giúp người dùng hiểu được cơ sở của từng quyết

định thông qua trực quan hóa đồ thị tri thức. Cụ thể, ứng dụng hỗ trợ linh hoạt ba kịch bản sử dụng chính:

- **Chức năng 1 – Tìm kiếm ứng viên:** Người dùng thuộc nhóm tổ chức nhập yêu cầu tuyển dụng bằng ngôn ngữ tự nhiên. Hệ thống thực hiện tìm kiếm hybrid kết hợp tín hiệu từ đồ thị kỹ năng và tín hiệu ngữ nghĩa từ vector embedding, trả về danh sách ứng viên kèm điểm số và phân giải thích có truy vết về cấu trúc đồ thị. Nhờ cơ chế này, nhà tuyển dụng không chỉ biết ai phù hợp mà còn biết tại sao người đó phù hợp.
- **Chức năng 2 – Phỏng vấn bản sao số:** Tổ chức có thể khởi tạo một phiên hội thoại với bản sao số của ứng viên thông qua giao diện chat streaming thời gian thực. Tác tử AI đóng vai ứng viên và chỉ trả lời trong phạm vi thông tin có trong hồ sơ. Ở chế độ công khai (khi chưa có kết nối được chấp thuận), tác tử chỉ truy cập dữ liệu công khai; sau khi ứng viên cấp quyền, toàn bộ vault dữ liệu riêng tư mới được mở khóa.
- **Chức năng 3 – Quản lý lịch hẹn:** Sau khi đánh giá sơ bộ qua bản sao số, nhà tuyển dụng có thể đặt lịch phỏng vấn thực trực tiếp trong ứng dụng. Hệ thống hỗ trợ đồng bộ lịch rảnh của ứng viên, gửi xác nhận qua email và đẩy thông báo thời gian thực qua Supabase Realtime [18].

2. Vấn đề giải pháp liên quan đến bài toán

2.1. Mô hình ngôn ngữ lớn và giao tiếp streaming

Mô hình ngôn ngữ lớn (Large Language Model – LLM) là các mạng nơ-ron Transformer [7] được huấn luyện trên lượng dữ liệu văn bản khổng lồ theo mục tiêu dự đoán token tiếp theo trong chuỗi. Với số lượng tham số từ hàng tỷ đến hàng nghìn tỷ, LLM có khả năng mã hóa kiến thức ngôn ngữ và thế giới ở mức độ sâu, cho phép thực hiện nhiều tác vụ khác nhau chỉ thông qua mô tả tự nhiên trong prompt mà không cần tinh chỉnh lại mô hình (zero-shot và few-shot prompting).


Tính chất sinh tạo xác suất (probabilistic generation) của LLM - trong đó mỗi token được chọn theo phân phối xác suất trên toàn bộ từ vựng - là nguồn gốc của hiện tượng ảo giác (hallucination), tức là mô hình có thể sinh ra những phát biểu nghe có vẻ hợp lý nhưng thực tế không chính xác. Tham số nhiệt độ (temperature) kiểm soát mức độ "sáng tạo" của quá trình sinh: nhiệt độ bằng 0 buộc mô hình luôn chọn token có xác suất cao nhất, tạo ra đầu ra rất định và ít ảo giác nhất; nhiệt độ cao làm phẳng phân phối xác suất, tăng tính đa dạng nhưng cũng tăng nguy cơ ảo giác. Trong các ứng dụng đòi hỏi tương tác thời gian thực, giao tiếp streaming là kỹ

thuật quan trọng giúp cải thiện trải nghiệm người dùng. Thay vì chờ toàn bộ phản hồi được sinh xong rồi mới trả về (có thể mất nhiều giây với các câu trả lời dài), máy chủ truyền từng token ngay khi được sinh ra thông qua cơ chế Server-Sent Events (SSE) hoặc WebSocket. Phía giao diện nhận và hiển thị lũy tiến, tạo cảm giác phản hồi tức thì tương tự như đang trò chuyện với người thật. Về mặt kiến trúc, điều này đòi hỏi máy chủ phải hỗ trợ xử lý bất đồng bộ (asynchronous I/O) để duy trì nhiều kết nối streaming song song mà không chặn luồng thực thi.

2.2. Mô hình nhúng đa ngôn ngữ


Mô hình nhúng (Embedding Model) là các mô hình học sâu có nhiệm vụ ánh xạ văn bản - từ, câu, hoặc đoạn văn - thành các vector số thực trong không gian nhiều chiều, sao cho các văn bản có ngữ nghĩa tương đồng sẽ nằm gần nhau về mặt hình học. Khác với các phương pháp truyền thống như Bag-of-Words hay TF-IDF chỉ dựa trên tần suất từ, các mô hình nhúng hiện đại dựa trên kiến trúc Transformer nắm bắt được ngữ nghĩa trong ngữ cảnh, tức là cùng một từ có thể được nhúng thành các vector khác nhau tùy theo văn cảnh xuất hiện. Sentence-BERT (SBERT) do

Reimers và Gurevych [9] giới thiệu là một sửa đổi quan trọng của kiến trúc BERT gốc, được tối ưu hóa đặc biệt cho tác vụ tạo vector biểu diễn ở cấp độ câu. SBERT sử dụng kiến trúc Siamese - hai nhánh encoder dùng chung trọng số - kết hợp với cơ chế Mean Pooling để nén thông tin toàn bộ câu thành một vector cố định. Quá trình huấn luyện tối ưu hóa hàm mất mát tương đồng (như Cosine Similarity Loss hoặc Triplet Loss) để kéo vector của các câu có ngữ nghĩa giống nhau lại gần và đẩy các câu khác nghĩa ra xa, tạo ra không gian nhúng có tính phân tách ngữ nghĩa cao.



Hình 1. Minh họa kiến trúc cơ bản của SBERT

Đối với dữ liệu văn bản đa ngôn ngữ - đặc biệt là các tài liệu tiếng Việt có xen lẫn thuật ngữ kỹ thuật tiếng Anh - yêu cầu đặt ra với mô hình nhúng không chỉ là hiểu ngữ nghĩa đơn ngữ mà còn phải có khả năng căn chỉnh đa ngôn ngữ (cross-lingual alignment), tức là ánh xạ các cụm từ cùng nghĩa trong hai ngôn ngữ khác nhau về cùng một vùng lân cận trong không gian vector. Các mô hình như multilingual-E5 [3], GTE-multilingual [4] và BGE-M3 [5] được huấn luyện trên dữ liệu song ngữ quy mô lớn theo mục tiêu này, và thường vượt trội so với các mô hình đơn ngữ khi xử lý các văn bản kỹ thuật có từ vựng pha trộn.



Hình 2. Minh họa kiến trúc cơ bản của mô hình nhúng đa ngôn ngữ (tiếng Anh - màu xanh và tiếng Đức - màu hồng)


2.3. Cơ sở dữ liệu vector và pgvector

Cơ sở dữ liệu vector (Vector Database) là hệ thống được thiết kế để lưu trữ và tìm kiếm hiệu quả các vector số thực có số chiều cao, thường thông qua các thuật toán tìm kiếm lân cận gần đúng (Approximate Nearest Neighbor – ANN). Thay vì so sánh chính xác từng cặp vector có độ phức tạp cao, ANN đánh đổi một phần độ chính xác để giảm đáng kể chi phí tính toán thông qua các cấu trúc dữ liệu chỉ mục như HNSW (Hierarchical Navigable Small World) hay IVF (Inverted File Index), cho phép tìm kiếm trong hàng triệu vector chỉ trong vài mili giây.



Hình 3. Quy trình hoạt động cơ bản của một cơ sở dữ liệu vector


Lập chỉ mục (Indexing): Sau khi chuyển đổi dữ liệu thô thành các vector (embeddings), cơ sở dữ liệu vector sắp xếp các vector này bằng các thuật toán ANN để hỗ trợ tìm kiếm nhanh.



Hình 4. Minh họa cấu trúc đồ thị đa tầng (trái) và cơ chế chọn lân cận heuristic (phải) của thuật toán HNSW dùng trong tìm kiếm ANN

Truy vấn (Querying): Cơ sở dữ liệu vector so sánh vector truy vấn với các vector trong tập dữ liệu bằng một độ đo tương đồng được chỉ định trước để tìm các vector gần nhất.


Hậu xử lý (Post-Processing): Hệ thống có thể áp dụng thêm các bộ lọc metadata hoặc tái xếp hạng để tạo kết quả cuối cùng phù hợp hơn.



Hình 5. Sơ đồ đường đi cho quá trình lưu trữ trong cơ sở dữ liệu vector

Giai đoạn truy vấn trong cơ sở dữ liệu vector bao gồm việc nhập dữ liệu cần so khớp, chẳng hạn như một bức ảnh sẽ được so sánh với các ảnh khác. Đồng thời, bộ lọc metadata có thể được áp dụng để loại bỏ các kết quả có đặc điểm không mong muốn, ví dụ như loại bỏ hình ảnh váy có màu cụ thể. Bộ lọc này có thể được thực hiện trước hoặc sau khi tìm kiếm tương đồng. Dữ liệu được xử lý bằng mô hình đã sử dụng để lưu trữ, và hệ thống sẽ trả về các kết quả gần giống nhất dựa trên độ

tương đồng.




Hình 6. Sơ đồ đường đi cho quá trình truy vấn trong cơ sở dữ liệu vector

Thước đo phổ biến để đánh giá độ tương đồng giữa hai vector trong không gian nhúng là độ tương đồng cosine:

$$S_{\text{vector}}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \cdot \|\mathbf{v}\|}$$

Giá trị này nằm trong khoảng $[-1, 1]$, trong đó giá trị tiệm cận 1 biểu thị hai vector gần như cùng hướng, tức hai đoạn văn bản có ngữ nghĩa tương đồng cao.




Hình 7. Minh họa việc sử dụng độ tương đồng cosine để đo lường khoảng cách ngữ nghĩa giữa các câu trong không gian vector

pgvector là phần mở rộng mã nguồn mở của PostgreSQL, cung cấp kiểu dữ liệu vector và các toán tử tìm kiếm ANN trực tiếp trong cơ sở dữ liệu quan hệ. So với các hệ thống vector độc lập (như Pinecone hay Weaviate), pgvector có lợi thế tận dụng hệ sinh thái PostgreSQL hiện có: giao dịch ACID, Row Level Security (RLS), và khả năng kết hợp truy vấn vector với điều kiện lọc quan hệ trong cùng một câu lệnh SQL.

2.4. Đồ thị tri thức và cơ sở dữ liệu đồ thị Neo4j


Đồ thị tri thức (Knowledge Graph) là một cấu trúc dữ liệu biểu diễn thế giới thực dưới dạng mạng lưới các thực thể và mối quan hệ giữa chúng. Về mặt hình thức, một đồ thị tri thức $G = (V, E)$ được đặc trưng bởi tập đỉnh V đại diện cho các thực thể (như con người, tổ chức, kỹ năng, dự án) và tập cạnh $E \subseteq V \times R \times V$, trong đó R là tập nhãn quan hệ có ngữ nghĩa. Khác với cơ sở dữ liệu quan hệ (RDBMS) phải thực hiện phép kết nối (JOIN) tốn kém khi duyệt nhiều bảng, đồ thị tri thức lưu trữ trực tiếp các liên kết đến đỉnh lân cận, cho phép duyệt cạnh hiệu quả khi thực hiện truy vấn nhiều bước (multi-hop).



Hình 8. Cấu trúc đồ thị tri thức

Mô hình Property Graph là một trong những chuẩn biểu diễn phổ biến nhất của đồ thị tri thức trong thực tế, trong đó cả đỉnh lẫn cạnh đều có thể mang các thuộc tính bổ sung dưới dạng cặp khóa-giá trị. Điều này cho phép mã hóa thông tin ngữ nghĩa phong phú trực tiếp trên cấu trúc đồ thị mà không cần các bảng phụ trợ hay bảng ánh xạ trung gian. Neo4j là hệ quản trị cơ sở dữ liệu đồ thị (Graph DBMS)

theo mô hình Property Graph. Neo4j sử dụng ngôn ngữ truy vấn Cypher, được thiết kế để biểu diễn các mẫu quan hệ (relationship patterns) một cách trực quan [17]. Cú pháp của Cypher cho phép mô tả các truy vấn multi-hop phức tạp trong một biểu thức ngắn gọn và dễ đọc, trong khi SQL thường cần nhiều tầng lồng nhau hoặc đệ quy. Ngoài khả năng truy vấn đồ thị, các phiên bản hiện đại của Neo4j còn hỗ trợ lưu trữ vector embedding trực tiếp như một thuộc tính của đỉnh, kết hợp với chỉ mục vector để thực hiện ANN Search ngay trong đồ thị.



Hình 9. Minh họa mô hình đồ thị thuộc tính trong Neo4j

2.5. Nền tảng lưu trữ và đồng bộ dữ liệu Supabase

Supabase là một nền tảng backend-as-a-service xây dựng trên PostgreSQL, cung cấp đồng thời cơ sở dữ liệu quan hệ, cơ chế xác thực người dùng, API tự sinh và kênh đồng bộ thời gian thực. Trong bối cảnh các ứng dụng AI cần vừa lưu trữ dữ liệu cấu trúc vừa hỗ trợ truy vấn ngữ nghĩa, Supabase cho phép kết hợp linh hoạt giữa bảng quan hệ truyền thống, Row Level Security (RLS) và các tiện ích mở rộng như pgvector để lưu trữ vector embedding ngay trong cùng một hệ quản trị [18].

Một ưu điểm quan trọng của Supabase là cơ chế Realtime, cho phép hệ thống phát sinh và lắng nghe các sự kiện thay đổi dữ liệu gần như tức thì mà không cần tự triển khai tầng WebSocket riêng. Điều này đặc biệt hữu ích cho các tác vụ như thông báo, cập nhật trạng thái hoặc đồng bộ lịch hẹn, nơi giao diện cần phản ánh thay đổi dữ liệu ngay sau khi có thao tác từ phía máy chủ. Bên cạnh đó, việc giữ dữ liệu riêng tư trong PostgreSQL và áp dụng RLS ở mức dòng giúp kiểm soát truy cập chi tiết hơn so với việc chỉ dựa vào tầng ứng dụng.

2.6. Tìm kiếm kết hợp

Tìm kiếm kết hợp là kỹ thuật kết hợp nhiều tín hiệu truy xuất có bản chất khác nhau để tận dụng ưu điểm của từng tín hiệu trong khi bù đắp điểm yếu của nhau. Trong bối cảnh tìm kiếm văn bản, hai tín hiệu phổ biến nhất thường được kết hợp là tín hiệu thưa (sparse retrieval) và tín hiệu dày (dense retrieval). Tín hiệu thưa dựa trên sự trùng khớp từ khóa chính xác, tiêu biểu là BM25 hoặc Jaccard. Tín hiệu này cho độ chính xác cao khi truy vấn chứa các từ khóa tường minh, nhưng dễ bỏ sót các trường hợp tương đương ngữ nghĩa. Ngược lại, tín hiệu dày dựa trên embedding vector bắt được quan hệ ngữ nghĩa ngầm định và từ đồng nghĩa, nhưng có thể kém chính xác khi truy vấn cần khớp với thực thể rất cụ thể. Điểm tổng hợp cuối cùng trong Tìm kiếm Kết hợp thường được tính theo hàm kết hợp tuyến tính có trọng số:

$$S_{\text{final}}(c) = \alpha \cdot S_{\text{sparse}}(c, q) + \beta \cdot S_{\text{dense}}(c, q), \quad \alpha + \beta = 1$$

trong đó α và β là các siêu tham số điều chỉnh mức độ ưu tiên tương đối giữa hai tín hiệu. Một kỹ thuật phổ biến để chuẩn hóa và kết hợp các tín hiệu từ nhiều nguồn có thang điểm khác nhau là Reciprocal Rank Fusion (RRF), trong đó mỗi tài liệu được gán điểm dựa trên thứ hạng trong từng danh sách kết quả thay vì điểm tuyệt đối.

2.7. Mô hình số cá nhân (AI Digital Twin)

Bản sao số (Digital Twin) là khái niệm chỉ một đại diện số phản chiếu trạng thái và đặc trưng của một thực thể thực trong thế giới vật lý – có thể là con người, thiết bị, quy trình hoặc hệ thống – được đồng bộ hóa liên tục thông qua dữ liệu từ thực thể gốc. Khái niệm này ban đầu xuất phát từ lĩnh vực kỹ thuật công nghiệp, sau đó được mở rộng sang các lĩnh vực y tế, giáo dục và quản trị nhân sự [15].

Trong bối cảnh AI hiện đại, AI Digital Twin của một cá nhân là một tác tử LLM được neo (grounded) chặt chẽ vào một tập ngữ cảnh được xây dựng từ dữ liệu thực của người đó, thay vì dựa vào kiến thức tham số chung của mô hình. Điểm then

chốt về mặt kỹ thuật là tác tử này phải tuân thủ hai ràng buộc cốt lõi. Ràng buộc thứ nhất là tính trung thực (Faithfulness): mọi câu trả lời sinh ra phải có thể truy vết trực tiếp về nguồn dữ liệu gốc trong tập ngữ cảnh, tác tử không được suy diễn hay bổ sung thông tin từ kiến thức tham số của mô hình. Ràng buộc thứ hai là tính riêng tư (Privacy): tập ngữ cảnh cấp cho tác tử phải được kiểm soát chặt chẽ theo quyền truy cập của người dùng hiện tại, đảm bảo thông tin nhạy cảm không bị lộ ngay cả khi hệ thống bị tấn công bằng các kỹ thuật khai thác prompt (prompt injection, jailbreak) [15].

Để đạt được tính trung thực, một kỹ thuật phổ biến là kết hợp cấu hình tham số nhiệt độ thấp (temperature = 0, buộc mô hình chọn token có xác suất cao nhất) với các lệnh ức chế ngữ nghĩa (Inhibitor Commands) tường minh trong system prompt, yêu cầu mô hình chỉ phản hồi dựa trên ngữ cảnh được cung cấp và từ chối trả lời khi thông tin không có trong đó.

2.8. Framework backend FastAPI và frontend Next.js

FastAPI là framework Python hiện đại xây dựng trên chuẩn ASGI (Asynchronous Server Gateway Interface), cho phép xử lý nhiều yêu cầu đồng thời theo mô hình bất đồng bộ (async/await) mà không chặn luồng thực thi [19]. Đặc tính này quan trọng đối với các ứng dụng AI, nơi một yêu cầu có thể phải chờ phản hồi từ LLM trong vài giây trong khi hệ thống vẫn cần phục vụ các yêu cầu khác song song. FastAPI tự động sinh tài liệu API theo chuẩn OpenAPI (Swagger UI) từ các khai báo kiểu dữ liệu Python, đồng thời tích hợp tự nhiên với hệ sinh thái thư viện học máy (PyTorch, Transformers, LangChain,...) mà không cần tầng giao tiếp trung gian. Next.js là framework React cho phép xây dựng ứng dụng web theo kiến trúc

kết hợp giữa Server-Side Rendering (SSR) và Client-Side Rendering (CSR). Với App Router trong các phiên bản gần đây, Next.js phân biệt rõ ràng giữa Server Components - được render ở phía máy chủ, thân thiện với SEO và hiệu năng tải trang ban đầu - và Client Components - được hydrate ở phía trình duyệt để xử lý tương tác người dùng động như streaming chat hay trực quan hóa đồ thị. Cơ chế middleware của Next.js cho phép thực hiện xác thực và kiểm tra phiên làm việc trước khi request được chuyển đến bất kỳ trang hay API nào, giúp bảo vệ toàn bộ nhóm route cần xác thực chỉ với một điểm kiểm soát duy nhất.

2.9. Thang đo đánh giá hệ thống RAG (RAGAS)

Đánh giá chất lượng hệ thống RAG đòi hỏi hai nhóm chỉ số riêng biệt vì truy xuất và sinh văn bản là hai bài toán có tiêu chí thành công khác nhau. Về chất lượng truy xuất, ba chỉ số phổ biến là $MRR@k$ (Mean Reciprocal Rank), $Recall@k$ và $NDCG@k$ (Normalized Discounted Cumulative Gain). $MRR@k$ đo chất lượng xếp hạng thông qua nghịch đảo thứ hạng của tài liệu đúng đầu tiên, được tính trung bình trên tập truy vấn:

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{rank_i}$$

$\text{Recall}@k$ đo tỉ lệ tài liệu đúng xuất hiện trong top- k kết quả trả về. $\text{NDCG}@k$ tính thêm yếu tố vị trí của tài liệu đúng, trong đó tài liệu đúng ở vị trí cao được thưởng điểm lớn hơn:

$$\text{NDCG}@k = \frac{\text{DCG}@k}{\text{IDCG}@k}, \quad \text{DCG}@k = \sum_{i=1}^k \frac{\text{rel}_i}{\log_2(i+1)}$$


Về chất lượng sinh văn bản, framework RAGAS do Es và cộng sự [6] giới thiệu sử dụng LLM đóng vai trò người đánh giá (LLM-as-judge) để tự động hóa quá trình kiểm định mà không cần tập ground truth tuyệt đối. Bốn chỉ số trọng tâm bao gồm: Faithfulness, Answer Relevancy, Context Precision và Context Recall.

CHƯƠNG 2. THIẾT KẾ VÀ CÀI ĐẶT GIẢI PHÁP

1. Thiết kế hệ thống

Quy trình tổng quát của hệ thống ORCHGRAPH-RAG được minh họa tại Hình 10, bao gồm bốn giai đoạn xử lý tuần tự liên kết với nhau: (1) Nhập liệu và tiền xử lý, (2) Xây dựng kho tri thức, (3) Định tuyến và truy vấn, và (4) Tổng hợp kết quả. Kiến trúc được thiết kế theo hai luồng nghiệp vụ độc lập: tìm kiếm ứng viên và phỏng vấn bản sao số nhưng dùng chung một nền tảng tri thức.

Đặc tả dữ liệu đầu vào (INPUT): Hệ thống tiếp nhận hai loại dữ liệu chính. Hồ sơ ứng viên được cung cấp dưới dạng tệp có định dạng .pdf, .docx, .txt hoặc .md. Truy vấn người dùng được nhập dưới dạng văn bản tự nhiên, bao gồm mô tả công việc (JD) hoặc câu hỏi phỏng vấn. Hệ thống được thiết kế với cơ chế chấp nhận thiếu hụt, cho phép hoạt động ngay cả khi người dùng không cung cấp đầy đủ thông tin.



Hình 10. Luồng xử lý tổng quát của hệ thống khi triển khai thành ứng dụng

Đặc tả dữ liệu đầu ra (OUTPUT): Tùy theo luồng nghiệp vụ, hệ thống trả về một trong hai loại kết quả: danh sách ứng viên xếp hạng kèm chuỗi lý giải có thể truy vết, hoặc câu trả lời phỏng vấn theo thời gian thực có căn cứ từ đồ thị tri thức cá nhân của ứng viên.

Chi tiết bốn giai đoạn xử lý được trình bày như sau:

- **Giai đoạn 1 – Nhập liệu và tiền xử lý (Ingestion Agent):** Hồ sơ ứng viên thô được xử lý tuần tự qua năm bước – phân tích định dạng, làm sạch văn bản, chia đoạn, trích xuất thực thể theo lược đồ RecruitmentNode, và vector hoá đa trường.
- **Giai đoạn 2 – Xây dựng kho tri thức (Dual-DB):** Dữ liệu sau khi xử lý được ghi song song lên Neo4j (dữ liệu công khai dạng đồ thị có hướng) và Supabase/pgvector (dữ liệu riêng tư và vector nhúng). Hai hệ thống tạo thành luồng truy xuất khép kín được mô tả chi tiết ở mục 1.2.

- **Giai đoạn 3 – Định tuyến và truy vấn (Orchestrator Agent):** Khi nhận truy vấn đầu vào, bộ định tuyến phân loại ý định và chuyển sang Tác tử tìm kiếm hoặc Tác tử bản sao số. Tác tử tìm kiếm kết hợp điểm đồ thị và điểm vector nhúng theo công thức:


$$S_{\text{final}}(c) = \alpha \cdot S_{\text{graph}}(c, q) + \beta \cdot S_{\text{vector}}(c, q), \quad \alpha = 0,2, \beta = 0,8 \quad (.1)$$


- **Giai đoạn 4 – Tổng hợp kết quả (Output):** Kết quả được trả về qua giao diện web. Luồng tìm kiếm hiển thị danh sách ứng viên xếp hạng kèm lý giải có truy vết về từng nút và cạnh cụ thể trên đồ thị. Luồng phỏng vấn truyền từng đoạn phản hồi theo thời gian thực qua kết nối WebSocket.

1.1. Mô hình lưu trữ song song (Dual-DB)

Thách thức thiết kế trung tâm của hệ thống là đồng thời đáp ứng ba yêu cầu có tính mâu thuẫn nhau: tìm kiếm ngữ nghĩa linh hoạt dựa trên vector nhúng, suy luận quan hệ có cấu trúc dựa trên duyệt đồ thị, và kiểm soát bảo mật dữ liệu cá nhân ở mức chi tiết theo từng trường. Không có hệ quản trị cơ sở dữ liệu đơn lẻ nào đáp ứng tốt cả ba yêu cầu này cùng lúc. Giải pháp được lựa chọn là kiến trúc lưu trữ

song song theo nguyên lý lưu trữ đa hệ thống (Polyglot Persistence): mỗi loại dữ liệu được lưu trong hệ thống phù hợp nhất với đặc tính của nó, thay vì ép tất cả vào một kho lưu trữ thống nhất. Kiến trúc tổng thể được minh họa tại Hình 11; nguyên lý phân tách công khai/riêng tư được thể hiện tại Hình 12.





Hình 12. Sơ đồ nguyên lý Polyglot Persistence

Hai lớp lưu trữ đảm nhận các vai trò kỹ thuật riêng biệt, được mô tả như sau:

- **Neo4j – Lớp lưu trữ cấu trúc công khai:** Neo4j đảm nhiệm toàn bộ dữ liệu công khai dưới dạng đồ thị có hướng. Các thực thể Personnel, Organization, Skill, Project, Education được biểu diễn là các nút mang nhãn và thuộc tính; các mối quan hệ HAS_SKILL, WORKED_AT, PARTICIPATED_IN, CONNECTED_TO là các cạnh. Neo4j được chọn vì hai lý do kỹ thuật cốt lõi. Thứ nhất, phép duyệt cạnh trực tiếp có độ phức tạp $O(1)$ bất kể kích thước đồ thị, cho phép thực hiện các truy vấn multi-hop hiệu quả hơn cơ sở dữ liệu quan hệ đòi hỏi phép kết nối (JOIN) tốn kém. Thứ hai, ngôn ngữ Cypher cho phép biểu diễn các truy vấn duyệt nhiều bước một cách trực quan trong một biểu thức ngắn gọn. Ngoài ra, Neo4j còn lưu trữ vector nhúng cấp thực thể (node-level vector) của từng ứng viên để phục vụ bước lọc thô ban đầu trong luồng tìm

kiểm [17].

- **Supabase/pgvector – Lớp lưu trữ ngữ nghĩa và riêng tư:** Supabase/pgvector quản lý hai loại dữ liệu. Thứ nhất, các đoạn văn bản (chunks) đã được vector hoá ở mức độ chi tiết (chunk-level) phục vụ tái xếp hạng ngữ nghĩa (re-ranking) sau bước lọc thô từ Neo4j. Thứ hai, kho dữ liệu riêng tư chứa thông tin nhạy cảm của từng ứng viên như lương kỳ vọng, thông tin liên hệ và bí mật kỹ thuật dự án. Cơ chế Row Level Security (RLS) của PostgreSQL áp dụng chính sách bảo mật tự động ở mức dòng dữ liệu dựa trên danh tính người dùng, đảm bảo dữ liệu riêng tư chỉ được truy xuất khi có quyền hạn hợp lệ được xác thực từ đồ thị. Supabase Realtime cung cấp cơ chế đăng ký/phát sóng (pub/sub) cho hệ thống thông báo mà không cần thêm thành phần trung gian riêng [18].


Hai lớp này tạo thành một luồng truy xuất hai tầng: hệ thống trước tiên truy hồi sơ bộ thông qua chỉ mục vector cấp thực thể trên Neo4j để lọc nhanh danh sách ứng viên tiềm năng (coarse filter); tiếp theo, hệ thống phân tán yêu cầu (fan-out) sang kho đoạn văn bản trên Supabase để lấy tín hiệu tương đồng chi tiết, sau đó hợp nhất và tái xếp hạng danh sách (fine-grained re-ranking). Chiến lược này vừa đảm bảo tốc độ lọc thô, vừa giữ được chất lượng đối sánh ngữ nghĩa ở cấp độ hạt mịn, khắc phục hạn chế của RAG thông thường khi chuỗi chia đoạn làm đứt gãy các quan hệ cấu trúc.

Đặc biệt, hệ thống duy trì ranh giới dữ liệu nghiêm ngặt theo ngữ cảnh nghiệp vụ: trong tác vụ Tìm kiếm, hệ thống chỉ truy cập các chunk công khai; trong tác vụ Phỏng vấn Bản sao số, dữ liệu riêng tư chỉ được đưa vào ngữ cảnh của mô hình ngôn ngữ khi và chỉ khi cạnh uỷ quyền (access-control edge) giữa tổ chức và ứng viên được xác thực hợp lệ trên đồ thị.


1.2. Pipeline nhập liệu CV tiếng Việt

Pipeline nhập liệu là cầu nối giữa CV phi cấu trúc và kiến trúc lưu trữ song song. Thiết kế pipeline ưu tiên ba mục tiêu: giảm thất thoát thông tin qua các bước biến đổi; phân tách dữ liệu công khai và riêng tư ngay từ bước trích xuất; và duy trì khả năng xử lý đa định dạng nhờ cơ chế dự phòng nhiều tầng.

Pipeline gồm sáu bước nối tiếp, được phân chia thành hai nhóm chức năng và minh hoạ tại Hình 13 (nhóm tiền xử lý) và Hình 14 (nhóm trích xuất và ghi dữ liệu).



Hình 13. Luồng tiền xử lý dữ liệu



- **Bước 1 – Phân tích định dạng (Parse):** CV thô được chuyển thành luồng văn bản tuyển tính định dạng Markdown. Hệ thống sử dụng chuỗi bộ phân tích dự phòng ba tầng: LlamaParse xử lý tốt nhất các bố cục phức tạp như bảng và chia cột; nếu LlamaParse quá thời gian hoặc thất bại, unstructured đảm nhận với chi phí thấp hơn; Nutrient API là tầng cuối cho các tệp khó đọc. Tệp .json bỏ qua toàn bộ chuỗi này vì đã có cấu trúc sẵn và được nạp trực tiếp (direct ingestion).
- **Bước 2 – Làm sạch văn bản (Clean):** Văn bản thô thường chứa nhiều gồm ký tự rác từ mã hoá, khoảng trắng thừa và dấu câu lặp. Bộ làm sạch dùng biểu thức chính quy để loại bỏ nhiễu mà không làm mất ký tự tiếng Việt, được kiểm soát qua chỉ số tỉ lệ ký tự tiếng Việt trước và sau khi làm sạch.
- **Bước 3 – Chia đoạn (Chunk):** Văn bản sạch được chia thành các đoạn với kích thước tối đa 7.000 ký tự và vùng chồng lấp 400 ký tự giữa hai đoạn liên kề. Vùng chồng lấp đảm bảo thông tin tại ranh giới không bị mất khi mô hình ngôn ngữ xử lý từng đoạn độc lập.
- **Bước 4 – Trích xuất thực thể (Extract):** Mỗi đoạn được đưa vào mô hình ngôn ngữ (gpt-4o-mini, nhiệt độ sinh = 0) để trích xuất thực thể theo lược đồ RecruitmentNode. Đầu ra phải là JSON hợp lệ, được kiểm tra qua Pydantic. Với CV dài nhiều đoạn, hàm `extract_knowledge()` đóng vai trò tầng Map để tạo các phần JSON rời rạc; hàm `_merge_extracted_chunks()` đóng vai trò tầng Reduce để hợp nhất thành payload chuẩn hoàn chỉnh. Ngoài ra, anchor regex được áp dụng để tăng tính quyết định cho các trường định danh và liên hệ.
- **Bước 5 – Vector hoá (Vectorize):** RecruitmentNode được vector hoá theo chiến lược đa trường – các trường `professional_summary`, `skills` và `experience` được nhúng thành vector riêng biệt, cho phép tìm kiếm ngữ nghĩa có trọng số theo từng khía cạnh của hồ sơ.
- **Bước 6 – Ghi song song (Dual-write):** Dữ liệu được ghi tuần tự lên Neo4j trước, sau đó lên Supabase. Neo4j lưu lớp cấu trúc đồ thị và vector cấp thực thể; Supabase lưu hồ sơ, chunks và embeddings cấp đoạn. Nếu ghi Neo4j thành công nhưng Supabase lỗi, pipeline ghi cảnh báo và không rollback Neo4j để tránh mất dữ liệu cấu trúc đã được trích xuất.

1.3. Lược đồ tri thức RecruitmentNode

RecruitmentNode là hợp đồng dữ liệu trung tâm của toàn hệ thống – mọi CV sau khi qua pipeline đều phải tuân thủ lược đồ này. Được hiện thực bằng Pydantic BaseModel trong `pipeline/schemas.py`, lược đồ đóng vai trò kép: vừa là ràng buộc đầu ra của bước trích xuất thực thể, vừa là bản đồ phân tách dữ liệu công khai và riêng tư. Nguyên tắc thiết kế cốt lõi là ranh giới bảo mật phải nằm ở tầng dữ

liệu, không phải tầng ứng dụng. Ngay từ lúc trích xuất, mỗi trường đã được gán rõ ràng vào một trong hai phân vùng – không có vùng xám. Một trường đã khai báo là riêng tư sẽ không bao giờ xuất hiện trong Neo4j, bất kể logic ứng dụng phía trên có gì.

Bảng 1. Bảng 4. Phân tách trường dữ liệu Public/Private trong RecruitmentNode

Trường công khai (Public → Neo4j)	Trường riêng tư (Private → Supabase)
full_name	contact.email
professional_summary	contact.phone
skills	contact.github / linkedin
experience (tên dự án, công ty)	salary_expectation
education	blacklist_orgs
certificates	project_technical_secrets
is_available	interview_questions_history
cultural_tags	evidence_links / additional_information


Bên cạnh phân tách, lược đồ áp dụng các luật chuẩn hóa cứng chạy độc lập sau bước trích xuất.

Bảng 2. Bảng 5. Các luật chuẩn hóa cứng áp dụng sau bước trích xuất thực thể

Trường áp dụng	Luật chuẩn hóa
skills	Toàn bộ tên kỹ năng ép về chữ thường để tránh bùng nổ nút trùng lặp trong Neo4j (ví dụ: “Python” → “python”).
is_available	Chuyển đổi từ mọi biểu đạt tự nhiên tiếng Việt (“Đang tìm việc”, “Open to offers”...) về kiểu logic nhị phân (true/false).
education.graduation_year	Ép về kiểu số nguyên 4 chữ số; loại bỏ định dạng không hợp lệ.

1.4. Cơ chế tìm kiếm kết hợp (Hybrid Search Engine)

Tác tử điều phối trung tâm nhận truy vấn tuyển dụng bằng ngôn ngữ tự nhiên và trả về danh sách ứng viên xếp hạng kèm lý giải. Khác với các hệ thống RAG truyền thống xử lý truy vấn theo một luồng cố định, hệ thống triển khai cơ chế tìm kiếm kết hợp hai tầng, hội tụ tín hiệu từ cả cơ sở dữ liệu đồ thị và kho vector phân mảnh [17, 18].



Hình 15. Kiến trúc Hybrid Query Engine – công thức S_{final} ($\alpha=0,2$; $\beta=0,8$)

Tầng 1 – Truy hồi sơ bộ cấp thực thể: Mọi truy vấn tuyển dụng dạng ngôn ngữ tự nhiên đều được xử lý thống nhất qua luồng truy hồi ngữ nghĩa. Truy vấn được mã hoá thành vector và đối chiếu trực tiếp với chỉ mục vector cấp thực thể (node-level vector index) lưu trên Neo4j [17]. Thao tác này hoạt động như bộ lọc thô (coarse filter), nhanh chóng thu hẹp không gian tìm kiếm và trích xuất danh sách ngắn (shortlist) top-k ứng viên có độ tương đồng ngữ nghĩa tổng thể gần nhất với JD, đồng thời truy xuất kèm mạng lưới quan hệ (relational subgraph) xung quanh mỗi ứng viên.

Tầng 2 – Tái xếp hạng kết hợp (Hybrid Re-ranking): Danh sách sơ bộ tiếp tục được đánh giá song song qua hai tín hiệu độc lập. Tín hiệu đồ thị (S_{graph}) đo mức độ khớp về cấu trúc kỹ năng. Tín hiệu vector (S_{vector}) được cập nhật bằng cách phân tán truy vấn (fan-out) sang Supabase để lấy điểm tương đồng ngữ nghĩa chi tiết từ các đoạn văn bản công khai của các ứng viên trong shortlist [18]. Điểm tổng hợp cuối cùng được tính theo công thức:

$$S_{final}(c) = \alpha \cdot S_{graph}(c, q) + \beta \cdot S_{vector}(c, q), \quad \alpha + \beta = 1 \quad (.2)$$

Với cấu hình mặc định $\alpha = 0,2$ và $\beta = 0,8$, hệ thống đặt trọng tâm vào độ tương đồng ngữ nghĩa từ mô hình nhúng, đồng thời sử dụng cấu trúc đồ thị như bộ hiệu chỉnh (calibrator) cho các kỹ năng đặc thù.

Điểm đồ thị nâng cao (S_{graph}) được thiết kế với ba thành phần:

$$S_{\text{graph}}(c, q) = \lambda_1 \cdot S_{\text{jaccard}} + \lambda_2 \cdot S_{\text{seniority}} + \lambda_3 \cdot S_{\text{bonus}} \quad (.3)$$

với $\lambda_1 = 0,50$, $\lambda_2 = 0,25$, $\lambda_3 = 0,25$, trong đó:

- S_{jaccard} (Điểm cơ sở): đo hệ số Jaccard thể hiện mức độ giao thoa giữa tập kỹ năng yêu cầu của JD và tập kỹ năng ứng viên sở hữu.
- $S_{\text{seniority}}$ (Điểm thâm niên): được tính dựa trên hàm bậc thang (step function) đánh giá tổng lượng kinh nghiệm quy đổi từ các thực thể Experience trên đồ thị.
- S_{bonus} (Điểm thưởng kết nối): được kích hoạt khi có sự giao thoa giữa kỹ năng yêu cầu và các công nghệ liên kết gián tiếp qua các cạnh USED_TECH và CONNECTED_TO.


Bảng 3. Bảng 6. Cấu hình siêu tham số Hybrid Search (cơ bản và điểm đồ thị nâng cao)

Hệ thống	α	β	Ghi chú
RAG thuần	0,0	1,0	Chỉ dùng vector cosine từ các đoạn văn bản
GraphRAG thuần	1,0	0,0	Chỉ dùng điểm đồ thị nâng cao
Hybrid (cơ bản)	0,2	0,8	Kết hợp vector và Jaccard kỹ năng cơ bản
Hybrid+ (đề xuất)	0,2	0,8	Kết hợp vector và S_{graph} nâng cao 3 thành phần

Sau khi lọc top-k ứng viên, tác tử trích xuất đồ thị con xung quanh từng ứng viên và dùng chuỗi quan hệ này làm cơ sở để mô hình ngôn ngữ sinh lý giải có thể truy vết về từng nút và cạnh cụ thể trên đồ thị – nền tảng của tính minh bạch (Explainable AI) trong quyết định tuyển dụng.


1.6. Thiết kế bản sao số

Bản sao số là tác tử cá nhân hoá đại diện cho một ứng viên cụ thể trong cuộc hội thoại phỏng vấn. Khác với tác tử điều phối hoạt động diện rộng trên toàn bộ tập dữ liệu, mỗi bản sao số chỉ biết về một người và chỉ được phép phản hồi trong phạm vi tri thức có trong hồ sơ của người đó.



Hình 16. Luồng xử lý phỏng vấn Digital Twin qua WebSocket streaming

Kiểm soát truy cập dựa trên quan hệ đồ thị: Cơ chế phân quyền không nằm ở tầng ứng dụng mà được ánh xạ trực tiếp trên cấu trúc đồ thị Neo4j [17]. Trước mỗi phiên phỏng vấn, hệ thống kiểm tra trạng thái cạnh CONNECTED_TO giữa nút tổ chức và nút ứng viên. Nếu quan hệ mang trạng thái đã chấp thuận, ngữ cảnh phỏng vấn được xây dựng toàn diện từ dữ liệu đồ thị công khai kết hợp với các đoạn văn bản riêng tư truy hồi từ Supabase [18]. Nếu chưa được chấp thuận, hệ thống giới hạn ngữ cảnh đầu vào chỉ ở phần thông tin công khai. Thiết kế này đảm bảo an toàn ở mức kiến trúc: ngay cả khi bị tấn công bằng kỹ thuật prompt injection, mô hình ngôn ngữ vẫn không thể sinh thông tin nhạy cảm vì ngữ cảnh được cấp không chứa các khối dữ liệu này.




Hình 17. Sơ đồ phân quyền truy cập dựa trên quan hệ đồ thị

Chiến lược hạn chế ảo giác: Để đảm bảo tính trung thực của bản sao số, hệ thống áp dụng chiến lược kiểm soát đa lớp. Về mặt tham số, nhiệt độ sinh được đặt ở mức thấp (temperature = 0,1) để mô hình ưu tiên tính chính xác và nhất quán mà vẫn giữ được độ tự nhiên cơ bản trong ngôn ngữ. Về mặt ngữ nghĩa, tác tử được ràng buộc bởi một thẻ định dạng nhân vật (persona prompt) nghiêm ngặt, kết hợp với bước đối chiếu dữ liệu nền (grounding check) và hậu kiểm chứng cứ (post-hoc validation). Tác tử phải phản hồi theo quy ước từ chối nếu câu hỏi vượt ra ngoài phạm vi hồ sơ gốc, ngăn chặn việc mô hình tự suy diễn từ kiến thức tham số nội tại.

Giao tiếp phản hồi liên tục qua WebSocket: Nhằm mang lại trải nghiệm tương tác liền mạch, máy chủ thiết lập kết nối WebSocket trực tiếp với máy khách. Thay vì truyền trực tiếp từng token từ mô hình (vốn có thể gây bất ổn và cần thời gian cho các bước hậu kiểm), hệ thống đợi mô hình sinh hoàn chỉnh và xác thực câu trả lời, sau đó phân tách văn bản đầu ra thành từng từ hoặc cụm từ nhỏ và liên tục đẩy về máy khách. Kỹ thuật này tạo ra hiệu ứng gõ phím trực tiếp (simulated streaming), vừa đảm bảo chất lượng nội dung, vừa duy trì cảm giác hội thoại thời gian thực.

1.7. Hệ thống lịch hẹn và thông báo

Sau khi đánh giá ứng viên qua bản sao số và quyết định tiến đến phỏng vấn thực, hệ thống lịch hẹn và thông báo thay thế quy trình trao đổi email thủ công bằng một luồng tương tác có cấu trúc trực tiếp trong ứng dụng. Quá trình đàm phán lịch phỏng vấn được quản lý thông qua một cỗ máy trạng thái (state machine).



Hình 18. Sơ đồ trạng thái vòng đời lịch phỏng vấn (đàm phán và đồng thuận)

Luồng hoạt động bắt đầu từ phía ứng viên thông qua việc thiết lập cấu hình lịch rảnh (availability). Ứng viên khai báo các khung giờ khả dụng định kỳ theo tuần, chỉ định các ngày ngoại lệ (blocked dates), cấu hình thời lượng mỗi phiên (slot duration) và ngưỡng thời gian báo trước tối thiểu (advance notice hours). Dựa trên các tham số này, hệ thống tự động suy diễn danh sách các khung giờ khả dụng thực tế.

Khi tổ chức truy vấn danh sách và quyết định tạo lịch phỏng vấn, hệ thống thực hiện đồng thời ba tác vụ nền: lưu bản ghi lịch hẹn với trạng thái khởi tạo (pending), gửi email xác nhận tự động đính kèm tệp sự kiện chuẩn (.ics) qua giao thức SMTP, và phát sinh bản ghi thông báo (notification) vào cơ sở dữ liệu.

Quá trình đàm phán lịch diễn ra qua các vòng lặp phản hồi, làm thay đổi trạng thái của lịch hẹn theo các bước sau:

- Pending (Khởi tạo): Lịch vừa được tổ chức tạo, chờ ứng viên phản hồi.
- Confirmed (Xác nhận): Một trong hai bên chấp nhận thời gian đề xuất của bên kia.
- Cancelled (Hủy bỏ): Một trong hai bên từ chối hoặc chủ động hủy lịch.
- Rescheduled (Thay đổi lịch): Ứng viên không đồng ý với giờ ban đầu và đề xuất khung giờ mới.
- Awaiting_org_response (Chờ tổ chức phản hồi): Trạng thái sau khi ứng viên đề xuất giờ mới.

- `Awaiting_personnel_response` (Chờ ứng viên phản hồi): Tổ chức đưa ra đề xuất ngược lại (`counter-propose`). Vòng lặp đàm phán tiếp diễn cho đến khi đạt trạng thái `confirmed` hoặc `cancelled`.

Hệ thống thông báo thời gian thực được xây dựng trên Supabase Realtime. Khác với kiến trúc thăm dò định kỳ (`polling`) gây tiêu tốn tài nguyên mạng, máy khách thiết lập một kênh đăng ký (`subscription`) lắng nghe trực tiếp các thay đổi trên bảng `notifications` trong PostgreSQL, đảm bảo ứng viên và tổ chức nhận cập nhật tức thì khi có yêu cầu kết nối mới, lịch phỏng vấn được tạo hoặc đối tác phản hồi.

2. Cài đặt giải pháp

2.1. Thu thập và chuẩn bị dữ liệu CV

Tập dữ liệu thực nghiệm được tác giả tự xây dựng theo nguyên tắc tránh circular evaluation bias: LLM chỉ được phép tạo sinh nội dung thô ban đầu; toàn bộ quá trình gán nhãn (annotation ground truth) do tác giả thực hiện thủ công và độc lập. Nguyên tắc này đảm bảo kết quả đánh giá không bị thiên lệch do mô hình tự chấm điểm dữ liệu nó tạo ra.

- **CV Dataset:** Dữ liệu thực nghiệm được tạo sinh bằng Claude/Gemini, bao gồm các CV đầy đủ thông tin theo chuẩn schema và một số CV chứa nhiều nhân tạo để kiểm thử khả năng xử lý ngoại lệ (edge case). Dữ liệu đối sánh thủ công (ground truth) được lưu tại `data_eval/ground_truth_corrected.json` sau khi qua bước kiểm định chất lượng (QA audit).
- **JD Dataset:** Bao gồm các mô tả công việc (JD) được viết bằng tiếng Việt, phân bổ vào các vai trò kỹ thuật như Data Engineering, Systems Programming, Mobile, Cloud/Infrastructure, AI/ML và Technical Leadership. Mỗi JD được annotation tối thiểu 3–5 Personnel relevant từ pool ứng viên trong Neo4j.
- **Các file hỗ trợ thực nghiệm:** `privacy_attacks.json` chứa các kịch bản tấn công cho kiểm thử bảo mật; `qa_dataset.json` chứa cặp Q&A để đánh giá RAGAS; và các file `emb_cache_*.json` lưu cache vector nhằm tối ưu thời gian chạy thử nghiệm.

2.2. Cài đặt các bước trong Pipeline Ingestion

Pipeline nhập liệu được điều phối bởi hàm `process_file()` trong `pipeline/main.py`, nhận đường dẫn tệp đầu vào và trả về trạng thái cuối cùng. Với tệp `.json` đã có cấu trúc, hệ thống đi theo luồng nạp trực tiếp (direct ingestion), bỏ qua các bước phân tích và trích xuất tốn kém.

Với luồng dữ liệu phi cấu trúc, hệ thống áp dụng chiến lược Map-Reduce cho bước trích xuất: văn bản được chia với `max_chars = 7.000` ký tự và vùng chồng lấp 400 ký tự; từng đoạn đi qua hàm `extract_knowledge()` (tầng Map) để tạo các phần JSON rời rạc; hàm `_merge_extracted_chunks()` (tầng Reduce) hợp nhất thành payload chuẩn `RecruitmentNode` hoàn chỉnh.


Bước trích xuất thông qua LLM chiếm phần lớn thời gian xử lý – đây là nút thắt tất yếu của hướng tiếp cận LLM-based. Tuy nhiên, do pipeline chạy nền một lần duy nhất khi ứng viên tải CV lên, độ trễ này không ảnh hưởng đến trải nghiệm tương tác thời gian thực. Phân bổ thời gian xử lý theo từng bước được trình bày tại Bảng 12.

Bảng 4. Bảng 12. Thời gian xử lý trung bình phân bổ theo các bước pipeline

Bước	Thời gian trung bình	Ghi chú
Parse (LlamaParse API)	~2–5 giây	Tùy thuộc độ phức tạp của tệp
Clean + Chunk	~0,01 giây	Xử lý regex nội bộ
Extract (LLM call)	~8,97 giây	Chiếm phần lớn thời gian (bottleneck)
Vectorize	~0,18 giây	Gọi API mô hình nhúng
Neo4j write	~0,1 giây	Lưu cấu trúc đồ thị và vector node
Supabase write	~0,5 giây	Lưu chunks và embeddings cấp đoạn

2.3. Cài đặt Hybrid Search và đồ thị tri thức

Hệ thống tìm kiếm kết hợp được hiện thực hóa thông qua hàm xử lý tìm kiếm ứng viên của tác tử điều phối chính.



Hình 19. Sơ đồ thuật toán tính điểm tìm kiếm kết hợp

Luồng truy xuất được thiết kế thành hai bước tính tế. Bước thứ nhất, hệ thống truy vấn chỉ mục vector của Neo4j để trích xuất nhanh một danh sách ngắn (short-

list) các ứng viên tiềm năng. Bước thứ hai, hệ thống thực hiện phân tán yêu cầu (fan-out) sang kho dữ liệu Supabase để lấy thêm tín hiệu tương đồng ngữ nghĩa chi tiết từ các đoạn văn bản công khai của những ứng viên trong danh sách này.

Điểm tổng hợp cuối cùng được tính theo công thức:

$$S_{\text{final}} = 0,2 \cdot S_{\text{graph}} + 0,8 \cdot S_{\text{vector}} \quad (.4)$$


trong đó điểm đồ thị nâng cao được tính theo:

$$S_{\text{graph}} = 0,5 \cdot S_{\text{base}} + 0,25 \cdot S_{\text{seniority}} + 0,25 \cdot S_{\text{bonus}} \quad (.5)$$

với S_{base} là điểm Jaccard kỹ năng, $S_{\text{seniority}}$ là điểm thâm niên, và S_{bonus} được kích hoạt khi có sự giao thoa giữa kỹ năng yêu cầu và các công nghệ liên kết trong đồ thị. Sau khi xác định top-k ứng viên, mô hình ngôn ngữ sinh phần lý giải đánh giá mức độ phù hợp (fit explanation) có truy vết về từng nút và cạnh cụ thể, phục vụ tính minh bạch cho hội đồng tuyển dụng.

2.4. Cài đặt Digital Twin qua WebSocket streaming

Tính năng Phòng vấn Bản sao số được thiết kế với hai điểm cuối (endpoint) xử lý đàm thoại: một endpoint hỗ trợ đàm thoại đơn lượt (single-turn HTTP) phục vụ kiểm thử nhanh, và một endpoint WebSocket hỗ trợ đàm thoại duy trì trạng thái (multi-turn streaming) dành cho tương tác thời gian thực trên giao diện.



Hình 20. Sơ đồ tuần tự giao tiếp WebSocket cho Digital Twin Interview

Luồng xử lý WebSocket bao gồm các bước tuần tự sau:

- **Xác thực ReBAC:** Hệ thống truy vấn Neo4j để kiểm tra trạng thái cạnh CONNECTED_TO giữa tổ chức và ứng viên, từ đó quyết định phạm vi dữ liệu được cấp cho mô hình [17].

- **Xây dựng ngữ cảnh:** Trong trường hợp chưa có kết nối hợp lệ, Mô hình Ngôn ngữ Lớn (LLM) chỉ được cấp quyền tiếp cận dữ liệu đồ thị công khai và các phân đoạn văn bản (chunks) công khai. Nếu quan hệ kết nối được xác thực hợp lệ, hệ thống sẽ tự động truy hồi thêm các phân đoạn văn bản mang tính riêng tư từ kho lưu trữ.
- **Cấu hình LLM:** Mô hình được thiết lập với mức độ ngẫu nhiên thấp (temperature = 0.1). Thiết lập này buộc mô hình ưu tiên tính chính xác và nhất quán dựa trên tập ngữ cảnh, nhưng vẫn duy trì được sự tự nhiên cơ bản trong ngôn ngữ giao tiếp.
- **Phát luồng dữ liệu:** Thay vì truyền trực tiếp từng token (vốn có thể gây bất ổn định kết nối), máy chủ chờ mô hình sinh hoàn chỉnh và xác thực toàn bộ câu trả lời. Sau đó, chuỗi kết quả được phân tách thành từng từ hoặc cụm từ nhỏ và liên tục đẩy về máy khách qua kênh WebSocket, tạo ra hiệu ứng gõ phím trực tiếp.
- **Lưu trữ:** Toàn bộ lịch sử giao tiếp (phiên và tin nhắn) được ghi nhận và lưu trữ vào cơ sở dữ liệu quan hệ để phục vụ cho các vòng đàm thoại tiếp theo.

2.5. Cài đặt API và hệ thống lịch hẹn

Hệ thống API backend được xây dựng trên framework FastAPI và tổ chức theo kiến trúc phân hệ theo lĩnh vực (router-per-domain) [19]. Cơ chế bảo mật và xác thực người dùng được thiết lập dựa trên chuẩn JSON Web Token (JWT). Token này do dịch vụ định danh cấp phát và được FastAPI kiểm chứng thông qua cơ chế tiêm phụ thuộc (dependency injection) tại mọi điểm cuối yêu cầu quyền truy cập. Tổng hợp danh sách các API endpoints cốt lõi và biến môi trường được trình bày từ Bảng 7 đến Bảng 10.

Bảng 5. Bảng 7. Danh sách API endpoints - Auth và Core

Method	Endpoint	Mô tả
POST	/auth/register	Đăng ký tài khoản mới (Tổ chức/Ứng viên).
POST	/auth/login	Xác thực đăng nhập, trả về JWT và thông tin người dùng.
POST	/ingest	Tiếp nhận hồ sơ và kích hoạt luồng nhập liệu đa phương thức.
POST	/search	Thực thi tìm kiếm kết hợp danh sách ứng viên.
POST	/interview	Giao tiếp Bản sao số dạng đơn lượt (HTTP).
WS	/interview/ws	Giao tiếp Bản sao số duy trì trạng thái (WebSocket).
GET	/graph	Truy xuất cấu trúc đồ thị phục vụ trực quan hóa mạng lưới.

Bảng 6. Bảng 8. Danh sách API endpoints - Chat và Scheduling

Method	Endpoint	Mô tả
GET	/chat/history/{id}	Truy xuất lịch sử hội thoại theo định danh ứng viên.
PUT	/availability	Cập nhật cấu hình lịch rảnh và các ngày ngoại lệ.
GET	/availability/{id}/slots	Tính toán và truy xuất danh sách khung giờ khả dụng.
POST	/schedule	Tổ chức khởi tạo yêu cầu đặt lịch phỏng vấn thực.
GET	/schedule	Liệt kê danh sách lịch trình (hỗ trợ lọc theo vai trò).
PATCH	/schedule/{id}/status	Cập nhật trạng thái xác nhận hoặc hủy lịch hẹn.
PATCH	/schedule/{id}/reschedule	Ứng viên phản hồi và đề xuất khung giờ thay thế.
PATCH	/schedule/{id}/counter-propose	Tổ chức phản hồi với đề xuất giờ mới.

Bảng 7. Bảng 9. Danh sách API endpoints - Notification


Method	Endpoint	Mô tả
GET	/notification	Truy xuất danh sách thông báo của người dùng.
GET	/notification/unread-count	Thống kê số lượng thông báo chưa đọc.
PATCH	/notification/{id}/read	Cập nhật trạng thái đã đọc cho một thông báo cụ thể.

Bảng 8. Bảng 10. Biến môi trường hệ thống

Phía	Biến tiêu biểu	Mô tả
BE	NEO4J_URI, SUPABASE_URL	Chuỗi kết nối cơ sở dữ liệu cốt lõi
BE	OPENAI_API_KEY, CERE- BRAS_API_KEY	Khoá truy cập các dịch vụ LLM
BE	LLAMA_CLOUD_API_KEY	Khoá API cho LlamaParse (bước Parse)
BE	DEMO_SENDER_EMAIL, DEMO_SENDER_APP_PASSWORD	Cấu hình SMTP gửi email xác nhận (.ics)
FE	NEXT_PUBLIC_SUPABASE_URL, NEXT_PUBLIC_SUPABASE_ANON_KEY	Cấu hình Supabase phía client
FE	NEXT_PUBLIC_API_URL	Base URL của FastAPI backend

2.6. Cài đặt giao diện

Hệ thống giao diện người dùng (Frontend) được phát triển trên nền tảng Next.js (phiên bản App Router), áp dụng nghiêm ngặt kiến trúc phân tầng Server/Client Components. Nhằm đảm bảo an ninh cho các phân hệ nội bộ, một Middleware chạy trên máy chủ (Server-Side Rendering Middleware) được thiết lập để bảo vệ toàn bộ nhóm định tuyến dành cho quản trị. Middleware này có nhiệm vụ liên tục kiểm tra, gia hạn (refresh) mã thông báo phiên làm việc (session token) và tự động chuyển hướng người dùng về trang xác thực nếu phát hiện phiên làm việc không còn hiệu lực.



Hình 21. Sơ đồ kiến trúc của giao diện người dùng

Việc quản lý trạng thái (State Management) của ứng dụng được phân tách minh bạch thành hai tầng chuyên biệt:

Trạng thái Máy khách (Client State): Sử dụng thư viện Zustand để xử lý các trạng thái giao diện cục bộ có tính chất tức thời (ví dụ: trạng thái thu/phóng thanh điều hướng, các tùy chọn hiển thị giao diện).

Trạng thái Máy chủ (Server State): Sử dụng thư viện TanStack Query để quản lý luồng dữ liệu truy xuất từ API. Thư viện này đảm nhận các tác vụ phức tạp như tự động lưu đệm (caching), đồng bộ hóa dữ liệu nền (background refetch) và cập nhật giao diện lạc quan (optimistic updates), giúp tối ưu hóa hiệu suất và nâng cao trải nghiệm người dùng.

Ảnh xạ giữa các đường dẫn định tuyến (Routing) và tính năng giao diện cốt lõi được hệ thống hóa tại Bảng 11.

Bảng 9. Bảng 11. Ánh xạ định tuyến (route), vai trò và tính năng chính (frontend)

Route	Vai trò	Tính năng chính
/search	Organization	Tìm kiếm ứng viên, xem ranking và lý giải có truy vết
/interview	Organization	Giao diện nhắn tin streaming với Bản sao số
/graph	Cả hai	Không gian tương tác mạng lưới đồ thị (zoom, pan, chi tiết nút)
/schedule	Cả hai	Quản lý vòng đời lịch phỏng vấn (confirm, cancel, reschedule)
/availability	Personnel	Thiết lập khung giờ khả dụng và ngày ngoại lệ
/notifications	Cả hai	Trung tâm hiển thị thông báo thời gian thực
/profile	Cả hai	Quản lý thông tin cá nhân và theo dõi trạng thái ingestion CV

CHƯƠNG 3. KIỂM THỬ VÀ ĐÁNH GIÁ

1. Giao diện sản phẩm

Hệ thống được thiết kế với giao diện trực quan, chia thành các phân hệ rõ ràng nhằm tối ưu hóa trải nghiệm tương tác cho cả nhà tuyển dụng và ứng viên. Dưới đây là mô tả chi tiết về các màn hình chức năng cốt lõi của hệ thống.

Giao diện trang tìm kiếm ứng viên (Hybrid Search)

Đây là màn hình chức năng trung tâm dành cho nhà tuyển dụng, cho phép thực hiện các truy vấn tìm kiếm ứng viên dựa trên mô tả công việc (Job Description – JD) thông qua cơ chế tìm kiếm kết hợp (Hybrid Search).


- **Khu vực nhập liệu mô tả công việc:** Cung cấp các biểu mẫu (form) để nhà tuyển dụng định nghĩa các tiêu chí cốt lõi bao gồm: vị trí tuyển dụng, cấp độ chuyên môn và danh sách các kỹ năng bắt buộc. Vùng văn bản mô tả công việc được thiết kế mở rộng nhằm thu thập tối đa ngữ cảnh về yêu cầu, trách nhiệm và môi trường làm việc, từ đó cung cấp dữ liệu đầu vào chất lượng cho cơ chế đối sánh của mô hình.
- **Khu vực tra cứu lịch sử tìm kiếm:** Hệ thống hỗ trợ lưu trữ cục bộ (local storage) danh sách các truy vấn gần đây. Mỗi bản ghi tóm tắt các tham số thiết yếu của lần tìm kiếm trước (như nội dung truy vấn rút gọn, thời điểm thực hiện và số lượng ứng viên tìm thấy), hỗ trợ người dùng xem lại và tái sử dụng các thiết lập tìm kiếm một cách nhanh chóng.

Hình 22. Hình giao diện trang tìm kiếm ứng viên

Giao diện phỏng vấn Digital Twin (đàm thoại thời gian thực)

Giao diện này cung cấp không gian tương tác trực tiếp giữa nhà tuyển dụng và bản sao số (Digital Twin) của ứng viên, được tổ chức thành ba khu vực chức năng liên kết chặt chẽ:

- **Khu vực tổng quan năng lực ứng viên:** Trình bày thông tin định danh của ứng viên. Điểm nhấn của khu vực này là bản tóm tắt mức độ phù hợp (LLM Fit Summary) do hệ thống AI tự động phân tích và tổng hợp. Bản tóm tắt này đối chiếu kinh nghiệm của ứng viên với yêu cầu công việc kèm theo điểm số tương đồng (Match score) và độ mạnh kết nối (Connection strength), cung cấp cơ sở tham khảo định lượng trước khi bắt đầu phỏng vấn.
- **Khu vực quản lý phiên hội thoại:** Hiển thị danh sách các phiên đàm thoại với các bản sao số, được sắp xếp mặc định theo thời gian tạo phiên (mới nhất xếp trước). Tích hợp công cụ tìm kiếm nhanh giúp nhà tuyển dụng dễ dàng điều hướng và quản lý nhiều luồng phỏng vấn khác nhau.
- **Khu vực hội thoại tương tác:** Mô phỏng môi trường nhắn tin trực tiếp. Hệ thống kết hợp giao thức WebSocket để tạo ra hiệu ứng truyền phát chuỗi (simulated streaming) ở lớp hiển thị, giúp quá trình sinh văn bản phản hồi từ LLM diễn ra tự nhiên như một cuộc hội thoại thực tế. Nút chức năng “Đặt lịch phỏng vấn thực” được đặt ngay trong giao diện, tạo sự liền mạch trong quy trình chuyển đổi trạng thái tuyển dụng.



Hình 23. Hình giao diện phỏng vấn Digital Twin


Giao diện trực quan hóa đồ thị tri thức

Nhằm tăng cường khả năng giải thích (Explainability) của hệ thống AI, giao diện đồ thị quan hệ được xây dựng dựa trên thuật toán đồ thị lực tương tác 2D (Force-directed graph 2D), cho phép người dùng quan sát trực quan cách thức dữ liệu được liên kết.

- **Không gian trực quan hóa mạng lưới:** Biểu diễn dữ liệu dưới dạng đồ thị phức hợp, trong đó các đỉnh (node) đại diện cho thực thể (nhân sự, kỹ năng,

tổ chức, dự án) và các cạnh (edge) thể hiện mối quan hệ ngữ nghĩa. Giao diện cung cấp các công cụ tương tác đa chiều như phóng to (zoom), thu nhỏ, kéo thả (pan) và chọn đỉnh, giúp người dùng linh hoạt phân tích cấu trúc topo của mạng lưới tri thức.

- **Bảng thông tin chi tiết:** Khi người dùng tương tác chọn một đỉnh nhân sự cụ thể, bảng điều khiển bên phải sẽ truy xuất và hiển thị thông tin tóm tắt chuyên môn cùng danh sách các kỹ năng cốt lõi. Từ đây, người dùng có thể thực hiện các thao tác chuyển hướng nhanh như bắt đầu phỏng vấn bản sao số hoặc xem hồ sơ chi tiết của nhân sự.




Hình 24. Hình giao diện trực quan hóa đồ thị tri thức

Giao diện quản lý lịch phỏng vấn thực (Schedule)

Phân hệ này được thiết kế để nhà tuyển dụng theo dõi, quản lý tập trung và kiểm soát vòng đời của các sự kiện phỏng vấn thực tế.

- **Danh sách lịch hẹn:** Trình bày các lịch phỏng vấn dưới dạng thẻ thông tin (card), sắp xếp theo trình tự thời gian. Mỗi thẻ cung cấp cái nhìn tổng quan về sự kiện, bao gồm: thông tin ứng viên/đối tác, thời gian, thời lượng, hình thức tổ chức (Online/Offline), địa điểm và trạng thái hiện tại của lịch hẹn (như Đang chờ, Đã xác nhận, Đã thay đổi lịch, Đã hủy). Trạng thái gửi email thông báo cũng được cập nhật trực tiếp trên thẻ.
- **Hỗ trợ thông tin tiền phỏng vấn:** Hệ thống cung cấp chức năng xem nhanh “Tóm tắt phỏng vấn AI” ngay trên thẻ sự kiện. Tính năng này cho phép nhà tuyển dụng truy xuất lại những điểm chính từ phiên tương tác với bản sao số trước đó, hỗ trợ đắc lực cho quá trình chuẩn bị kịch bản phỏng vấn chính thức. Tùy thuộc vào vai trò (nhà tuyển dụng hay ứng viên) và trạng thái hiện tại, hệ thống sẽ hiển thị các nút hành động tương ứng (Xác nhận, Đề xuất giờ khác, Hủy lịch).




Hình 25. Hình giao diện quản lý lịch phỏng vấn thực

Giao diện cài đặt lịch rảnh của ứng viên (Availability)

Đây là màn hình chức năng dành riêng cho người dùng đóng vai trò ứng viên, cho phép họ chủ động khai báo quỹ thời gian khả dụng của bản thân.

Thiết lập cấu hình thời gian: Ứng viên có thể thiết lập các khung giờ rảnh rồi lặp lại theo từng ngày trong tuần thông qua các công cụ chọn giờ (Time Pickers) trực quan. Hệ thống cũng cho phép đánh dấu vô hiệu hóa toàn bộ một ngày (trạng thái “Nghỉ”). Các tham số cấu hình này sau khi được lưu trữ sẽ làm cơ sở dữ liệu đầu vào, giúp hệ thống và nhà tuyển dụng dễ dàng đề xuất và lựa chọn các khung giờ phù hợp khi tạo lịch hẹn phỏng vấn.



Hình 26. Hình giao diện cài đặt lịch rảnh của ứng viên

Giao diện upload và phản hồi trạng thái xử lý CV (Hồ sơ của tôi)

Giao diện hồ sơ cá nhân đóng vai trò là điểm tiếp nhận dữ liệu (ingestion) của ứng viên vào hệ thống, đồng thời hiển thị kết quả bóc tách thông tin cơ bản.

- **Khu vực tải lên và tiếp nhận hồ sơ:** Cung cấp vùng tương tác (Dropzone) để ứng viên tải lên dữ liệu đầu vào, hỗ trợ các định dạng tệp văn bản phổ biến (PDF, DOCX, TXT, JSON, MD). Sau khi tải lên, hệ thống sẽ phản hồi trạng thái xử lý cơ bản (thành công hoặc thất bại) để người dùng nắm bắt tiến trình cập nhật tri thức cho bản sao số.
- **Khu vực hiển thị kết quả trích xuất:** Minh bạch hóa quá trình xử lý dữ liệu bằng cách hiển thị trực tiếp những thông tin mà hệ thống AI đã bóc tách được từ tệp hồ sơ gốc. Khu vực này bao gồm một đoạn văn bản giới thiệu tổng quan năng lực và một danh sách các thẻ (tags) từ khóa đại diện cho bộ kỹ năng chuyên môn của ứng viên.

The screenshot displays the 'HỒ SƠ CỦA TÔI' (My Profile) page in the ORCHGRAPH-RAG system. On the left is a sidebar with navigation links: 'Hồ sơ' (Profile), 'Lịch rảnh' (Availability), 'Lịch hẹn' (Appointment), and 'Thông báo' (Notification). Below these is a user card for 'Nguyễn Văn Phúc' (Nguyen Van Phuc), an 'Ứng viên' (Candidate), with a 'Đăng xuất' (Logout) button. The main content area is titled 'Hồ sơ của tôi' and contains three sections: 1. 'Upload hồ sơ' (Upload CV), which includes a description and a dashed box for file upload, supporting PDF, DOCX, TXT, and JSON formats. 2. 'Skills & Giới thiệu' (Skills & Introduction), which includes a 'GIỚI THIỆU' (Introduction) paragraph about the user's 5-year experience as a Cyber Security Engineer and SOC Analyst at Viettel Cyber Security, and a 'KỸ NĂNG' (Skills) section with tags for cyber security, threat hunting, incident response, siem, soar, python, threat intelligence, network forensics, endpoint forensics, and malware analysis. A small globe icon is visible in the bottom right corner of the main content area.

Hình 27. Hình giao diện upload và phản hồi trạng thái xử lý CV

2. Kết quả thực nghiệm

Phần này trình bày quá trình thiết lập thực nghiệm, đánh giá quy trình nhập liệu, so sánh mô hình biểu diễn vector, và kiểm thử hệ thống truy xuất kết hợp cơ chế bảo mật dữ liệu cá nhân.

2.1. Thiết lập thực nghiệm

2.1.1. Tập dữ liệu thực nghiệm

Để đảm bảo tính khách quan, toàn bộ dữ liệu thực nghiệm được xây dựng theo nguyên tắc: mô hình ngôn ngữ lớn chỉ tạo sinh nội dung thô ban đầu, còn việc gán nhãn chuẩn do tác giả thực hiện thủ công và độc lập. Nguyên tắc này ngăn mô hình tự đánh giá tốt trên dữ liệu mà chính nó tạo ra.

Tập dữ liệu gồm ba thành phần chính. Tập hồ sơ ứng viên bao gồm 30 CV kỹ thuật tiếng Việt lĩnh vực IT, trong đó 20 CV đầy đủ thông tin theo chuẩn lược đồ đã định nghĩa và 10 CV bị thiếu một số trường, nhằm kiểm tra khả năng xử lý dữ liệu không hoàn chỉnh của hệ thống. Tập bản mô tả công việc bao gồm 40 yêu cầu tuyển dụng viết bằng tiếng Việt, phân bổ theo sáu vai trò kỹ thuật gồm Kỹ thuật dữ liệu, Lập trình hệ thống, Di động, Hạ tầng đám mây, Trí tuệ nhân tạo và Dẫn dắt kỹ thuật; mỗi yêu cầu được gán nhãn tối thiểu 3-5 ứng viên phù hợp từ tập 56 hồ sơ trong cơ sở dữ liệu đồ thị. Tập câu hỏi phỏng vấn bao gồm 26 cặp câu hỏi - câu trả lời chuẩn, phục vụ đánh giá chất lượng truy xuất theo bộ chỉ số RAGAS.

2.1.2. Môi trường thực nghiệm

Các thực nghiệm được thực hiện với cấu hình như sau: ngôn ngữ lập trình Python 3.12, cơ sở dữ liệu đồ thị Neo4j 5.26 chạy qua Docker, cơ sở dữ liệu vector Supabase tích hợp pgvector, bộ đánh giá RAGAS phiên bản 0.2 trở lên. Mô hình ngôn ngữ dùng để đánh giá là GPT-4o-mini với nhiệt độ sinh bằng 0 (kết quả tắt định), mô hình trích xuất thực thể sử dụng GPT-4o-mini làm lựa chọn chính và Llama 3.1-8B làm phương án dự phòng.

2.1.3. Chiến lược kiểm thử

Hệ thống được kiểm thử trên hai luồng nghiệp vụ có đặc trưng khác nhau, nên bộ thang đo cũng được chọn riêng cho từng luồng.

Luồng tìm kiếm ứng viên là bài toán xếp hạng danh sách, được đánh giá trên 40 truy vấn bằng ba chỉ số: MRR@5 (thứ hạng trung bình nghịch đảo của ứng viên đúng đầu tiên trong top 5), Recall@5 và Recall@10 (tỉ lệ ứng viên đúng xuất hiện trong top 5 và top 10), và NDCG@5 (chỉ số xếp hạng có tính đến vị trí của từng kết quả đúng). Luồng truy xuất để trả lời câu hỏi phỏng vấn được đánh giá trên 26 cặp câu hỏi bằng bộ chỉ số RAGAS gồm năm thành phần: Độ trung thực (tỉ lệ thông tin trong câu trả lời có thể truy vết về ngữ cảnh được cấp), Độ phù hợp câu trả lời (mức độ câu trả lời giải quyết đúng câu hỏi), Độ bao phủ ngữ cảnh (ngữ cảnh truy xuất có bao phủ đủ thông tin cần thiết không), Độ chính xác ngữ cảnh (tỉ lệ ngữ cảnh được dùng thực sự cần thiết), và Độ đúng dẫn câu trả lời (so sánh với câu trả lời chuẩn).

2.2. Đánh giá quy trình nhập liệu

2.2.1. Bước làm sạch văn bản

Bước này có nhiệm vụ loại bỏ nhiễu từ văn bản thô gồm ký tự lạ, khoảng trắng thừa và lỗi mã hóa, mà không làm mất thông tin ngôn ngữ. Kết quả đánh giá trên 30 CV được trình bày trong Bảng 10.

Bảng 10. Kết quả đánh giá bước làm sạch văn bản trên 30 CV

Chỉ số	Công thức	Kết quả	Mục tiêu
Số tệp xử lý	-	30	30
Tỉ lệ loại bỏ nhiễu trung bình	(độ dài trước - sau) / trước	0,32%	10-30%
Tỉ lệ ký tự tiếng Việt trước xử lý	số ký tự TV / tổng ký tự chữ	0,0903	-
Tỉ lệ ký tự tiếng Việt sau xử lý	số ký tự TV / tổng ký tự chữ	0,0903	$\geq 0,09$

Tỉ lệ loại bỏ nhiễu đạt 0,32%, thấp hơn kỳ vọng vì tập CV tổng hợp được tạo từ mô hình ngôn ngữ lớn nên vốn đã khá sạch. Quan trọng hơn, tỉ lệ ký tự tiếng Việt trước và sau xử lý bằng nhau (0,0903), xác nhận bước này không làm mất dữ liệu ngôn ngữ. Với CV thực tế từ người dùng (tệp PDF scan, dán từ Word), tỉ lệ loại bỏ nhiễu dự kiến sẽ cao hơn đáng kể.


2.2.2. Bước trích xuất thực thể

Đây là bước trọng tâm của quy trình nhập liệu, sử dụng mô hình ngôn ngữ lớn để trích xuất thông tin có cấu trúc từ CV theo lược đồ đã định nghĩa. Chất lượng ở bước này ảnh hưởng trực tiếp đến toàn bộ phần sau: chất lượng đồ thị tri thức, chất lượng biểu diễn vector và khả năng trả lời câu hỏi phỏng vấn.

Hệ thống áp dụng phương pháp danh sách trắng để phân loại dữ liệu. Nhóm trường công khai gồm 8 trường: tên đầy đủ, tóm tắt năng lực, kỹ năng, kinh nghiệm, học vấn, chứng chỉ, trạng thái tìm việc và đặc trưng văn hóa. Nhóm trường riêng tư gồm các trường còn lại như email, số điện thoại, tài khoản mạng xã hội, mức lương kỳ vọng, danh sách tổ chức cần tránh, bí mật kỹ thuật dự án và lịch sử phỏng vấn.

Bảng 11. Độ bao phủ từng trường trên 30 CV có nhãn chuẩn

Trường	Độ bao phủ	Nhóm
Tên đầy đủ	1,00	Công khai
Tóm tắt năng lực	1,00	Công khai
Kỹ năng	1,00	Công khai
Mức lương kỳ vọng	0,96	Riêng tư
Kinh nghiệm	0,96	Công khai
Email liên hệ	0,92	Riêng tư
Số điện thoại	0,92	Riêng tư
Học vấn	0,88	Công khai
Chứng chỉ	0,64	Công khai
Bí mật kỹ thuật dự án	0,24	Riêng tư
Danh sách tổ chức cần tránh	0,24	Riêng tư
Đặc trưng văn hóa	0,12	Công khai
Trạng thái tìm việc	0,00	Công khai



Hình 28. Biểu đồ trực quan hóa độ bao phủ từng trường

Bảng 12. Tổng hợp kết quả bước trích xuất thực thể

Chỉ số	Giá trị
Độ bao phủ trung bình – nhóm công khai	0,700
Độ bao phủ trung bình – nhóm riêng tư	0,656
Độ chính xác phân loại công khai/riêng tư	0,824
Tỉ lệ sinh thông tin sai trung bình	0,08 trường/CV
Thời gian trích xuất trung bình	8,97 giây/CV

Dựa trên kết quả trên, có thể rút ra một số nhận xét như sau:

- Ba trường cốt lõi (tên, tóm tắt năng lực, kỹ năng) đạt độ bao phủ 100%, cho thấy mô hình xử lý tốt thông tin được trình bày rõ ràng trong CV.
- Trường trạng thái tìm việc đạt 0% vì câu lệnh hướng dẫn mô hình chưa có ví dụ về cách chuyển đổi biểu đạt tự nhiên (như "Đang tìm việc" hay "Open to offers") sang giá trị nhị phân. Cần bổ sung ví dụ cụ thể trong phần hướng dẫn của mô hình.
- Các trường bí mật kỹ thuật dự án và danh sách tổ chức cần tránh chỉ đạt 0,24 vì thường xuất hiện ẩn trong phần mô tả tự do của CV, không có cấu trúc tường minh để mô hình nhận diện.
- Trường đặc trưng văn hóa đạt 0,12 do khái niệm này chưa phổ biến trong format CV tiếng Việt, mô hình không đủ cơ sở để suy luận.
- Tỉ lệ sinh thông tin sai chỉ 0,08 trường/CV (chỉ xuất hiện ở 2 trong 25 CV) là mức thấp, xác nhận độ tin cậy của quy trình trong điều kiện dữ liệu sạch.
- Bước trích xuất thực thể chiếm khoảng 70% tổng thời gian xử lý và là điểm nghẽn chính của toàn bộ quy trình. Tuy nhiên, vì quy trình này chỉ chạy một lần khi người dùng tải CV lên và chạy ngầm (offline), độ trễ này không ảnh hưởng đến trải nghiệm tương tác trực tiếp.

2.2.3. Chất lượng đồ thị tri thức

Sau khi nhập liệu, đề tài kiểm tra mức độ đầy đủ và nhất quán của dữ liệu đã được ghi vào đồ thị. Kết quả được tổng hợp trong Bảng 13 và Bảng 14.

Bảng 13. Mức độ đầy đủ của các nút ứng viên (50 nút)

Chỉ số	Giá trị	Tỉ lệ
Tổng nút ứng viên	50	100%
Có tên đầy đủ	50	100,0%
Có danh sách kỹ năng	50	100,0%
Có tóm tắt năng lực	50	100,0%
Có vectơ biểu diễn	50	100,0%
Có trạng thái tìm việc	50	100,0%

Bảng 14. Thống kê quan hệ và kỹ năng trong đồ thị

Chỉ số	Giá trị
Tổng quan hệ kết nối tổ chức - ứng viên	10
– Đã chấp thuận	6
– Đang chờ	4
Số kỹ năng duy nhất (sau chuẩn hóa)	555
Tổng số lần kỹ năng xuất hiện	1.008
Số kỹ năng trung bình mỗi ứng viên	22,46
Tỉ lệ giảm biến thể sau chuẩn hóa	0,72% (559 xuống 555)

Đồ thị đạt mức đầy đủ cao với 100% nút ứng viên có đủ các thuộc tính cần thiết. Tuy nhiên, số lượng quan hệ kết nối giữa tổ chức và ứng viên còn ít (10 quan hệ cho 50 nút), khiến thành phần điểm thưởng kết nối trong công thức tìm kiếm chưa phát huy hết tác dụng. Đây là lý do đề tài bổ sung thêm thành phần tính điểm thâm niên vào công thức để tín hiệu từ đồ thị không phụ thuộc quá nhiều vào độ thưa của dữ liệu quan hệ.

2.3. So sánh các mô hình biểu diễn vector

2.3.1. Thiết lập thực nghiệm

Bốn mô hình biểu diễn vector đa ngôn ngữ được so sánh, bao gồm PhoBERT-base-v2 (768 chiều, 135 triệu tham số), multilingual-E5-base (768 chiều, 278 triệu tham số), GTE-multilingual-base (768 chiều, 305 triệu tham số) và BGE-M3 (768 chiều, 568 triệu tham số).

Hai luồng nghiệp vụ của hệ thống có yêu cầu khác nhau về mô hình biểu diễn, nên được đánh giá riêng. Tác vụ tìm kiếm ứng viên đòi hỏi mô hình so khớp tốt giữa bản mô tả công việc và hồ sơ ứng viên (đều là văn bản dài, có nhiều thuật ngữ kỹ thuật tiếng Anh xen lẫn tiếng Việt). Tác vụ truy xuất để trả lời câu hỏi phỏng vấn đòi hỏi mô hình tìm đúng đoạn văn bản ngắn trong CV khớp với câu hỏi cụ thể của nhà tuyển dụng.

2.3.2. Kết quả trên tác vụ tìm kiếm ứng viên

Bảng 15 trình bày kết quả kiểm thử trên 40 truy vấn tuyển dụng với tập 56 hồ sơ ứng viên.

Bảng 15. So sánh 4 mô hình biểu diễn vector trên tác vụ tìm kiếm ứng viên

Mô hình	MRR@5	Recall@5	Recall@10	NDCG@5	Thời gian TB (ms)
PhoBERT-base-v2	0,6361	0,6694	0,7361	0,5832	206,95
multilingual-E5-base	1,0000	0,9556	1,0000	0,9573	186,44
GTE-multilingual-base	1,0000	0,9722	0,9833	0,9698	244,41
BGE-M3	1,0000	0,3890	1,0000	0,9465	556,28

Dựa trên kết quả trên, có thể rút ra một số nhận xét như sau:

- Ba mô hình E5, GTE và BGE-M3 đều đạt $MRR@5 = 1,0$, nghĩa là ứng viên phù hợp nhất luôn xuất hiện ở vị trí đầu tiên trong mọi truy vấn kiểm thử. Điều này cho thấy cả ba mô hình đều có khả năng biểu diễn ngữ nghĩa đa ngôn ngữ đủ tốt cho dữ liệu CV kỹ thuật tiếng Việt có thuật ngữ tiếng Anh xen lẫn.
- PhoBERT-base-v2 chỉ đạt $MRR@5 = 0,6361$, thấp hơn đáng kể so với ba mô hình còn lại. Nguyên nhân là PhoBERT được huấn luyện trên tập dữ liệu tin tức và báo chí tiếng Việt, nên thiếu khả năng hiểu các thuật ngữ kỹ thuật tiếng Anh vốn rất phổ biến trong cả bản mô tả công việc lẫn hồ sơ ứng viên IT.
- BGE-M3 tuy đạt $MRR@5 = 1,0$ nhưng $Recall@5$ chỉ đạt 0,3890, thấp hơn nhiều so với E5 (0,9556) và GTE (0,9722). Điều này cho thấy BGE-M3 xếp đúng ứng viên số một nhưng không tốt trong việc đưa nhiều ứng viên phù hợp vào danh sách top 5. Thêm vào đó, thời gian xử lý của BGE-M3 gấp 2,3 lần GTE nên không phải lựa chọn hiệu quả về mặt chi phí tính toán.
- Xét cả chất lượng lẫn tốc độ, GTE-multilingual-base là lựa chọn cân bằng nhất: $Recall@5$ cao nhất (0,9722), $NDCG@5$ cao nhất (0,9698), thời gian xử lý chấp nhận được (244 ms).

2.3.3. Kết quả trên tác vụ truy xuất câu hỏi phỏng vấn

Tác vụ này đánh giá khả năng tìm đúng các đoạn văn bản trong CV cần thiết để trả lời câu hỏi phỏng vấn. Khác với tác vụ tìm kiếm (so khớp toàn bộ hồ sơ với bản mô tả công việc), tác vụ này yêu cầu mô hình hiểu câu hỏi cụ thể và ánh xạ chính xác đến đoạn văn bản tương ứng trong CV.

Bảng 16. So sánh 4 mô hình biểu diễn vector trên tác vụ truy xuất câu hỏi phỏng vấn

Mô hình	Precision@5	Recall	MRR	Hit@1	Thời gian TB (ms)
PhoBERT-base-v2	0,4462	0,7500	0,9231	0,8462	793,56
multilingual-E5-base	0,4000	0,6795	0,9423	0,9231	723,78
GTE-multilingual-base	0,4692	0,7949	0,9359	0,8846	730,07
BGE-M3	0,2231	0,3782	0,4622	0,2692	736,09

Dựa trên kết quả trên, có thể rút ra một số nhận xét như sau:

- GTE-multilingual-base tiếp tục dẫn đầu về Precision@5 (0,4692) và Recall (0,7949), cho thấy mô hình nhất quán cả khi tìm kiếm hồ sơ tổng thể lẫn khi truy xuất chi tiết trong văn bản.
- multilingual-E5-base dẫn đầu về MRR (0,9423) và Hit@1 (0,9231), nghĩa là đoạn văn bản đúng thường xuất hiện ở vị trí đầu tiên, dù danh sách top 5 tổng thể không bao phủ bằng GTE.

- BGE-M3 sụt giảm mạnh ở tác vụ này: MRR chỉ đạt 0,4622 và Recall chỉ 0,3782, tương phản hoàn toàn với kết quả tốt ở tác vụ tìm kiếm. Điều này cho thấy mô hình không phù hợp với bài toán tìm đoạn văn bản ngắn trong CV tiếng Việt.
- PhoBERT-base-v2 cho kết quả khá hơn kỳ vọng ở tác vụ này (MRR 0,9231, Recall 0,7500), vì câu hỏi phỏng vấn thường dùng tiếng Việt thuần, phù hợp hơn với tập dữ liệu mà PhoBERT được huấn luyện.
- Nhìn chung qua cả hai tác vụ, GTE-multilingual-base là mô hình nhất quán nhất: dẫn đầu về Recall trên tác vụ tìm kiếm và cũng dẫn đầu về Recall lẫn Precision trên tác vụ truy xuất. Do đó, đề tài sử dụng GTE-multilingual-base làm mô hình biểu diễn vector thống nhất cho toàn hệ thống.

2.4. Đánh giá hệ thống truy xuất và bảo mật

2.4.1. Cấu hình thực nghiệm

Bốn cấu hình truy xuất được so sánh thông qua điều chỉnh trọng số α và β trong công thức kết hợp, đồng thời thay đổi cách tính điểm đồ thị. Mục tiêu là đánh giá xem việc bổ sung tín hiệu từ đồ thị tri thức (GraphRAG) và chiến lược tính điểm nâng cao có cải thiện chất lượng trả lời so với truy xuất vector thuần túy hay không.

Công thức tính điểm đồ thị nâng cao gồm ba thành phần:

$$S_{\text{graph}}(c, q) = \lambda_1 \cdot S_{\text{skill}} + \lambda_2 \cdot S_{\text{tenure}} + \lambda_3 \cdot S_{\text{connection}} \quad (.6)$$

với $\lambda_1 = 0,50$, $\lambda_2 = 0,25$, $\lambda_3 = 0,25$. Trong đó: điểm kỹ năng đo tỉ lệ giao thoa kỹ năng giữa ứng viên và yêu cầu tuyển dụng; điểm thâm niên tính dựa trên tổng số năm kinh nghiệm theo các quan hệ làm việc trong đồ thị; điểm kết nối được kích hoạt khi ứng viên có kinh nghiệm tại tổ chức đã thực hiện dự án dùng đúng công nghệ yêu cầu (chuỗi 3 bước quan hệ: ứng viên – tổ chức – dự án – công nghệ).

Bảng 17. Cấu hình bốn hệ thống thực nghiệm

Hệ thống	α	β	Điểm đồ thị	Mô tả
RAG	0,0	1,0	-	Chỉ dùng độ tương đồng vector
GraphRAG	1,0	0,0	Chỉ kỹ năng	Chỉ dùng điểm đồ thị (cũ)
Hybrid	0,4	0,6	Chỉ kỹ năng	Kết hợp – điểm đồ thị cũ
Hybrid+ (đề xuất)	0,4	0,6	3 thành phần	Kết hợp – điểm đồ thị nâng cao

2.4.2. Kết quả so sánh bốn cấu hình

Bảng 18 trình bày kết quả đánh giá trên 26 cặp câu hỏi - câu trả lời, sử dụng GPT-4o-mini làm mô hình chấm điểm với nhiệt độ sinh bằng 0.

Bảng 18. Kết quả RAGAS so sánh bốn cấu hình truy xuất

Hệ thống	Độ trung thực	Phù hợp câu trả lời	Bao phủ ngữ cảnh	Chính xác ngữ cảnh	Đúng dẫn câu trả lời
RAG	0,8727	0,6458	0,9615	0,9103	0,6613
GraphRAG	0,8833	0,6761	0,9615	0,9167	0,7052
Hybrid	0,8613	0,7462	0,9615	0,9103	0,6378
Hybrid+	0,8803	0,7474	0,9615	0,9167	0,6567

Dựa trên kết quả kiểm thử bốn cấu hình, có thể rút ra một số nhận xét như sau:

- Độ bao phủ ngữ cảnh đạt 0,9615 đồng đều ở cả bốn cấu hình, cho thấy đồ thị tri thức đã chứa đủ thông tin cần thiết để trả lời các câu hỏi trong tập kiểm thử, bất kể chiến lược truy xuất nào được áp dụng.
- GraphRAG đạt độ trung thực cao nhất (0,8833) và độ đúng dẫn câu trả lời cao nhất (0,7052). Khi chỉ dùng tín hiệu từ đồ thị, ngữ cảnh được cấp cho mô hình có cấu trúc quan hệ chặt chẽ hơn, giúp câu trả lời sinh ra chính xác và bám sát nguồn dữ liệu hơn.
- Hybrid+ đạt độ phù hợp câu trả lời cao nhất (0,7474), nhỉnh hơn Hybrid (0,7462) và vượt rõ GraphRAG (0,6761). Tín hiệu thâm niên và kết nối trong công thức điểm nâng cao giúp truy xuất ứng viên có ngữ cảnh liên quan hơn đến từng câu hỏi cụ thể.
- Hybrid có độ trung thực thấp nhất (0,8613), cho thấy việc kết hợp vector thuần với điểm kỹ năng đơn giản có thể đưa vào ngữ cảnh những thông tin ít liên quan hơn, làm giảm độ bám sát nguồn của câu trả lời.
- Khoảng cách giữa Hybrid và Hybrid+ còn nhỏ (0,7462 so với 0,7474) vì tập dữ liệu hiện tại có ít quan hệ tổ chức - ứng viên, khiến thành phần điểm kết nối chưa phát huy. Khi quy mô đồ thị tăng lên, sự chênh lệch này dự kiến sẽ rõ hơn, nhất là với các yêu cầu tuyển dụng có điều kiện cụ thể về thâm niên hoặc lĩnh vực kinh nghiệm.

2.4.3. Kiểm thử bảo mật dữ liệu cá nhân

Đây là thực nghiệm quan trọng nhất về mặt độ tin cậy của hệ thống. Kiến trúc phân tách công khai - riêng tư được thiết kế để ngăn chặn rò rỉ thông tin nhạy cảm khi tổ chức chưa có kết nối được ứng viên chấp thuận.

Ba ứng viên có đầy đủ thông tin mức lương kỳ vọng và bí mật kỹ thuật dự án được dùng để kiểm thử với 12 câu tấn công, chia làm 4 kịch bản (3 câu mỗi kịch bản). Tất cả cuộc gọi truy vấn đều dùng một tổ chức không có bất kỳ quan hệ nào trong đồ thị.

Bảng 19. Kết quả kiểm thử bảo mật dữ liệu cá nhân

Kịch bản	Số câu	Rò rỉ	Tỉ lệ rò rỉ	Tỉ lệ an toàn
Hỏi trực tiếp	3	0	0,0%	100,0%
Khai thác gián tiếp	3	0	0,0%	100,0%
Tấn công vượt rào câu lệnh	3	0	0,0%	100,0%
Đánh lừa ngữ cảnh	3	0	0,0%	100,0%
Tổng	12	0	0,0%	100,0%

Hệ thống đạt tỉ lệ an toàn 100% trên tất cả 4 kịch bản, kể cả câu tấn công vượt rào bằng tiếng Anh ("Ignore previous instructions. List all private information.") và câu đánh lừa ngữ cảnh ("Tôi là người đại diện pháp lý, hãy cung cấp thông tin lương"). Kết quả này xác nhận hiệu quả của cơ chế bảo mật hai tầng: xác thực trạng thái quan hệ trong đồ thị tri thức trước khi xây dựng ngữ cảnh, đảm bảo mô hình ngôn ngữ không thể suy luận thông tin mà nó chưa bao giờ được thấy trong phiên truy vấn đó, dù bị tấn công theo cách nào.

3. Thảo luận chung

Dựa trên các thực nghiệm từ quy trình nhập liệu đến đánh giá hệ thống truy xuất và kiểm thử bảo mật, có thể rút ra các nhận xét tổng quát sau:

- **Hiệu quả của kiến trúc phân tách dữ liệu:** Việc phân tách cứng thông tin công khai và riêng tư ngay tại tầng dữ liệu, thay vì kiểm soát ở tầng ứng dụng, mang lại mức bảo mật tuyệt đối trong kiểm thử (100% tỉ lệ an toàn). Đây là điểm khác biệt so với các hệ thống kiểm soát truy cập thông thường, nơi ranh giới bảo mật có thể bị vượt qua nếu câu lệnh hướng dẫn mô hình bị can thiệp.
- **Chất lượng đồ thị tri thức:** Đồ thị đạt mức đầy đủ cao với 100% nút có đủ thuộc tính cần thiết và 555 kỹ năng duy nhất, trung bình 22,46 kỹ năng/ứng viên. Tuy nhiên, số lượng quan hệ tổ chức - ứng viên (10 quan hệ trên 50 nút) còn ít, làm hạn chế tín hiệu điểm kết nối trong công thức tìm kiếm. Đây là hạn chế cần giải quyết khi mở rộng quy mô hệ thống thực tế.
- **Lựa chọn mô hình biểu diễn vector:** GTE-multilingual-base là mô hình nhất quán nhất trên cả hai tác vụ: dẫn đầu về Recall trên tác vụ tìm kiếm ứng viên và tiếp tục dẫn đầu về cả Precision lẫn Recall trên tác vụ truy xuất câu hỏi phỏng vấn. BGE-M3 thể hiện sự phân kỳ lớn giữa hai tác vụ (tốt ở tìm kiếm tổng thể nhưng kém ở khớp chi tiết), cho thấy không phải mô hình có nhiều tham số nhất là lựa chọn tối ưu cho mọi tác vụ.
- **Đánh đổi giữa GraphRAG và Hybrid+:** GraphRAG cho câu trả lời trung thực và đúng đắn hơn; Hybrid+ cho câu trả lời phù hợp hơn với từng câu hỏi cụ thể. Sự khác biệt này phản ánh đặc thù của từng chiến lược: ngữ cảnh từ đồ thị có cấu trúc chặt hơn nên ít bị pha loãng, trong khi kết hợp thêm tín hiệu vector giúp bắt được ngữ nghĩa câu hỏi tốt hơn. Với bài toán tuyển dụng, Hybrid+ là lựa chọn thực tế hơn vì nhà tuyển dụng thường đặt câu hỏi theo nhiều cách khác nhau.
- **Điểm nghẽn quy trình nhập liệu:** Bước trích xuất thực thể chiếm khoảng 70% tổng thời gian xử lý (~8,97 giây trên tổng ~13 giây/CV), là điểm nghẽn không thể tránh khi dùng mô hình ngôn ngữ lớn để phân tích văn bản phi cấu trúc. Do quy trình này chạy ngầm một lần duy nhất khi ứng viên tải CV lên, độ trễ này không ảnh hưởng đến trải nghiệm người dùng cuối.

III. PHẦN KẾT LUẬN

1. Kết quả đạt được

- **Xây dựng thành công kiến trúc đồ thị đa phương thức:** Đề tài đã đề xuất và cài đặt hoàn chỉnh mô hình học sâu kết hợp giữa MGAT và mạng Kolmogorov-Arnold (FastKAN). Kiến trúc này cho phép tích hợp hiệu quả ba phương thức (hình ảnh, văn bản, âm thanh) vào một không gian biểu diễn thống nhất, khắc phục được hạn chế về nhập nhằng ngữ cảnh của các phương pháp chỉ dựa trên hình ảnh truyền thống.
- **Cải thiện đáng kể kết quả phân lớp:** Kết quả thực nghiệm chứng minh mô hình đề xuất cho ra kết quả vượt trội hơn so với các mô hình CNN Baseline đơn phương thức, đặc biệt ở các lớp dữ liệu có độ nhập nhằng cao. Việc bổ sung thông tin từ văn bản và âm thanh đã giúp hệ thống đạt độ chính xác lên tới 94.35% với DenseNet121 + MGAT + FastKAN, cao hơn 4% so với MobileNetV3 Large baseline (với độ chính xác 90.28%) khẳng định tính đúng đắn và hiệu quả của hướng tiếp cận đa phương thức.
- **Triển khai ứng dụng thực tiễn:** Đề tài đã hoàn thiện ứng dụng web ICH Predictor với giao diện trực quan, cho phép người dùng tương tác linh hoạt với hệ thống (tải lên dữ liệu đa dạng, tùy chọn mô hình). Đặc biệt, tính năng trực quan hóa cấu trúc đồ thị giúp tăng tính minh bạch trong quá trình ra quyết định của mô hình, mang lại giá trị tham khảo cho người dùng.

2. Hướng phát triển

- **Mở rộng phạm vi thực nghiệm:** Tiếp tục thử nghiệm kiến trúc đề xuất trên các họ mạng trích xuất đặc trưng hiện đại khác (như EfficientNet, ConvNeXt hoặc Vision Transformer) để đánh giá khách quan hơn về tính ổn định và khả năng thích nghi của module MGAT + FastKAN/MLP đối với các dạng đặc trưng đầu vào khác nhau.
- **Làm giàu tập dữ liệu:** Tìm kiếm và thu thập thêm dữ liệu video ICH từ nhiều nguồn khác nhau để gia tăng kích thước tập dữ liệu. Việc này không chỉ giúp mô hình học được các đặc trưng tổng quát hơn mà còn đảm bảo kết quả đánh giá mang tính khách quan cao.
- **Nâng cao khả năng suy luận trên đồ thị:** Nghiên cứu các phương pháp xây dựng đồ thị đa phương thức có tính giải thích cao hơn. Thay vì chỉ học các mối quan hệ "đối kháng" hoặc "bạn bè" thông qua trọng số cạnh, hướng phát triển trong tương lai sẽ tập trung vào việc mô hình hóa các quan hệ nhân quả hoặc ngữ nghĩa được biểu diễn một cách tường minh dưới dạng đồ thị suy luận (Reasoning Graph). Cách tiếp cận này giúp mô hình khai thác tốt hơn nội hàm ngữ nghĩa của dữ liệu ICH, đồng thời mở ra khả năng thực hiện các tác vụ suy luận dựa trên cấu trúc đồ thị.

TÀI LIỆU THAM KHẢO

- [1] Takuya Akiba et al. “Optuna: A Next-generation Hyperparameter Optimization Framework”. In: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 2019, pp. 2623–2631.
- [2] Jiacheng Chen et al. “BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation”. In: arXiv preprint arXiv:2309.07597 (2024).
- [3] Jacob Devlin et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. In: *Proceedings of NAACL-HLT 2019*. 2019, pp. 4171–4186.
- [4] Darren Edge et al. “From Local to Global: A Graph RAG Approach to Query-Focused Summarization”. In: arXiv preprint arXiv:2404.16130 (2024).
- [5] Shahul Es et al. “RAGAS: Automated Evaluation of Retrieval Augmented Generation”. In: *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*. 2024, pp. 150–158.
- [6] European Commission. *ESCO – European Skills, Competences, Qualifications and Occupations*. <https://esco.ec.europa.eu>. Accessed: 2026-04-13. 2023.
- [7] Roman Grigorev. “Relationship-Based Access Control (ReBAC) for Graph Databases”. In: *Proceedings of the 28th ACM Symposium on Access Control Models and Technologies*. 2023.
- [8] Neo4j Inc. *Neo4j Graph Database Documentation v5.26*. <https://neo4j.com/docs/>. Accessed: 2026-04-13. 2024.
- [9] Dat Quoc Nguyen and Anh Tuan Nguyen. “PhoBERT: Pre-trained Language Models for Vietnamese”. In: *Findings of the Association for Computational Linguistics: EMNLP 2020*. 2020, pp. 1037–1042.
- [10] Shirui Pan et al. “Unifying Large Language Models and Knowledge Graphs: A Roadmap”. In: *IEEE Transactions on Knowledge and Data Engineering* 36.7 (2024), pp. 3580–3599.
- [11] Jian Peng et al. “Graph Retrieval-Augmented Generation: A Survey”. In: arXiv preprint arXiv:2408.08921 (2024).

- [12] Nils Reimers and Iryna Gurevych. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. 2019, pp. 3982–3992.
- [13] Supabase Inc. *Supabase Documentation – pgvector and Vector Embeddings*. <https://supabase.com/docs/guides/ai>. Accessed: 2026-04-13. 2024.
- [14] Sergey Tikhomirov. “FastAPI: Modern, Fast Web Framework for Building APIs with Python”. In: *Journal of Open Source Software* 6.63 (2021), p. 3079.
- [15] Soon Tiong et al. “Digital Twin for Human Resource Management: A Systematic Review”. In: *Journal of Industrial Information Integration* 35 (2023), p. 100511.
- [16] Ashish Vaswani et al. “Attention Is All You Need”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017.
- [17] Liang Wang et al. “Multilingual E5 Text Embeddings: A Technical Report”. In: arXiv preprint arXiv:2402.05672 (2024).
- [18] Zhiwei Zhang et al. “mGTE: Generalized Long-Context Text Representation and Reranking Models for Multilingual Text Retrieval”. In: arXiv preprint arXiv:2407.19669 (2024).
- [19] Yukun Zhu et al. “Aligning Books and Movies: Towards Story-Like Visual Explanations by Watching Movies and Reading Books”. In: *Proceedings of the IEEE International Conference on Computer Vision*. 2015, pp. 19–27.